

3 问题一：多模态特征提取与时序对齐

3.1 问题分析与总体方案

附件 1 给出了 100 条包含文本、语音和画面信息的视频样本。三种模态经过各自编码后，文本以词语或片段形成表示，语音形成较密集的声学序列，视觉对应离散采样帧。要将这些长度和时间粒度不同的序列组织在一起，首先需要确定每个特征在原视频中对应的时间范围。

本文把独立编码、尚未进入公共时间轴的向量序列称为原生特征，把每个向量对应的媒体时间区间称为它的时间支持。文本的时间支持来自词语或识别片段，语音来自 WAV 样本范围，视觉来自采样帧附近的区间。这样，每个向量既保留内容表示，也带有能够连接其他模态的时间信息。

整体方案如图 1 所示。先建立统一媒体时间基准，分别提取带时间支持的三模态原生特征，再将每条视频的有效时长划分为 50 个公共窗。各模态按最大时间重叠规则选取每个窗的来源，形成统一长度的序列，并同步保存有效掩码和原始来源记录。




图 1 三模态特征提取与时序对齐流程。

3.2 原始数据预处理与统一时间基准

三模态的时间联系从原始媒体开始建立。每条样本以视频标识和片段编号定位，将附件 1 文件夹名、MP4 文件名与 label-100.xlsx 中的记录连接，取得对应的赛题转写与情感标注。媒体路径及文件哈希随处理记录保存，使三种特征始终连接到同一片段。

音频由 FFmpeg 提取 MP4 的第一音轨，转换为 16 kHz 单声道 PCM WAV；视频帧的显示时间戳（PTS）由 FFprobe 读取。对全部 100 条媒体核验后，音视频流起点、首视频帧 PTS 和首解码音频帧 PTS 均为 0 s，因而 WAV 样本零点与视频 PTS 零点共同构成相对时间起点。

以容器时长和最后一帧 PTS 加一个名义帧间隔中的较大者作为有效时长 T_i ，第 i 条样本的媒体时间域为

$$\mathcal{T}_i = [0, T_i). \quad (1)$$

文本时间、WAV 样本位置换算的秒数及视频帧 PTS 都在媒体时间域 T_i 中记录。为得到统一长度的序列，将每条样本自身的有效时长等分为 $K = 50$ 个公共窗，并保存各窗的实际秒数边界。由于视频长度不同，同一窗号的时间范围随样本时长变化。

图 2 中，视频时长以较短片段为主，同时包含少量较长片段。文本有效窗数的样本间差异较大，语音和视觉则较集中；文本内容主要采用赛题转写，时间戳回退涉及少数样本。这些差异在共同时间基准下保留，成为逐样本特征记录的一部分。




图 2 附件 1 样本与三模态特征统计。

3.3 三模态原生特征提取

有了共同的媒体时间坐标，就可以分别为词语、声学位置和采样画面建立时间支持。三种模态各自编码，原生序列保留自身采样密度，每一行向量与对应时间区间及原始来源一起保存。

3.3.1 文本特征提取

文本的内容和时间信息分别来自赛题转写与同一视频的语音识别。采用 **Whisper large-v3-turbo** 获取词级和片段级时间 [1]，将能够对应到识别词序的赛题词语连接到这些区间；未匹配词保留在原转写中，编码时使用已建立时间支持的词语。对于文本对应条件不满足的片段，采用媒体 ASR 内容。最终 75 条使用赛题转写，25 条使用媒体 ASR。例如，样本-NFrJFQijFE_2 的赛题转写描述仪器准备，而识别内容描述鹰的听觉和视觉，该样本采用媒体 ASR，同时保留原转写。

词级区间须为有限值，满足 $0 \leq s < e \leq T_i$ ，且起止边界相对于前一原始词区间保持

时间顺序。无效或非单调的词级区间回退到所属识别片段的有效范围；若该片段也无有效时间，则记录为未解决。时间来源和回退标记随文本记录保存，区分词级和片段级支持。

带时间信息的词语列表按图 3 的流程送入 RoBERTa-base 编码 [2]。快速分词器按预分词列表处理，最大长度为 510 词元；取最后一层隐藏表示，并按词索引平均同一词的子词向量，得到 768 维原生表示。特殊词元由分词器索引排除，截断后没有对应词元的单元保留提示记录。模型使用预训练权重进行推理。第 j 个文本特征及其时间支持为

$$\mathbf{h}_{ij}^{(T)} \in \mathbb{R}^{768}, \quad I_{ij}^{(T)} = [s_{ij}^{(T)}, e_{ij}^{(T)}]. \quad (2)$$




图 3 文本模态特征提取流程。色块为表示结构示意图。

3.3.2 语音特征提取

文本建立了语言内容的时间位置，语音则需将连续波形编码后的声学位置连接回 WAV。使用 WavLM-base-plus 处理 16 kHz 单声道输入 [3]，取最后一层逐位置表示，得到 768 维声学序列。

根据模型卷积核与步长，计算累计步距 H 和感受范围 R 。当 WAV 含 N 个样本时，第 j 个声学位置对应采样区间 $[jH, \min(N, jH + R)]$ ；区间端点除以采样率后转换为秒，并将末端限制在 T_i 以内。输出位置数与模型长度计算函数核对，原生向量同时记录其 WAV 采样范围。声学特征及时间支持记为

$$\mathbf{h}_{ij}^{(A)} \in \mathbb{R}^{768}, \quad I_{ij}^{(A)} = [s_{ij}^{(A)}, e_{ij}^{(A)}]. \quad (3)$$

声学位置较密集，同一个公共窗内可能覆盖多个原生区间，后续通过时间交叠确定该窗的语音来源。原始波形到声学表示的处理见图 4。




图 4 语音模态特征提取流程。色块为表示结构示意图。

3.3.3 视觉特征提取

文本和语音已有媒体时间区间，视觉特征进一步由采样画面的真实显示时刻定位。以每秒 4 帧建立目标时间网格，在 PTS 序列中选择离目标时刻最近的帧；等距时取较早帧，

相邻目标选中同一帧时保留一次。所选画面按源帧编号解码，经配套图像处理器缩放、归一化后，送入 SigLIP2-base-patch16-224[4]，得到 768 维视觉向量。

以相邻已选帧 PTS 的中点划分支持区间，首边界为 0，尾边界为 T_i 。每个向量同时保留源帧编号和 PTS：前者定位原视频画面，后者记录其显示时刻，支持区间则参与公共窗映射。视觉原生表示为

$$\mathbf{h}_{ij}^{(V)} \in \mathbb{R}^{768}, \quad I_{ij}^{(V)} = [s_{ij}^{(V)}, e_{ij}^{(V)}]. \quad (4)$$

全部视频的顺序解码帧与 FFprobe 记录的显示时间经核验保持一致，源帧编号与 PTS 可以联合回查视觉来源。采样与编码步骤见图 5。




图 5 视觉模态特征提取流程。色块为表示结构示意图。

3.4 基于最大时间重叠的跨模态时序对齐

经过独立提取，三种模态都具有原生向量和时间支持。跨模态对齐据此将它们映射为固定长度序列，使同一公共位置汇集来自相同媒体时间范围的文本、语音和视觉信息（图 6）。

一个公共窗可与同一模态的多个原生区间交叠。本文选取正交叠时长最长的一个，让该窗直接继承对应向量；这样，每个有效位置都连接到一个确定的原生来源。

将第 i 条样本的有效时长均分为 $K = 50$ 个半开区间：

$$B_{ik} = \left[\frac{kT_i}{K}, \frac{(k+1)T_i}{K} \right), \quad k = 0, 1, \dots, K-1. \quad (5)$$

记 $b_{ik} = kT_i/K$ ，模态 $m \in \{T, A, V\}$ 的原生时间支持为

$$I_{ij}^{(m)} = [s_{ij}^{(m)}, e_{ij}^{(m)}]. \quad (6)$$

其与公共窗的交叠长度为

$$\omega_{ijk}^{(m)} = \max \left(0, \min(e_{ij}^{(m)}, b_{i,k+1}) - \max(s_{ij}^{(m)}, b_{ik}) \right). \quad (7)$$

当存在正交叠时，选择

$$j_{ik}^{(m)} = \arg \max_j \omega_{ijk}^{(m)}, \quad \omega_{i,j_{ik}^{(m)},k}^{(m)} > 0, \quad (8)$$

并令

$$\mathbf{z}_{ik}^{(m)} = \mathbf{h}_{i,j_{ik}^{(m)}}^{(m)}, \quad M_{ik}^{(m)} = 1. \quad (9)$$

实际实现中，最大交叠并列时，优先选择区间中心更接近公共窗中心者，仍并列则取较早原生索引。所选索引、时间支持和实际交叠时长写入来源记录。无正交叠时，令 $\mathbf{z}_{ik}^{(m)} = \mathbf{0}$ 、

$M_{ik}^{(m)} = 0$ ，保留空来源；有效性由掩码 $M_{ik}^{(m)}$ 表示。单样本及全量结果分别组织为

$$\mathbf{Z}_i^{(m)} \in \mathbb{R}^{50 \times d_m}, \quad \mathbf{Z}^{(m)} \in \mathbb{R}^{100 \times 50 \times d_m}, \quad d_T = d_A = d_V = 768. \quad (10)$$




图 6 三模态原生序列到公共时间窗的映射。矩阵色值为结构示意图。

3.5 特征构建结果与完整性检验

对全部 100 条样本完成映射后，文本、语音和视觉各形成 $100 \times 50 \times 768$ 的单精度浮点数组，有效掩码各为 100×50 的布尔数组。三种模态的原生向量总数及平均覆盖率见表 1。

表 1 三模态特征构建与时间覆盖结果

模态	特征提取方法	原生特征数	特征维数	单样本对齐形状	平均时间覆盖率
文本	RoBERTa-base	1847	768	50×768	0.8242
语音	WavLM-base-plus	38776	768	50×768	0.9910
视觉	SigLIP2-B/16	3205	768	50×768	1.0000

文本、语音和视觉的有效位置分别为 4121、4955 和 5000，平均覆盖率为 0.8242、0.9910 和 1.0000。文本以离散词语和片段出现，部分公共窗内没有对应文本特征，由文本掩码标记；连续声学序列更密集，语音仅在少数位置出现空窗；视觉支持区间覆盖全部 50 窗。覆盖率差异由各模态的时间组织体现出来。

完整性检查确认 100 个样本编号唯一，矩阵行序与样本清单一致，三模态数组形状及掩码尺寸匹配，特征数值均有限，无效位置均为零。来源表包含全部 15000 个“样本—公共窗—模态”组合，每个有效位置均能连接到被选原生索引及原始来源。

3.6 全量样本特征构建结果

各样本的媒体时长和语言内容不同，对应的特征覆盖也有所变化。表 2 逐条列出 100 条样本的时长、模态、维度和对齐粒度，并保留三模态有效窗、文本来源及时间戳回退记录。

表 2 附件 1 全部 100 条样本的三模态特征构建与时序对齐结果

样本 ID	时长/s	模态	维度 (T/A/V)	对齐 粒度	有效窗 (T/A/V)	文本 来源	回退
-3g5yACwYnA__13	5.514	T/A/V	768/768/768	50 窗	33/49/50	赛题转写	0
-3g5yACwYnA__2	9.394	T/A/V	768/768/768	50 窗	28/50/50	赛题转写	0
-3g5yACwYnA__3	14.389	T/A/V	768/768/768	50 窗	43/50/50	赛题转写	0
-3g5yACwYnA__9	8.817	T/A/V	768/768/768	50 窗	43/50/50	赛题转写	0
-3nNcZdcvU__5	7.868	T/A/V	768/768/768	50 窗	37/50/50	赛题转写	0
-571d8cVauQ__0	5.167	T/A/V	768/768/768	50 窗	34/49/50	赛题转写	0
-571d8cVauQ__5	15.273	T/A/V	768/768/768	50 窗	47/50/50	赛题转写	0
-6rXp3zJ3kc__8	12.805	T/A/V	768/768/768	50 窗	44/50/50	赛题转写	0
-9y-fZ3swSY__0	6.900	T/A/V	768/768/768	50 窗	41/49/50	赛题转写	0
-9y-fZ3swSY__4	2.821	T/A/V	768/768/768	50 窗	44/47/50	赛题转写	0
-9y-fZ3swSY__8	4.989	T/A/V	768/768/768	50 窗	41/50/50	赛题转写	0
-AUZQgSxyPQ__2	22.511	T/A/V	768/768/768	50 窗	45/50/50	赛题转写	0
-HeZS2-Prhc__2	8.262	T/A/V	768/768/768	50 窗	40/50/50	赛题转写	0
-HwX2H8Z4hY__2	3.982	T/A/V	768/768/768	50 窗	26/50/50	媒体 ASR	0
-HwX2H8Z4hY__5	5.653	T/A/V	768/768/768	50 窗	44/49/50	赛题转写	0
-HwX2H8Z4hY__6	3.358	T/A/V	768/768/768	50 窗	38/49/50	赛题转写	0
-HwX2H8Z4hY__9	7.734	T/A/V	768/768/768	50 窗	46/50/50	赛题转写	0
-I_e4mIh0yE__1	7.622	T/A/V	768/768/768	50 窗	44/49/50	赛题转写	0
-I_e4mIh0yE__3	9.163	T/A/V	768/768/768	50 窗	46/50/50	赛题转写	0
-MeTTTeMJBNC__0	9.333	T/A/V	768/768/768	50 窗	42/50/50	赛题转写	0
-MeTTTeMJBNC__13	5.430	T/A/V	768/768/768	50 窗	39/49/50	赛题转写	0
-MeTTTeMJBNC__7	10.517	T/A/V	768/768/768	50 窗	45/50/50	赛题转写	0
-NFrJFQijFE__1	5.746	T/A/V	768/768/768	50 窗	13/50/50	媒体 ASR	5
-NFrJFQijFE__2	6.856	T/A/V	768/768/768	50 窗	25/49/50	媒体 ASR	0
-RfYyzHpjk4__11	5.239	T/A/V	768/768/768	50 窗	43/49/50	赛题转写	0
-RfYyzHpjk4__2	5.516	T/A/V	768/768/768	50 窗	42/49/50	赛题转写	1
-RfYyzHpjk4__8	4.589	T/A/V	768/768/768	50 窗	37/50/50	赛题转写	0
-THoVjtlkeU__12	14.896	T/A/V	768/768/768	50 窗	40/50/50	赛题转写	0
-THoVjtlkeU__2	4.292	T/A/V	768/768/768	50 窗	43/50/50	赛题转写	0
-THoVjtlkeU__6	8.097	T/A/V	768/768/768	50 窗	45/50/50	赛题转写	0
-UUCSKoHeMA__0	7.867	T/A/V	768/768/768	50 窗	37/50/50	赛题转写	0
-UacrmKiTn4__10	7.362	T/A/V	768/768/768	50 窗	41/50/50	赛题转写	0
-UacrmKiTn4__4	4.741	T/A/V	768/768/768	50 窗	43/50/50	赛题转写	0
-UuX1xuaiiE__0	3.700	T/A/V	768/768/768	50 窗	40/49/50	赛题转写	0
-UuX1xuaiiE__1	10.350	T/A/V	768/768/768	50 窗	47/50/50	赛题转写	0

续下页

续表 2（接上页）

样本 ID	时长/s	模态	维度 (T/A/V)	对齐 粒度	有效窗 (T/A/V)	文本 来源	回退
-UuX1xuaiiE__3	4.130	T/A/V	768/768/768	50 窗	43/49/50	赛题转写	0
-UuX1xuaiiE__6	8.114	T/A/V	768/768/768	50 窗	45/49/50	赛题转写	1
-a55Q6RWvTA__3	22.154	T/A/V	768/768/768	50 窗	48/50/50	赛题转写	0
-aNfi7CP8vM__7	8.695	T/A/V	768/768/768	50 窗	46/50/50	赛题转写	0
-aqamKhZ1Ec__0	11.000	T/A/V	768/768/768	50 窗	33/50/50	赛题转写	0
-dxFTGcXJoc__0	20.533	T/A/V	768/768/768	50 窗	47/50/50	赛题转写	0
-dxFTGcXJoc__1	16.161	T/A/V	768/768/768	50 窗	47/50/50	赛题转写	0
-dxFTGcXJoc__2	16.698	T/A/V	768/768/768	50 窗	46/50/50	赛题转写	0
-dxFTGcXJoc__6	12.735	T/A/V	768/768/768	50 窗	48/50/50	赛题转写	0
-egA8-b7-3M__1	10.266	T/A/V	768/768/768	50 窗	44/50/50	赛题转写	0
-egA8-b7-3M__13	4.184	T/A/V	768/768/768	50 窗	40/48/50	赛题转写	0
-egA8-b7-3M__16	5.538	T/A/V	768/768/768	50 窗	41/50/50	赛题转写	0
-egA8-b7-3M__17	7.271	T/A/V	768/768/768	50 窗	43/49/50	赛题转写	0
-egA8-b7-3M__18	8.386	T/A/V	768/768/768	50 窗	47/50/50	赛题转写	0
-egA8-b7-3M__20	6.645	T/A/V	768/768/768	50 窗	43/49/50	赛题转写	0
-egA8-b7-3M__26	6.031	T/A/V	768/768/768	50 窗	42/49/50	赛题转写	0
-egA8-b7-3M__6	6.265	T/A/V	768/768/768	50 窗	40/50/50	赛题转写	0
-egA8-b7-3M__9	5.090	T/A/V	768/768/768	50 窗	40/49/50	赛题转写	0
-hnBHBn8p5A__6	6.401	T/A/V	768/768/768	50 窗	43/50/50	媒体 ASR	0
-hnBHBn8p5A__7	7.372	T/A/V	768/768/768	50 窗	46/50/50	媒体 ASR	0
-iRBcNs9oI8__3	5.621	T/A/V	768/768/768	50 窗	47/50/50	媒体 ASR	0
-iRBcNs9oI8__6	2.903	T/A/V	768/768/768	50 窗	42/49/50	媒体 ASR	0
-iRBcNs9oI8__7	4.104	T/A/V	768/768/768	50 窗	44/49/50	媒体 ASR	0
-iRBcNs9oI8__8	8.093	T/A/V	768/768/768	50 窗	41/50/50	媒体 ASR	0
-iRBcNs9oI8__9	3.416	T/A/V	768/768/768	50 窗	34/50/50	媒体 ASR	0
-lZEya4AM__4_5	7.675	T/A/V	768/768/768	50 窗	42/50/50	赛题转写	0
-lZEya4AM__4_6	14.792	T/A/V	768/768/768	50 窗	48/50/50	赛题转写	0
-mJ2ud6oKI8__1	6.103	T/A/V	768/768/768	50 窗	45/50/50	媒体 ASR	0
-mJ2ud6oKI8__2	5.731	T/A/V	768/768/768	50 窗	45/50/50	媒体 ASR	0
-mJ2ud6oKI8__6	2.257	T/A/V	768/768/768	50 窗	45/50/50	媒体 ASR	0
-mJ2ud6oKI8__8	4.192	T/A/V	768/768/768	50 窗	45/50/50	媒体 ASR	4
-mJ2ud6oKI8__9	7.033	T/A/V	768/768/768	50 窗	49/50/50	媒体 ASR	1
-mqbVkbCndg__0	6.500	T/A/V	768/768/768	50 窗	41/50/50	赛题转写	0
-qDkUB0GgYY__6	4.678	T/A/V	768/768/768	50 窗	37/50/50	赛题转写	0
-ri04Z7vwnc__0	2.807	T/A/V	768/768/768	50 窗	19/49/50	媒体 ASR	0
-ri04Z7vwnc__2	6.027	T/A/V	768/768/768	50 窗	14/49/50	媒体 ASR	0
-ri04Z7vwnc__5	3.545	T/A/V	768/768/768	50 窗	48/49/50	媒体 ASR	1
-s9qJ7ATP7w__0	6.867	T/A/V	768/768/768	50 窗	43/49/50	媒体 ASR	0
-s9qJ7ATP7w__1	4.792	T/A/V	768/768/768	50 窗	38/49/50	赛题转写	0
-s9qJ7ATP7w__4	4.427	T/A/V	768/768/768	50 窗	31/48/50	赛题转写	0
-s9qJ7ATP7w__5	8.561	T/A/V	768/768/768	50 窗	46/49/50	赛题转写	0
-s9qJ7ATP7w__6	2.475	T/A/V	768/768/768	50 窗	29/47/50	赛题转写	0
-s9qJ7ATP7w__7	6.966	T/A/V	768/768/768	50 窗	42/49/50	赛题转写	0

续下页

续表 2（接上页）

样本 ID	时长/s	模态	维度 (T/A/V)	对齐 粒度	有效窗 (T/A/V)	文本 来源	回退
-s9qJ7ATP7w__8	3.295	T/A/V	768/768/768	50 窗	36/49/50	赛题转写	0
-t217m2on-s__2	5.686	T/A/V	768/768/768	50 窗	39/50/50	赛题转写	0
-t217m2on-s__7	17.183	T/A/V	768/768/768	50 窗	48/50/50	赛题转写	0
-tANM6ETI_M__3	6.758	T/A/V	768/768/768	50 窗	45/49/50	赛题转写	0
-tPCytz4rww__10	4.789	T/A/V	768/768/768	50 窗	48/49/50	媒体 ASR	0
-tPCytz4rww__11	5.467	T/A/V	768/768/768	50 窗	49/50/50	媒体 ASR	0
-tPCytz4rww__12	11.864	T/A/V	768/768/768	50 窗	47/50/50	媒体 ASR	0
-tPCytz4rww__16	7.206	T/A/V	768/768/768	50 窗	45/50/50	赛题转写	0
-tPCytz4rww__18	6.645	T/A/V	768/768/768	50 窗	42/50/50	赛题转写	0
-uywlfIYOS8__4	6.045	T/A/V	768/768/768	50 窗	34/49/50	赛题转写	0
-vxjVxOeScU__4	9.127	T/A/V	768/768/768	50 窗	45/50/50	赛题转写	0
-wMB_hJL-3o__7	6.044	T/A/V	768/768/768	50 窗	39/50/50	赛题转写	0
-wny0OAz3g8__0	3.333	T/A/V	768/768/768	50 窗	41/49/50	赛题转写	0
-wny0OAz3g8__1	6.844	T/A/V	768/768/768	50 窗	46/50/50	赛题转写	0
-wny0OAz3g8__2	6.687	T/A/V	768/768/768	50 窗	42/49/50	赛题转写	0
-wny0OAz3g8__3	6.146	T/A/V	768/768/768	50 窗	41/50/50	赛题转写	0
-wny0OAz3g8__5	6.912	T/A/V	768/768/768	50 窗	43/49/50	赛题转写	0
-wny0OAz3g8__7	8.068	T/A/V	768/768/768	50 窗	46/49/50	赛题转写	0
-wny0OAz3g8__9	6.213	T/A/V	768/768/768	50 窗	42/49/50	赛题转写	0
-yRb-Jum7EQ__1	29.288	T/A/V	768/768/768	50 窗	38/50/50	媒体 ASR	8
-yRb-Jum7EQ__5	13.169	T/A/V	768/768/768	50 窗	45/50/50	媒体 ASR	0
-yRb-Jum7EQ__6	11.242	T/A/V	768/768/768	50 窗	47/50/50	媒体 ASR	0

注：

- (1) T、A、V 分别表示文本、语音、视觉；“有效窗 (T/A/V)” 依次给出三模态的有效公共窗数。
- (2) “赛题转写” 为附件 1 label-100.xlsx 的 text 字段；“媒体 ASR” 为当前视频语音识别得到的文本。
- (3) “回退” 为词级时间戳不可用时，实际采用所属识别片段时间区间的映射次数。

文本有效窗数为 13–49，语音为 47–50，视觉均为 50，文本时间支持呈现出最明显的样本间差异。75 条采用赛题转写，25 条采用媒体 ASR；7 条样本包含时间戳回退，累计 21 个实际回退位置。逐样本记录因而同时呈现覆盖范围和文本时间支持的粒度，与总体平均覆盖率共同反映特征构建结果。

3.7 方案比较与信息保持能力验证

在确认特征能够完整读取并回溯后，进一步比较不同方案对情感信息的保持能力。使用固定的轻量预测模型作为特征探针，在同一训练与评价设置下分别改变对齐方法、视觉编码器和模态组合，以准确率、宏平均 F1、MAE 及皮尔逊相关系数观察差异。

探针将每模态 768 维输入映射为 32 维，在公共位置拼接三路表示，经小型感知机变换和联合有效位均值池化，输出情感类别与连续强度。采用 40 轮 AdamW 训练，学习率 0.002、权重衰减 0.001，目标为交叉熵加 0.25 倍平滑绝对误差；标准化参数由各训练折的有效位置估计。评价为 5 次重复分层五折，表中报告均值与样本标准差。由于按片段标签分层、未按原视频分组，该实验用于 Q1 内部方案比较。

3.7.1 时序对齐方法比较

首先比较最大时间重叠、最近中心和重叠加权平均，结果见表 3 及图 7。三种方案的平均指标总体接近，最近中心在部分指标上略高；同时，其 152 个有效文本公共窗选择了与目标窗零交叠的来源。

表 3 不同时序对齐方法的定量比较

对齐方法	准确率	宏平均 F1 值	平均绝对误差 (MAE)	皮尔逊相关系数
最大时间重叠法	0.6129 ± 0.0938	0.4816 ± 0.0850	0.5258 ± 0.0966	0.5419 ± 0.1470
最近中心法	0.6148 ± 0.0913	0.4832 ± 0.0849	0.5210 ± 0.0967	0.5535 ± 0.1492
重叠加权平均法	0.6074 ± 0.0945	0.4712 ± 0.0868	0.5237 ± 0.0977	0.5482 ± 0.1506

注：数值为均值 $\pm$ 样本标准差。

重叠加权平均将多个原生向量合成为一个公共位置，来源随之变为多行向量及权重的组合。最大时间重叠则保留正时间交叠与单一来源，使每个公共位置能够直接回查到原生行。综合辅助评价、时间对应和回查方式，最终采用最大时间重叠对齐。




图 7 对齐方法的辅助评价。点为均值，半透明区间为均值上下一个样本标准差。

3.7.2 视觉特征提取方法比较

确定时间映射后，比较不同视觉表示对情感信息的保持效果。固定采样帧、PTS 及对齐规则，仅将 SigLIP2 替换为 DINOv3[5]，得到表 4 的结果。

表 4 不同视觉特征提取方法的比较

视觉编码器	准确率	宏平均 F1	MAE	皮尔逊 r	提取时长 (秒)
SigLIP2	0.6129 ± 0.0938	0.4816 ± 0.0850	0.5258 ± 0.0966	0.5419 ± 0.1470	52.37
DINOv3 (ViT-B/16)	0.5899 ± 0.0857	0.4427 ± 0.0760	0.5401 ± 0.0819	0.5155 ± 0.1473	70.38

SigLIP2 的准确率、宏平均 F1 和相关系数均值更高，MAE 均值更低，单次提取耗时也较短，因此选为最终视觉编码器。两组使用相同视觉来源，差异体现这些画面经不同骨干形成的表示效果。

3.7.3 模态组合比较

在所选对齐方法与视觉编码器下，再比较三个单模态、三种双模态及三模态组合，结果见表 5。各组合沿用相同公共窗与有效位，通过增减输入观察任务信息的变化。

表 5 不同模态组合的定量比较

模态组合	准确率	宏平均 F1 值	平均绝对误差 (MAE)	皮尔逊 相关系数
文本	0.6519 ± 0.0772	0.5202 ± 0.0935	0.5516 ± 0.0797	0.4998 ± 0.1148
语音	0.6230 ± 0.0756	0.3927 ± 0.1050	0.5936 ± 0.0986	0.2254 ± 0.1800
视觉	0.5332 ± 0.0857	0.4195 ± 0.0942	0.6064 ± 0.0872	0.4428 ± 0.1550
文本 + 语音	0.6783 ± 0.0726	0.5454 ± 0.0900	0.5409 ± 0.0836	0.5135 ± 0.1145
文本 + 视觉	0.5992 ± 0.1049	0.4711 ± 0.0969	0.5257 ± 0.1021	0.5493 ± 0.1580
语音 + 视觉	0.5744 ± 0.0893	0.4617 ± 0.0991	0.5949 ± 0.0833	0.4274 ± 0.1597
文本 + 语音 + 视觉	0.6129 ± 0.0938	0.4816 ± 0.0850	0.5258 ± 0.0966	0.5419 ± 0.1470

文本单模态保留了较强的情感信息，加入语音后分类指标进一步提高；文本与视觉组合在连续强度预测的 MAE 和相关系数上均值较优。分类与强度预测各有优势组合，表明语言内容、声音和画面对两类任务的作用有所差异。三模态简单拼接的结果仍有融合改进空间。

3.8 特征文件组织与复现说明

上述结果分别保存为三模态特征、有效掩码、样本行序和逐窗来源四部分，文件组织见表 6。模型标识、版本与文件校验信息随特征清单保存。

表 6 对齐特征与来源文件组织

文件	内容与组织形式
aligned_features_ fp32.npz	text/audio/vision; 各 $100 \times 50 \times 768$, FP32
masks.npz	三模态有效掩码; 各 100×50 , 布尔值
sample_ids.csv	行号与样本编号; 100 条对应记录
source_mapping_ 15000.csv	逐公共窗来源; 15000 条记录

读取时以样本编号确定矩阵行，再按模态取得特征与有效掩码。媒体来源可按样本编号、公共窗索引及模态连接来源表，得到原生行号、时间区间与文本、WAV 或源帧记录；原生向量和同名说明文件随结果一并保存。

复现时依次核对媒体信息，转换音频并获取文本时间，完成三模态原生编码、时间支持建立、公共窗划分和最大时间重叠映射，再保存并检查四部分产物。核心环境为 PyTorch 2.14.0+cu130 与 Transformers 4.57.3，编码器及采样设置沿用前述配置。

3.9 典型样本分析与本问小结

样本-a55Q6RWvTA__3 的有效时长为 22.154 s，划分为 50 个公共窗。表 7 列出第 24–26 窗，即零起始索引 23–25 的九条三模态映射记录。

表 7 典型样本连续三个公共时间窗的三模态时序对齐与来源追踪

公共窗及范围/s	模态	原生索引	时间支持/s	交叠时长/s	原始来源
第 24 窗 索引 23 [10.191, 10.634)	文本	31	10.300–10.520	0.220	词语: best 词级时间支持
	语音	520	10.400–10.425	0.025	WAV 采样区间: [166400, 166800)
	视觉	42	10.367–10.617	0.250	源帧: 315 帧显示时间: 10.500 s
第 25 窗 索引 24 [10.634, 11.077)	文本	34	10.900–11.120	0.177	词语: life 词级时间支持
	语音	542	10.840–10.865	0.025	WAV 采样区间: [173440, 173840)
	视觉	43	10.617–10.867	0.233	源帧: 322 帧显示时间: 10.733 s
第 26 窗 索引 25 [11.077, 11.520)	文本	36	11.320–11.700	0.200	词语: free 词级时间支持
	语音	564	11.280–11.305	0.025	WAV 采样区间: [180480, 180880)
	视觉	45	11.117–11.367	0.250	源帧: 337 帧显示时间: 11.233 s

注: (1) “第 24 窗”等窗序号从 1 开始; “索引 23”等公共窗索引及原生特征索引从 0 开始。源帧编号沿用原始记录。(2) 时间支持为所选原生特征的媒体时间区间, 交叠时长为其与对应公共窗的交集长度; 数值沿用既有结果的三位小数表示。(3) 文本来自赛题转写, 时间支持来自词级识别时间戳; WAV 采样区间为左闭右开; 视觉 PTS 为源帧显示时间, 与视觉特征支持区间含义不同。

词语 best、life、free 分别为各窗选中的来源, 不表示连续原文短语。

第 25 窗的范围为 [10.634, 11.077) s。文本索引 34 的支持区间为 10.900–11.120 s, 语音索引 542 为 10.840–10.865 s, 视觉索引 43 为 10.617–10.867 s。三个区间宽度不同, 但都与该窗发生实际交叠, 由此汇入同一个公共位置。

三个连续窗内, 文本原生索引从 31 变为 34、36, 语音从 520 变为 542、564, 视觉从 42 变为 43、45。索引变化速度反映各模态的采样密度; 公共窗按媒体时间组织这些来源, 同时保留其原有序列位置。

每个公共位置还可沿原生索引和时间区间回查文本词语、WAV 样本或视频帧。例如, 第 25 窗的视觉特征来自帧 322, PTS 为 10.733 s, 显示时刻与该特征的支持区间分别记录。这样, 从统一序列可以逐层返回实际媒体来源。

本文从媒体时间出发构建三模态原生特征, 通过最大时间重叠形成统一的 50 位序列, 最终得到 100 条样本的特征、有效掩码和来源记录。辅助比较支持所采用的对齐与视觉编码方案, 真实样本呈现了统一时间位置与文本、语音和画面来源之间的对应关系。

4 问题二：缺失场景下的多模态情感预测模型

4.1 问题分析与总体方案

针对问题二，由于附件 2 已经给出了统一到 50 个时间位置的文本、语音和视觉特征，本文直接以对齐后的三模态序列为输入，同时开展情感极性分类与连续情感强度回归，并进一步研究局部连续缺失对预测结果的影响。考虑到缺失可能发生在不同模态、不同位置并持续不同长度，后续从缺失模态、缺失比例和缺失位置三个方面设置统一场景，用于比较模型在完整输入和不同受损条件下的表现。

为建立结构简单、便于分析缺失影响的比较参照，本文首先采用掩码均值池化（Masked Mean Pooling, MMP），聚合各模态有效时间位置上的特征，再进行融合并输出分类与回归结果。这一路径能够处理不同有效长度的序列，但对同一模态内所有有效位置等权处理，局部缺失后仍难以区分剩余位置的重要程度。

针对这一限制，本文在均值表示之外引入内容驱动的时间加权残差分支，构成轻量时间注意力残差池化（Lightweight Temporal Attention Residual Pooling, LTARP）。均值分支保留整体统计信息，新增分支根据当前样本内容调整时间位置权重，为突出剩余序列中更有判别力的信息提供补充。后续在固定连续缺失场景中评价这一补充的实际收益，整体结构见图 8。




图 8 LTARP 三模态池化与双任务预测流程。

4.2 数据表示与预测任务

为使后续比较主要反映聚合方式与缺失场景带来的差异，本文在统一的数据划分和标签定义下使用附件 2 的对齐输入。对齐特征文件为 `aligned-50.pkl`，训练、验证和测试划分分别含 3395、728 和 727 条样本。训练集用于学习参数，验证集用于结构选择与评价；测试划分和无标签附件 3 不参与建模。

统一最大长度为 $T = 50$ ，样本 i 的三模态输入为

$$\mathbf{X}_i^{(T)} \in \mathbb{R}^{50 \times 768}, \quad \mathbf{X}_i^{(A)} \in \mathbb{R}^{50 \times 74}, \quad \mathbf{X}_i^{(V)} \in \mathbb{R}^{50 \times 35}. \quad (11)$$

样本有效长度为 L_i ($3 \leq L_i \leq 50$), 由随附注意力掩码确定。定义有效槽位指示变量

$$p_{it} = \begin{cases} 1, & t \in \{1, 2, \dots, L_i\}, \\ 0, & t \in \{L_i + 1, \dots, 50\}. \end{cases} \quad (12)$$

缺失实验仅作用于原本有效的时间位置。附件 2 中已有的零值输入保持原始状态, 并与后续人为构造的连续缺失分别记录。填充后缀由掩码排除, 原始有效范围在遮挡前后保持一致。人工置零的位置仍位于有效前缀中, 均值聚合的分母继续使用原有效长度, 模型因而接收相同长度、局部内容受损的序列。

连续情感强度标签记为 $y_i \in [-3.0, +3.0]$, 三类极性由其符号确定:

$$c_i = \begin{cases} 0 & (\text{消极 Negative}), & y_i < 0, \\ 1 & (\text{中性 Neutral}), & y_i = 0, \\ 2 & (\text{积极 Positive}), & y_i > 0. \end{cases} \quad (13)$$

其中 $y_i = 0$ 对应中性类, 分类与回归分别描述极性类别和连续情感强度。

训练集与验证集均以积极样本为最多, 中性样本相对较少, 类别比例呈现不均衡; 连续情感强度集中于零附近, 两侧分布覆盖不同程度的极性。有效序列长度也有明显差异, 训练与验证的中位数分别为 22 和 23.5, 小于统一长度 50。因此, 类别权重和有效位掩码分别进入损失计算与特征聚合 (图 9)。




图 9 附件 2 的样本、情感标签与有效序列长度分布。

4.3 掩码均值池化基线

在上述输入与任务定义基础上，本文首先建立掩码均值池化基线 **MMP**，作为后续改进结构的比较参照。有效位掩码使填充后缀不参与聚合，各模态由此得到固定维度的均值向量，再接入共同的融合与双任务输出路径。对模态 $m \in \{T, A, V\}$ ，其均值为

$$\boldsymbol{\mu}_i^{(m)} = \frac{\sum_{t=1}^{50} p_{it} \mathbf{x}_{it}^{(m)}}{\sum_{t=1}^{50} p_{it}}. \quad (14)$$

均值向量通过模态专属映射 $P_m(\cdot)$ 得到 128 维表示：

$$\mathbf{h}_{i,0}^{(m)} = P_m(\boldsymbol{\mu}_i^{(m)}) = \text{Dropout}\left(\text{GELU}\left(\text{LayerNorm}(\mathbf{W}_m \boldsymbol{\mu}_i^{(m)} + \mathbf{b}_m)\right)\right). \quad (15)$$

三路表示拼接为 384 维向量 $\mathbf{h}_i^{\text{concat}} = [\mathbf{h}_{i,0}^{(T)}; \mathbf{h}_{i,0}^{(A)}; \mathbf{h}_{i,0}^{(V)}]$ ，再经 128 维融合层得到

$$\mathbf{z}_i = \text{Dropout}\left(\text{GELU}\left(\text{LayerNorm}(\mathbf{W}_f \mathbf{h}_i^{\text{concat}} + \mathbf{b}_f)\right)\right). \quad (16)$$

联合表征分别连接三分类与强度回归输出：

$$\hat{\mathbf{p}}_i = \text{Softmax}(\mathbf{W}_c \mathbf{z}_i + \mathbf{b}_c) \in \mathbb{R}^3, \quad \hat{y}_i = \mathbf{W}_r \mathbf{z}_i + b_r \in \mathbb{R}. \quad (17)$$

预测类别取 $\hat{c}_i = \arg \max_{k \in \{0,1,2\}} \hat{p}_{ik}$ 。

训练集的消极、中性和积极样本数分别为 967、758 和 1670。采用类别频数逆加权交叉熵，使三类在分类目标中获得相应权重：

$$w_c = \frac{N_{\text{train}}}{3 \cdot N_c}, \quad \mathcal{L}_{\text{WCE}} = -\frac{\sum_{i=1}^N w_{c_i} \log \hat{p}_{i c_i}}{\sum_{i=1}^N w_{c_i}}. \quad (18)$$

其中分类损失按当前批次标签权重之和归一化， N 为批次样本数。回归采用 SmoothL1 损失：

$$\mathcal{L}_{\text{SmoothL1}} = \frac{1}{N} \sum_{i=1}^N \ell_{\text{smooth}}(\hat{y}_i - y_i), \quad \ell_{\text{smooth}}(u) = \begin{cases} 0.5u^2, & |u| < 1, \\ |u| - 0.5, & |u| \geq 1. \end{cases} \quad (19)$$

两项任务以相同权重联合优化：

$$\mathcal{L} = \mathcal{L}_{\text{WCE}} + \lambda_r \mathcal{L}_{\text{SmoothL1}}, \quad \lambda_r = 1.0. \quad (20)$$

MMP 共含 163460 个参数，直接使用附件 2 的原始数值特征，不额外标准化。采用 AdamW，学习率 10^{-3} 、权重衰减 10^{-4} 、批量大小 128、随机失活率 0.1；最多训练 80 轮，提前停止耐心轮数为 12 轮。基线在完整输入上训练。

4.4 轻量时间注意力残差池化模型

当局部连续缺失移除一段信息后，剩余有效位置所包含的情感信息并不均等。**MMP** 仍采用等权聚合，难以突出更有判别力的位置。为使聚合权重能够随当前样本内容变化，**LTARP** 在均值分支之外增加逐槽位内容打分，并将加权表示作为残差补充。每个模态使用一个线性标量打分器，其打分记为

$$e_{it}^{(m)} = f_m(\mathbf{x}_{it}^{(m)}) = \mathbf{w}_m^\top \mathbf{x}_{it}^{(m)} + b_m. \quad (21)$$

权重在原始有效槽位内归一化，并形成内容加权表示：

$$\alpha_{it}^{(m)} = \frac{p_{it} \exp(e_{it}^{(m)})}{\sum_{s:p_{is}=1} \exp(e_{is}^{(m)})}, \quad \mathbf{a}_i^{(m)} = \sum_{t=1}^{50} \alpha_{it}^{(m)} \mathbf{x}_{it}^{(m)}. \quad (22)$$

填充位的 $\alpha_{it}^{(m)}$ 恒为 0。人工遮挡后的零值仍按原有效指示参与打分与聚合，权重变化由当前输入内容决定。

内容加权表示作为均值表示的补充，两路共享模态映射 P_m ，以可学习系数 γ_m 进行残差组合：

$$\mathbf{h}_i^{(m)} = P_m(\boldsymbol{\mu}_i^{(m)}) + \gamma_m \cdot P_m(\mathbf{a}_i^{(m)}), \quad m \in \{T, A, V\}. \quad (23)$$

该表示继续进入原有融合层与双任务输出，新增分支只改变模态内的聚合方式。共享映射使两路表示具有相同维度，均值路径保留整体信息，内容加权路径提供随样本变化的补充；残差系数控制补充分支进入预测的程度。

训练首先完成 MMP 的模态映射、融合与双任务输出学习，再以其参数初始化 LTARP。第二阶段保持这些已有参数不变，仅学习三个模态打分器及三个残差系数。令 γ_m 初值为 0，初始模态输出为

$$\mathbf{h}_i^{(m)} = P_m(\boldsymbol{\mu}_i^{(m)}), \quad (24)$$

与 MMP 保持一致。随后，内容加权分支通过残差系数逐步参与预测。新增可训练参数为 883 个，总参数量增至 164343，从而以较小的参数增量补充时间位置的内容差异。

4.5 连续缺失场景与评价协议

为系统比较不同连续缺失形式对预测的影响，并在相同受损条件下观察 MMP 与 LTARP 的表现，本文从缺失模态、缺失比例和缺失位置三个维度构造固定场景。单模态场景沿比例变化考察各输入的敏感程度，双模态场景在同一比例下考察信息同时受损的影响；前段、中段和后段遮挡则用于区分缺失发生位置。三个维度组合形成 54 种场景，使模型比较与缺失规律分析共享同一组受损输入。

- 单模态场景集 $\mathcal{C}_1$: $m \in \{T, A, V\}$ ，目标缺失比例 $\rho_{\text{target}} \in \mathcal{R} = \{0.1, 0.2, 0.3, 0.4, 0.5\}$ ，位置 $\mathcal{P} = \{\text{前段}, \text{中段}, \text{后段}\}$ ，共 $3 \times 5 \times 3 = 45$ 种。
- 双模态场景集 $\mathcal{C}_2$: 模态对为 $\{T, A\}$ 、 $\{T, V\}$ 、 $\{A, V\}$ ，固定 $\rho_{\text{target}} = 0.3$ ，分别取三个位置，共 $3 \times 1 \times 3 = 9$ 种。

对有效长度 L_i ，遮挡槽位数与实际比例为

$$\ell_i = \max(1, \text{round}(\rho_{\text{target}} \cdot L_i)), \quad \rho_{\text{actual}, i} = \frac{\ell_i}{L_i}. \quad (25)$$

槽位数必须取整数，短序列的实际比例会偏离目标比例；验证集中，目标比例 0.1 的实际范围为 0.0714–0.3333，目标比例 0.5 为 0.4000–0.6667，对应均值为 0.1040 和 0.5009。图表横轴用目标比例标识场景，实际比例逐样本记录。

前段、中段、后段的起点 s_i 分别为 0、 $\lfloor (L_i - \ell_i)/2 \rfloor$ 和 $L_i - \ell_i$ 。遮挡将指定模态在 $[s_i, s_i + \ell_i - 1]$ 内的特征置零，该遮挡区间采用零起始槽位索引；其余模态和填充掩码保持原样。每个场景都在完整的 728 条验证样本上评价，各样本按自身有效长度计算区间。

分类评价同时采用准确率与宏平均 F1，分别观察总体识别与类别均衡表现；回归采用 MAE 和皮尔逊相关系数，分别观察绝对误差与变化趋势。四项指标定义为：

- 准确率 (Accuracy, $\uparrow$): $\text{Acc} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\hat{c}_i = c_i)$;
- 宏平均 F1 (Macro-F1, $\uparrow$): $\text{MacroF1} = \frac{1}{3} \sum_{k=0}^2 \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k}$;
- 平均绝对误差 (MAE, $\downarrow$): $\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i|$;
- 皮尔逊相关系数 (Pearson, r , $\uparrow$): $\text{Pearson} = \frac{\sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})^2} \sqrt{\sum_{i=1}^N (y_i - \bar{y})^2}}$ 。

分类与回归分别反映极性识别和连续情感强度预测，单项指标不能同时概括两项任务。为在参数选择时兼顾二者，本文将四项评价指标组合为得分 S ：

$$S = \frac{1}{4} \text{Acc} + \frac{1}{4} \text{MacroF1} + \frac{1}{4} \left(1 - \frac{\text{MAE}}{6} \right) + \frac{1}{8} (\text{Pearson} + 1). \quad (26)$$

连续情感强度标签位于 $[-3, 3]$ ，跨度为 6，因此以 $\text{MAE}/6$ 缩放误差量级，并通过 $1 - \text{MAE}/6$ 统一为越大越好的方向。 Pearson 的取值范围为 $[-1, 1]$ ， $(\text{Pearson} + 1)/2$ 将其映射至 $[0, 1]$ ，故式 (26) 中的最后一项等价于给该映射值赋予 1/4 权重。两项分类指标合计占 1/2，两项回归指标合计占 1/2，兼顾极性识别与连续情感强度预测。回归输出不作截断，6 作为标签尺度使用，而非预测误差的上界。

完整输入得分只能描述正常观测下的表现，连续缺失后的保持程度还需结合受损场景评价。本文将完整输入对应的得分记为 S_{clean} ，并以其与 54 种缺失场景的平均得分共同定义综合鲁棒得分 R ：

$$R = \frac{1}{2} \left(S_{\text{clean}} + \frac{1}{54} \sum_{j=1}^{54} S_j \right). \quad (27)$$

完整输入得分占 1/2，54 种缺失场景的等权平均占 1/2。这一组合同时考虑正常输入与受损输入下的表现，使配置选择兼顾完整输入能力和缺失后的保持程度。

结构比较表 8 以及公开方法表 11、12，均按完整输入验证得分 S_{clean} 选择参数；选定后同时评价完整输入与全部 54 种缺失场景，保证两张公开方法结果表使用同一套参数。缺失敏感性与鲁棒诊断图 10–13 则沿用按 R 选定的 LTARP 配置，MMP 仍使用对应初始化的完整输入最优基线。前者比较统一完整输入标准下的结构表现，后者分析最终配置在固定缺失场景集合中的响应与波动；在每类实验内，每次初始化均固定一套参数，不按缺失模态、比例或位置重新选择。

场景统计先在种子内汇总，再计算种子间均值与样本标准差。设第 s 个种子在场景 j 的指标为 $M_{s,j}$ ，其缺失场景均值为

$$\bar{M}_s = \frac{1}{54} \sum_{j=1}^{54} M_{s,j}, \quad s \in \{42, 43, 44\}. \quad (28)$$

三次初始化是统计重复单位，54 个场景在各自初始化内等权平均。这样，场景平均表示模型在固定受损条件集合中的总体表现，种子间标准差则描述同一训练设置的初始化波动。算法 1 概括执行步骤。

算法 1 连续缺失场景评价

输入：验证集三模态特征、有效掩码与已选模型。

输出：完整输入及 54 场景指标、 S_{clean} 与 R 。

1. 预测完整输入，计算四项指标及 S_{clean} 。
 2. 遍历场景配置 ($\mathcal{M}_{\text{target}}, \rho_{\text{target}}, \text{pos}$)。
 3. 对各样本读取 L_i ，按式 (25) 计算 ℓ_i 并确定 s_i 。
 4. 在原输入副本中置零目标模态的连续区间，保持有效掩码。
 5. 预测当前场景，记录四项指标与 S_j 。
 6. 汇总 54 场景结果，按式 (27) 计算 R 。
-

4.6 基线与 LTARP 的结构比较

首先在统一完整输入选模标准下直接比较 MMP 与 LTARP，以观察聚合结构改变后的分类与回归表现。LTARP 在宏平均 F1、MAE 和 Pearson 的三种子均值上均优于 MMP，准确率变化较小。对相同模型参数施加 54 种缺失后，三项指标的平均改善仍保留，准确率则略有下降（表 8）。MAE 与 Pearson 的改善分别对应连续情感强度绝对误差的减少和预测趋势的一致性提高。

验证集中积极样本最多，准确率按样本汇总，受多数类别识别情况的影响较大；宏平均 F1 对三类等权，能够反映整体准确率之外的类别差异。当前改善更多体现在宏平均 F1，说明评价两种池化结构时需要同时观察总体识别和类别均衡表现。中性类的混淆仍然明显，其具体错误分布在后续分析中结合混淆矩阵观察。

表 8 统一完整输入选模规则下的 MMP 与 LTARP 比较（三随机种子均值 $\pm$ 样本标准差）

条件	模型	准确率 $\uparrow$	宏平均 F1 $\uparrow$	MAE $\downarrow$	相关系数 $\uparrow$
完整输入	MMP	0.6401 ± 0.0048	0.6139 ± 0.0091	0.6079 ± 0.0103	0.6409 ± 0.0043
完整输入	LTARP	0.6415 ± 0.0050	0.6243 ± 0.0026	0.6052 ± 0.0063	0.6475 ± 0.0024
54 场景平均	MMP	0.6349 ± 0.0062	0.6092 ± 0.0075	0.6111 ± 0.0098	0.6359 ± 0.0038
54 场景平均	LTARP	0.6334 ± 0.0038	0.6163 ± 0.0013	0.6086 ± 0.0059	0.6417 ± 0.0024

为观察随机初始化对跨场景表现的影响，进一步比较三个随机种子的综合得分。种子 42 和 43 呈正增益，种子 44 近乎持平；配对差 $\Delta R = R_{\text{LTARP}} - R_{\text{MMP}}$ 分别为 +0.005600、+0.003791 和 -0.000090，平均为 $+0.003100 \pm 0.002907$ 。总体收益较小，同时存在初始化敏感性。

4.7 缺失类型、位置与比例分析

表 8 给出了完整输入与 54 种缺失场景的总体平均，但平均值不能呈现不同缺失模态、比例和位置的差异。为进一步辨别这些差异，以下分解考察最终鲁棒配置的缺失响应。图 10 中，文本随遮挡比例增大退化最明显，语音和视觉变化较平缓；分类与回归对输入损失的响应程度也不同。文本遮挡由 0.1 增至 0.5 时，宏平均 F1 从 0.6163 降至 0.5933，显示语言内容在这组样本中的较强作用。




图 10 单模态缺失比例与验证集性能。阴影为三随机种子的样本标准差，虚线为完整输入均值。

固定目标缺失比例 $\rho_{\text{target}} = 0.3$ 后，缺失位置仍会改变模型表现。文本前段与后段遮挡对宏平均 F1 的影响大于中段；包含文本的双模态缺失也呈相近规律，语音、视觉及语音-视觉组合的影响较小。分类与回归的位置响应并不完全一致，例如文本中段遮挡降低宏平均 F1，却使 MAE 略有下降（图 11）。




图 11 不同模态与位置相对完整输入的性能变化。各指标使用独立色标。

在比例与位置规律之外，图 12 进一步比较最终鲁棒配置与 MMP 基线在相同受损场景下的响应差异。此处 LTARP 采用按 R 选定的配置，分析目的在于观察最终配置的场景收益；统一完整输入选模标准下的直接结构比较仍以表 8 为准。宏平均 F1 和 Pearson 的改善更为一致，在语音、视觉及语音-视觉缺失条件下较明显；准确率随位置与模态组合出现正负波动。内容加权补充有助于保持部分剩余信息，其效果仍随受损输入而变化。包含文本的受损场景影响较大，而仅语音或视觉受损时仍有文本输入；图 12 描述两种固定配置在不同受损输入下的指标差异，图 11 则描述缺失输入相对完整输入的性能变化，两者分别用于观察配置响应和信息损失规律。




图 12 最终鲁棒配置与 MMP 基线在不同缺失场景下的指标差异。MAE 取 MMP 减 LTARP，其余指标取 LTARP 减 MMP；正值表示 LTARP 对应指标更优。

4.8 稳定性、错误分布与消融分析

4.8.1 随机初始化稳定性与验证集错误分布

前述分析给出了不同缺失场景的平均响应，下面进一步从随机初始化、类别混淆和特殊输入三个方面观察这些结果的保持程度。三次初始化的配对收益较小，结合完整输入分类错误与原生视觉全零样本，可以识别总体平均之外的差异（图 13）。




图 13 随机初始化稳定性与误差分析。(a) 配对综合分数; (b) 混淆矩阵; (c) 场景分组; (d) 原生视觉全零子集。

三次初始化中有两次提高, 一次近乎持平, 场景分组后的平均差也较小。完整输入下, 消极与积极类的召回相对较高, 中性类最低, 为 43.48%; 中性样本更容易被分到两侧极性类别, 弱极性与类别边界仍是主要混淆位置。

验证集另有 15 条原生视觉特征整段全零样本。该子集中, 部分初始化的 LTARP 分类表现低于 MMP, 呈现与总体平均趋势不同的结果; 样本量较少, 其表现结合三次初始化单独观察。

4.8.2 候选结构与训练策略消融

在考察最终配置的稳定性与错误分布后, 进一步比较不同结构和训练调整能否带来类似收益。本文保留时间编码、训练期连续遮挡和均值-最大值残差池化三种候选, 与 MMP 及 LTARP 并列 (表 9)。

表 9 候选结构与训练策略消融。均值-最大值残差池化仅有一次初始化。

方案	初始化次数	总参数量	综合分数 R
MMP (基线)	3	163460	0.7417 ± 0.0015
单模态时间编码	3	957572	0.7351 ± 0.0020
训练期连续遮挡	3	163460	0.7385 ± 0.0025
均值-最大值残差池化	1	163463	0.7443
LTARP (本文方案)	3	164343	0.7448 ± 0.0015

单模态时间编码在聚合前加入顺序建模, 参数量明显增加, 综合得分却低于 MMP。训

练期连续遮挡保持网络不变：每条样本以 0.5 概率保留完整输入，其余样本中 75% 遮挡一个模态、25% 遮挡两个模态，比例从 {0.1, 0.2, 0.3, 0.4, 0.5} 选择，起点在有效范围内随机确定，掩码保持原值。这种缺失增强也未带来综合得分改善。

均值-最大值残差池化沿用式 (14) 的掩码均值表示，并增加有效槽位上的逐特征维最大值，再经残差组合接入原有网络。其得分接近 LTARP，但仅保留一次初始化结果，主要作为结构探索参考，不与三随机种子结果作精细统计比较。LTARP 的三种子综合均值在本组最高，同时只增加 883 个参数，在本组候选中提供了较好的综合表现。

4.9 公开方法适配与对比

完成 MMP 与 LTARP 的内部比较及候选结构分析后，为考察 LTARP 与其他多模态建模路线的相对表现，本文进一步选取 11 种公开方法进行统一适配比较。各方法使用附件 2 的 aligned-50 输入与分类、回归双任务接口，三模态维度、数据划分、指标和完整输入选模标准保持一致，并按既有适配配置训练。表 10 概括适配中的机制与规模。

表 10 公开方法的统一接口适配概览

方法	类型	本文适配中的核心机制	参数量
TFN[6]	张量融合	三路表示增广后的外积融合	4,840,670
LMF[7]	低秩融合	模态专属低秩因子融合	323,276
MFN[8]	时序记忆融合	三路递归编码、记忆注意力与门控记忆	261,764
MuT[9]	跨模态注意力	六路定向跨模态注意力与模态内记忆	624,094
MISA[10]	表征解耦	共享/特有表示、重构与差异约束	1,118,852
Self-MM[11]	多任务辅助学习	融合预测与单模态伪目标辅助监督	82,119
MMIM[12]	互信息约束	模态间及融合-单模态的 InfoNCE 约束	163,204
TFR-Net[13]	缺失重构	连续遮挡、时序上下文与潜在表示重构	415,620
MissModal[14]	缺失表征对齐	几何对比、分布与情感语义对齐	163,204
M3S[15]	缺失元采样	低秩骨干、完整支持/缺失查询的一步一阶元更新	323,276
MMIN[16]	缺失模态推断	潜在表示推断、残差细化与循环约束	292,164

这些方法分别通过张量交互、时序记忆、表征约束或辅助任务组织多模态信息，缺失增强方法还引入重构、表征对齐、元采样及潜在表示推断。比较同时考察完整输入预测能力、连续缺失后的表现和参数规模：前两项反映同一配置在不同输入条件下的结果，参数量补充表示模型复杂度。各方法接入统一特征与双任务接口，以下结果均限定在本文统一适配与评价设置下。

在本文统一适配与评价设置下，LTARP 在完整输入的四项指标上均取得表 11 中最优的三随机种子均值。部分轻量方法及缺失增强方法的表现接近 LTARP，而更复杂的融合结构未呈现同等的平均优势。Self-MM 和 MMIM 借助辅助任务或信息约束，在较小规模下也保留了较强预测信息；TFR-Net 的宏平均 F1 接近 LTARP，但回归指标有所差异。因此，分类均衡性和回归结果需要结合观察。

表 11 公开方法与 LTARP 的完整输入验证集结果（三随机种子均值 $\pm$ 样本标准差）

模型	训练方式	参数量	准确率 $\uparrow$	宏平均 F1 $\uparrow$	MAE $\downarrow$	相关系数 $\uparrow$
TFN	完整输入训练	4,840,670	0.6099 ± 0.0076	0.5872 ± 0.0083	0.6336 ± 0.0102	0.6056 ± 0.0098
LMF	完整输入训练	323,276	0.5925 ± 0.0114	0.5719 ± 0.0090	0.6682 ± 0.0196	0.5807 ± 0.0188
MFN	完整输入训练	261,764	0.5966 ± 0.0080	0.5824 ± 0.0062	0.6418 ± 0.0124	0.5908 ± 0.0125
MulT	完整输入训练	624,094	0.6172 ± 0.0148	0.5891 ± 0.0236	0.6221 ± 0.0260	0.6369 ± 0.0115
MISA	完整输入训练	1,118,852	0.6131 ± 0.0083	0.6010 ± 0.0060	0.9175 ± 0.1005	0.6269 ± 0.0087
Self-MM	完整输入训练	82,119	0.6355 ± 0.0052	0.6107 ± 0.0084	0.6099 ± 0.0066	0.6423 ± 0.0042
MMIM	完整输入训练	163,204	0.6360 ± 0.0048	0.6110 ± 0.0007	0.6102 ± 0.0098	0.6375 ± 0.0054
TFR-Net	缺失增强训练	415,620	0.6374 ± 0.0071	0.6230 ± 0.0080	0.6145 ± 0.0118	0.6267 ± 0.0142
MissModal	缺失增强训练	163,204	0.6305 ± 0.0071	0.6108 ± 0.0069	0.6084 ± 0.0113	0.6431 ± 0.0006
M3S	缺失增强训练	323,276	0.6035 ± 0.0063	0.5775 ± 0.0169	0.6706 ± 0.0173	0.5793 ± 0.0171
MMIN	缺失增强训练	292,164	0.6383 ± 0.0062	0.6117 ± 0.0079	0.6279 ± 0.0247	0.6401 ± 0.0027
LTARP	完整输入训练	164,343	0.6415 ± 0.0050	0.6243 ± 0.0026	0.6052 ± 0.0063	0.6475 ± 0.0024

在本文统一适配与评价设置下，54 种连续缺失等权平均后，LTARP 的宏平均 F1 和 Pearson 在表 12 中最高，MAE 最低，准确率与 TFR-Net、MMIN 接近。完整输入表现与缺失后保持程度共同决定跨场景结果；缺失增强方法之间也存在差异。

表 12 公开方法与 LTARP 的 54 种连续缺失场景平均结果（三随机种子均值 $\pm$ 样本标准差）

模型	训练方式	参数量	准确率 $\uparrow$	宏平均 F1 $\uparrow$	MAE $\downarrow$	相关系数 $\uparrow$
TFN	完整输入 训练	4,840,670	0.5767 ± 0.0197	0.5582 ± 0.0127	0.6451 ± 0.0101	0.5784 ± 0.0070
LMF	完整输入 训练	323,276	0.5616 ± 0.0054	0.5392 ± 0.0066	0.6630 ± 0.0123	0.5539 ± 0.0185
MFN	完整输入 训练	261,764	0.5657 ± 0.0070	0.5532 ± 0.0081	0.6559 ± 0.0097	0.5540 ± 0.0092
MuT	完整输入 训练	624,094	0.6000 ± 0.0209	0.5749 ± 0.0230	0.6309 ± 0.0189	0.6232 ± 0.0057
MISA	完整输入 训练	1,118,852	0.6079 ± 0.0095	0.5958 ± 0.0080	0.9247 ± 0.1025	0.6198 ± 0.0077
Self-MM	完整输入 训练	82,119	0.6302 ± 0.0016	0.6053 ± 0.0042	0.6131 ± 0.0068	0.6371 ± 0.0040
MMIM	完整输入 训练	163,204	0.6302 ± 0.0041	0.6059 ± 0.0004	0.6135 ± 0.0101	0.6332 ± 0.0051
TFR-Net	缺失增强 训练	415,620	0.6336 ± 0.0099	0.6154 ± 0.0098	0.6232 ± 0.0146	0.6220 ± 0.0143
MissModal	缺失增强 训练	163,204	0.6260 ± 0.0096	0.6068 ± 0.0048	0.6111 ± 0.0112	0.6381 ± 0.0013
M3S	缺失增强 训练	323,276	0.5733 ± 0.0056	0.5493 ± 0.0102	0.6620 ± 0.0071	0.5581 ± 0.0192
MMIN	缺失增强 训练	292,164	0.6341 ± 0.0049	0.6072 ± 0.0039	0.6318 ± 0.0259	0.6346 ± 0.0037
LTARP	完整输入 训练	164,343	0.6334 ± 0.0038	0.6163 ± 0.0013	0.6086 ± 0.0059	0.6417 ± 0.0024

在上述性能结果基础上，再结合参数量比较各方法的模型规模。LTARP 总参数量为 164343，约 16.4 万，明显小于 TFN、MuT 和 MISA 等结构，与 MMIM 和 MissModal 处于相近量级。在表 11–12 所列模型中，其完整输入和缺失平均宏平均 F1 均保持较高水平。图 14 分别对照这两类输入条件；不同方法的参数规模跨越一个数量级以上，横轴采用对数尺度，使轻量结构和较大融合网络能够在同一坐标中比较。这组结果体现了 LTARP 在当前接口下的性能与规模平衡，结构复杂度本身不足以决定预测表现。




图 14 公开多模态模型的参数规模与宏平均 F1 比较。(a) 完整输入验证集；(b) 54 种连续缺失场景平均。横轴为总参数量（对数尺度），误差线为三随机种子的样本标准差。

4.10 附件 3 预测

4.10.1 文本特征重构与核验

完成上述验证与模型选择后，将 LTARP 用于附件 3 的 30 条无标签样本。对齐版提供 `text_bert` 词元输入，以及 `audio` 和 `vision` 数值特征。单样本的 `text_bert` 形状为 3×50 ，三行依次为词元编号、有效位掩码和词元类型编号，并非模型所需的 50×768 连续文本表示。因此，使用已验证的 `bert-base-uncased` 接口编码有效词元前缀，取最后隐层逐词元表示，再在填充后缀补零至 50×768 ；语音、视觉特征及有效位掩码保持原样。

已有接口检查使用附件 4 中 20 条同时包含 `text_bert` 和预计算 `text` 的无标签样本，逐行比较全部 604 个有效槽位；604/604 个重构行的最大余弦相似度位置均为同索引，特征最大绝对差为 3.0041×10^{-5} 、RMSE 为 8.3977×10^{-7} 。输入同一固定参数模型后，分类 logits 最大绝对差为 2.44×10^{-6} ，回归为 1.12×10^{-6} 。该数值检查支持词元编码与既有文本特征接口的衔接，附件 3 随后沿此固定路径完成推理。

4.10.2 预测结果汇总

30 条样本预测为消极、中性和积极的数量分别为 7、11 和 12，对应 23.33%、36.67% 和 40.00%。连续情感强度均值为 +0.123114、样本标准差为 0.611792，范围为 $[-1.642545, +1.539758]$ ；平均分类置信度为 0.624599。类别与连续情感强度由两个输出头独立预测，推理阶段不使用回归值符号对分类结果进行二次修正。逐样本类别、连续情感强度和置信度见表 13，与独立 CSV 保存的同批结果对应。附件 3 不提供真实标签，因此本节仅报告预测结果，不计算 Accuracy、Macro-F1、MAE 等监督评价指标。

表 13 附件 3 全部 30 条无标签样本的最终预测

样本 ID	预测类别	连续情感强度	分类置信度
附件 3_01	消极	-0.405876	0.7460
附件 3_02	中性	-0.144469	0.6501
附件 3_03	中性	-0.128127	0.6101
附件 3_04	积极	+0.514640	0.6097
附件 3_05	消极	-1.642545	0.9405
附件 3_06	积极	+0.765383	0.7435
附件 3_07	中性	+0.249776	0.4401
附件 3_08	消极	-0.337494	0.5324
附件 3_09	积极	+1.076601	0.8747
附件 3_10	中性	-0.178815	0.7725
附件 3_11	中性	+0.010376	0.5348
附件 3_12	积极	+0.922382	0.6466
附件 3_13	积极	+0.237651	0.4991
附件 3_14	消极	-0.550781	0.7443
附件 3_15	积极	+0.684222	0.7227
附件 3_16	积极	+1.539758	0.9228
附件 3_17	消极	-0.589950	0.4977
附件 3_18	积极	+0.246677	0.4397
附件 3_19	消极	-0.320886	0.4778
附件 3_20	中性	-0.246796	0.6422
附件 3_21	积极	+0.667961	0.7211
附件 3_22	中性	+0.186271	0.4059
附件 3_23	中性	+0.138655	0.6286
附件 3_24	消极	-0.458430	0.5284
附件 3_25	中性	+0.048311	0.5231
附件 3_26	积极	+0.574989	0.7292
附件 3_27	积极	+0.567220	0.6708
附件 3_28	积极	+0.397136	0.4846
附件 3_29	中性	+0.071600	0.4322
附件 3_30	中性	-0.202034	0.5667

4.11 本问小结

本问以附件 2 已对齐的三模态特征为起点，建立 MMP 双任务基线，并通过 LTARP 内容加权残差分支补充时间位置的信息差异。在共用融合与输出路径的基础上，第二阶段仅新增 883 个参数，形成完整输入和连续缺失输入下可直接评价的预测模型。

围绕 54 种连续缺失场景的比较表明，文本局部缺失的影响最明显，分类与回归对位置的响应有所不同。LTARP 在宏平均 F1、MAE 和 Pearson 上总体优于 MMP，但提升幅度较小，不同随机初始化下仍存在一定波动。与公开方法的统一适配比较进一步体现了其性能与参数规模的折中。在此基础上，本问完成附件 3 全部 30 条无标签样本的预测，并为问题三的解释分析固定预测模型。

5 问题三：多模态情感预测的可解释分析与证据定位

5.1 问题分析与总体方案

问题二已经完成三模态情感类别与连续强度预测。针对问题三，本问不再调整预测模型，而是固定问题二得到的模型参数，进一步分析不同模态和局部输入对当前预测结果的

作用。解释对象是同一条样本在不同输入条件下的输出变化。

由于最终预测由文本、语音和视觉共同产生，仅有类别和连续强度还无法区分各模态的具体作用。本问需要回答：三种模态分别贡献多少，两种模态共同输入时是否产生额外作用，以及影响当前预测的信息位于哪些特征位置。因此，分析依次从模态贡献转向模态交互，再定位局部特征区间。

整体求解路线见图 15。输入为 50×768 的文本特征、 50×74 的语音特征和 50×35 的视觉特征，先枚举 8 种模态组合计算 **Shapley** 贡献，再利用相同组合输出分析模态交互；随后对分类主导模态进行连续窗口遮挡，定位影响当前类别的特征区间。所选区间进一步通过随机等长窗口对照和删除实验检验，并结合跨种子比较观察结果稳定性，最后沿来源记录回查原文片段或未对齐特征行。预测与解释始终使用问题二的双任务模型，分类和回归分别采用各自的解释目标，使两种输出的作用方向都有明确含义。




图 15 固定预测模型的解释分析流程。输入为文本、语音和视觉特征，输出为预测类别、连续强度、模态贡献与关键特征区间。

5.2 模态贡献分析

5.2.1 精确 Shapley 贡献

只比较完整输入与去掉某一模态后的输出，得到的是该模态在另外两种模态都存在时的作用。一个模态的边际变化还可能取决于其他输入是否参与：单独有效的信息在联合输入中可能被替代，也可能在另一模态提供的条件下发挥更大作用。因此，需要把不同组合中的变化一起考虑。

Shapley 贡献将一个模态加入不同组合时的边际变化加权平均。令 $\mathcal{M} = \{T, A, V\}$ 分别表示文本、语音和视觉， $S \subseteq \mathcal{M}$ 为保留的模态集合， $v(S)$ 为相应组合的解释目标。三种模态只有 $2^3 = 8$ 种组合，即空组合、三个单模态组合、三个双模态组合及完整组合，可以直接完整枚举，无需 Monte Carlo 采样近似。对模态 m ，其贡献为

$$\phi_m = \sum_{S \subseteq \mathcal{M} \setminus \{m\}} \frac{|S|!(2 - |S|)!}{3!} [v(S \cup \{m\}) - v(S)]. \quad (29)$$

式中权重对应模态在不同加入顺序下遇到集合 S 的比例。三模态情况下，加入空组合或另外两模态均在场时的权重各为 $1/3$ ，加入单模态组合时各为 $1/6$ 。每个模态按相同规则计算，使单独作用与联合输入下的增量都参与贡献分配。

计算时，未保留模态只在有效位置清零，填充位置与原生零记录保持原样。空组合对应全部有效模态清零后的模型输出，作为本问的共同基准。精确计算满足 $\sum_m \phi_m = v(\mathcal{M}) - v(\emptyset)$ ，用于检查贡献分配是否完整；该关系针对模型输出差，空组合的预测值本身由固定模型决定。

5.2.2 解释目标与主导模态

确定模态贡献的计算方式后，还需要为各模态组合规定一致的比较目标。由于分类与回归的输出形式不同，本文分别定义两类解释目标。分类解释固定完整输入预测的类别 c^* ，所有模态组合均衡量对这一类别的支持程度。若只记录遮挡后类别是否翻转，许多尚未越过分类边界的变化会被忽略；采用分类对数优势 (log-odds)，则能保留当前类别相对于其

他类别的连续变化。记 $z_k(S)$ 为组合 S 下类别 k 的 **logit**，回归直接使用连续强度预测 $\hat{y}^r(S)$ ，两种目标定义为

$$v_c(S) = z_{c^*}(S) - \log \sum_{k \neq c^*} \exp z_k(S), \quad v_r(S) = \hat{y}^r(S). \quad (30)$$

其中，分类目标等于 $\log[p_{c^*}(S)/(1 - p_{c^*}(S))]$ 。即使某个组合使模型改判其他类别， c^* 也保持不变，前后差值仍指向同一个解释对象。回归目标保留模型输出的原始尺度，因此分类和回归分别计算贡献并确定主导模态。

分类正贡献表示该模态支持当前类别，负贡献表示其反向作用；回归正、负贡献分别对应连续强度向正、负方向的变化。贡献的绝对值表示变化幅度，符号保留方向。例如，某模态可以增强中性判断，同时使连续强度降低，两个结果分别依据各自目标解读。

分类主导模态优先取最大正 **Shapley** 贡献；若三种贡献均非正，则取绝对贡献最大者，并标明其非支持性质。回归主导模态取绝对贡献最大者。两类选择遇到并列时，均按文本、语音、视觉的固定顺序处理。后续连续窗口遮挡以分类主导模态为分析对象，回归输出用于观察同一区间对强度的影响。

主导模态确定局部分析对象，三路贡献仍共同保留。非主导模态可能提供较小的同向支持，也可能产生较大的反向作用；只报告最大值会掩盖这种差异。逐样本表因此列出完整的三模态贡献，便于结合大小和方向阅读当前预测。

5.3 模态交互分析

Shapley 贡献将完整输入相对空输入的预测变化分配给各模态，其中已经包含联合输入的影响。模态交互另行回答：两种模态共同输入后，相对于各自作用的简单相加，多出了什么变化。贡献较大的模态与其他模态仍可能呈现正或负交互，二者描述的方面不同。

本文考察文本–语音、文本–视觉和语音–视觉三对关系。对模态 i, j 及剩余模态 k ，分别计算第三模态缺席和在场时的二阶差，再取平均：

$$I_{ij} = \frac{1}{2} \{v(\{i, j\}) - v(\{i\}) - v(\{j\}) + v(\emptyset) + v(\mathcal{M}) - v(\{i, k\}) - v(\{j, k\}) + v(\{k\})\}. \quad (31)$$

正交互表示联合输入产生的输出变化高于相应加性基准，负交互表示低于这一基准。符号针对式 (30) 的解释目标，具体原因需结合样本输入判断；分类和回归分别计算。

附件 2 验证集 728 条样本的交互统计见表 14。平均交互概括作用的平均大小，主要符号比例为该方向在样本中出现的频率。文本–视觉在两个目标下平均为正，其中分类均值为 +0.0781；语音–视觉的平均方向则由分类负向转为回归正向。可见，共同输入对类别支持与连续强度的影响并不完全一致。

表 14 附件 2 验证集分类与回归解释目标的二阶模态交互 ($n = 728$)

解释目标	模态对	平均交互	主要符号比例	主要符号
分类	文本–语音	−0.0706	69.4%	负
	文本–视觉	+0.0781	60.3%	正
	语音–视觉	−0.0372	64.4%	负
回归	文本–语音	−0.1592	85.7%	负
	文本–视觉	+0.0503	65.4%	正
	语音–视觉	+0.0592	84.1%	正

总体方向也不能代替单样本结果。文本–视觉的分类交互有 60.3% 为正，仍有相当一部分样本呈现其他方向。群体统计用于概括这批输入的共同特点，逐条解释则保留样本自

身的交互量，与其模态贡献和局部位置一起阅读。

5.4 连续窗口遮挡与关键区间定位

模态贡献比较整路输入的作用，尚未指出重要信息位于序列何处。本文在分类主导模态内部遮挡连续特征区间，保持其他模态及窗口外输入不变，通过输出变化定位局部影响。连续窗口覆盖相邻特征，可以观察一段输入共同被去除后的响应，避免把片段作用仅归于单个槽位。

对样本 i ，有效长度为 L_i ，窗口宽度为 $w_i = \max(1, \text{round}(0.30L_i))$ ，滑动步长为 1。窗口只在有效序列内生成，依次覆盖从起点到末端的所有可用连续区间。有效掩码保持不变，清零操作表示去除当前窗口的观测内容；原生零记录沿用输入原值，填充位置不进入候选窗口。记 $g(\mathbf{x})$ 为固定类别的分类对数优势，窗口 W 的遮挡效应为

$$D_i(W) = g(\mathbf{x}_i) - g(\mathbf{x}_i^{\setminus W}), \quad (32)$$

其中 $\mathbf{x}_i^{\setminus W}$ 仅将分类主导模态在窗口内的有效特征清零。 $D_i(W) > 0$ 表示删除后当前类别支持下降，窗口原本支持该预测； $D_i(W) < 0$ 表示删除后支持上升，窗口原本对当前类别起反向作用。

若存在正效应窗口，选择 $D_i(W)$ 最大的窗口；若所有窗口均无正效应，则选择绝对效应最大的窗口并标注方向。平局时取最早位置。结果使用从零开始的对齐索引 $[a, b)$ 表示，包含 a 至 $b-1$ 位置。对每个有效槽位，将覆盖该位置的窗口效应最大值记为局部曲线；这条曲线描述连续遮挡下的响应，窗口之间可以重叠。

窗口比例通过附件 2 验证集的设计子集确定。既有实验比较 $\{0.10, 0.20, 0.30\}$ ，按所选窗口相对随机等长窗口的平均分类对数优势下降差选择比例；三者依次为 0.268837、0.366684 和 0.440487，因此选定 0.30。随后固定该比例，在独立验证子集报告结果，并用于附件 4。该选择依据对应局部分类影响，实际区间宽度仍随每条样本的有效长度变化。

区间索引首先定位的是模型接收的特征，具体输入来源在第 5.6 节回溯。对同一所选窗口，回归同时记录完整输出减遮挡输出的有符号变化及其绝对值，分别描述强度移动方向和幅度。

三模态 Shapley 只需 8 种组合，三对交互复用这些输出。连续窗口的候选数为 $L_i - w_i + 1$ ，随有效长度线性增加。在最长 50 位的序列上，单样本的贡献计算与局部定位均可直接遍历；模型参数、有效掩码、解释目标及窗口规则固定后，同一输入的结果可按上述步骤复算。

5.5 关键区间的干预验证与稳定性分析

前述模态贡献和连续窗口遮挡给出了对当前预测起主要作用的模态及关键特征区间，但这些位置是否对应更明显的模型响应，还需要通过独立验证子集上的干预对照进行检验。

5.5.1 实验设计

为此，本文固定问题二的 seed 42 模型。其在附件 2 验证集上的基础性能见表 15，其中中性类别 F1 和召回率低于另两类，是主要分类误差来源之一。基础性能提供预测质量背景，下述实验评价所选位置与该模型输出之间的对应关系。

表 15 Q3 固定预测模型在附件 2 验证集上的基础性能 (seed 42, $n = 728$)

Accuracy	Macro-F1	MAE	Pearson
0.648352	0.623435	0.608260	0.646170
消极 F1	中性 F1	积极 F1	中性召回率
0.689655	0.467836	0.712813	0.434783

附件 2 验证集共 728 条片段，按 video ID 分为设计子集和独立验证子集。前者含 332 条片段、113 个视频，后者含 396 条片段、126 个视频，两组 video ID 无重叠。同一视频的片段可能共享说话人和场景，按视频分组可以避免这些共同条件跨越两组。设计子集用于确定窗口比例，独立验证子集用于报告最终干预结果；这里的独立性针对窗口比例选择与解释验证。

对每条独立验证样本，从同一主导模态的有效序列中随机抽取 32 次等长窗口，以其平均效应作为对照。等长条件控制被遮挡位置的数量，使比较集中于位置差异。另按局部曲线从高到低删除 10%、20%、30%、40% 的有效位置，与删除同样数量的随机位置比较，观察累计影响。随机种子为 20260924，95% 区间采用按视频分组的 1000 次自助采样，以保留同视频片段的组内关联。

5.5.2 核心干预结果

表 16 中，三个分类指标方向一致：所选窗口删除后引起的输出变化大于随机等长窗口。分类对数优势平均下降差为 0.400735，95% 区间为 [0.3635, 0.4372]；置信度和当前类别 logit 也呈同向差异。这说明固定模型对所选位置更敏感。由于所选窗口本身依据遮挡效应确定，该比较主要用于观察这些位置对固定模型输出的敏感程度。上述干预结果描述输入变化与固定模型输出之间的关系，不用于推断现实情感形成的因果机制。

表 16 附件 2 独立验证子集的解释干预一致性结果（396 条片段；按视频分组的 95% 自助采样区间）

输出量	所选窗口	随机等长窗口	平均差	95% 区间
分类对数优势下降	0.482771	0.082036	0.400735	[0.3635, 0.4372]
分类置信度下降	0.093286	0.015567	0.077718	[0.0712, 0.0843]
分类 logit 下降	0.292982	0.053294	0.239688	[0.2195, 0.2603]
回归有符号变化	0.002082	0.020177	-0.018095	[-0.0526, 0.0141]
回归绝对变化	0.202760	0.099215	0.103545	[0.0883, 0.1203]

回归结果需要区分方向与幅度。有符号变化差为 -0.018095，区间跨零，表明删除后连续强度没有统一的移动方向；不同样本的正、负变化可能在平均时抵消。绝对变化差为 +0.103545，说明同一所选区间仍引起更大的强度数值变化。局部窗口依据分类目标选出，回归结果描述该窗口对另一输出的响应。

删除曲线进一步显示影响随去除范围的变化。删除比例由 10% 增至 40% 时，高影响位置与随机位置的平均分类对数优势下降差依次为 0.108296、0.237758、0.418076 和 0.465465（图 16）。差异在四个比例下均为正并逐渐扩大，说明高影响位置的累计删除持续改变当前类别支持。曲线按局部效应排序后删除多个位置，与表中的单个连续窗口对照采用不同的删除集合。




图 16 主导模态与删除干预结果。(A) 728 条验证样本的分类、回归主导模态计数；(B) 396 条独立验证样本的删除比例曲线；(C) 高影响位置与随机位置的配对下降差。阴影为按视频分组的 95% 自助采样区间。

5.5.3 跨种子稳定性

使用既有 seed 43、44 模型与 seed 42 比较，保持独立验证样本和窗口比例相同。表 17 同时报告主导模态一致率、Shapley 贡献的 Spearman 秩相关系数及关键区间交并比 (IoU)。秩相关先在每条样本的三个贡献值之间计算，再对样本取均值；分类相关仅比较两个模型预测类别相同的样本，使贡献排序对应同一类别。

表 17 附件 2 独立验证子集的跨种子解释稳定性 (seed 42 分别与 43、44 比较； $n = 396$)

解释目标	种子对	主导模态一致率	Shapley 秩相关	关键区间 IoU
分类	42/43	0.869	0.818	0.579
	42/44	0.831	0.783	0.527
回归	42/43	0.778	0.745	—
	42/44	0.783	0.760	—

秩相关为逐样本三模态 Shapley 贡献的 Spearman 系数均值。分类仅统计两种子预测类别一致的样本；IoU 为主导模态相同时的区间交并比，模态不同时记为 0；回归未单独定义关键区间。

分类主导模态一致率为 0.869 和 0.831，区间 IoU 为 0.579 和 0.527；回归主导模态一致率为 0.778 和 0.783。模态选择相对稳定，具体窗口边界更敏感。主导模态只在三路输入之间比较，窗口却要从多个重叠候选中选出最大效应位置；若相邻窗口作用接近，初始化导致的小幅输出变化就可能改变边界。局部区间因此宜结合模态贡献和连续曲线阅读。

5.6 关键位置的输入来源回溯

连续窗口遮挡给出对齐特征中的索引，来源回溯将这些位置连接到可阅读的文本或已有特征记录。附件 4 的对应关系来自其自身的词元输入、原文和未对齐特征，按三种模态

现有记录能够确认的精度分别报告。

文本采用“对齐特征槽位 → BERT 词元 → 原文字符区间”的映射。利用固定 BERT 编码路径重构文本特征后，对 20 条样本的 604 个有效槽位进行逐行比较，全部行的最大余弦相似度匹配位置均为同索引。平均同索引余弦为 0.999999994，最大绝对差为 3.0041×10^{-5} ，均方根误差为 8.3977×10^{-7} 。这些数值支持对齐文本行与词元位置的对应关系。

词元到原文的字符跨度由分词器提供，因而可将所选窗口内的实际词元回到原文字符区间。特殊词元本身不产生原文片段，窗口内的文本以真实字符跨度读取。这一处理使结果既保留模型中的槽位索引，也给出可直接阅读的文字；两种坐标描述的是同一输入在不同表示中的位置。

语音和视觉通过逐行特征匹配回到未对齐数组。附件 4 的 564/564 个非零语音对齐行、534/534 个非零视觉对齐行，都能在对应该样本的未对齐特征中找到唯一且逐元素相等的行。这种对应依赖实际特征值，不要求把 50 个槽位均分到视频时长；原生零行则保留原记录，不赋予未经确认的来源索引。

据此，文本位置报告为“原文字符级”，语音和视觉位置报告为“未对齐特征行级”。现有音视频来源记录还缺少从未对齐行到音频秒数或视频帧时间的可靠映射，位置精度止于特征行。典型案例图保留的视频画面用于显示上下文，其选取独立于关键特征区间。

5.7 附件 4 预测与解释结果

完成解释方法及独立验证后，本文将固定的预测与解释流程应用于附件 4 的 20 条无标签样本，其中预测为消极、中性和积极的数量分别为 7、5 和 8，分布见表 18。全部类别、连续强度和分类置信度列于表 19；分类 Shapley 贡献与关键特征区间列于表 20。附件 4 没有真实标签，因此本节报告预测及解释结果，不计算 Accuracy、F1、MAE 或 Pearson 等监督评价指标。

分类主导模态为文本、视觉、语音的样本数分别为 19、1、0，回归分别为 18、2、0。分类主导模态与回归主导模态在 17 条样本上一致，占 85%，其余 3 条样本的两类主导模态不同。表中 ϕ_T, ϕ_A, ϕ_V 均对应分类对数优势，保留符号以显示同向支持和反向作用。

表 18 附件 4 的无标签预测及解释摘要（共 20 条样本）

统计项	类别或来源	数量	比例
预测情感类别	消极	7	35%
	中性	5	25%
	积极	8	40%
分类主导模态	文本	19	95%
	语音	0	0%
	视觉	1	5%
回归主导模态	文本	18	90%
	语音	0	0%
	视觉	2	10%
分类关键位置来源	原文字符级	19	95%
	未对齐特征行级	1	5%

表 19 附件 4 全部 20 条无标签样本的预测结果

样本 ID	预测类别	情感强度	分类置信度
01	中性	+0.177915	0.5359
02	消极	-0.027301	0.3898
03	中性	-0.064430	0.5441
04	消极	-0.398096	0.6741
05	积极	+0.886586	0.7131
06	积极	+0.759221	0.7287
07	积极	+0.799232	0.7699
08	积极	+0.678992	0.7512
09	消极	-1.987819	0.9671
10	消极	-1.556107	0.9453
11	消极	-0.965641	0.8577
12	消极	-0.981858	0.8488
13	中性	+0.173788	0.5675
14	中性	+0.154869	0.5568
15	积极	+1.267568	0.8941
16	消极	-2.030377	0.9670
17	积极	+1.656759	0.9493
18	中性	-0.158624	0.5781
19	积极	+0.276115	0.3840
20	积极	+0.875848	0.8013

表 20 附件 4 全部 20 条样本的分类贡献与输入来源：区间为从零开始的对齐特征槽位 $[a, b)$

ID	ϕ_T	ϕ_A	ϕ_V	主导模态	关键区间	输入来源
01	+0.4448	+0.0283	+0.0097	文本	[17, 24)	原文字符级
02	-0.1971	+0.2277	+0.8294	视觉	[1, 7)	未对齐特征行级
03	+0.6919	-0.1267	-0.0492	文本	[0, 10)	原文字符级
04	+1.9249	+0.1198	-0.0096	文本	[20, 28)	原文字符级
05	+1.1092	-0.3336	+0.6619	文本	[0, 5)	原文字符级
06	+2.2790	-0.2529	-0.5109	文本	[14, 25)	原文字符级
07	+1.6925	-0.3365	+0.3790	文本	[13, 28)	原文字符级
08	+2.4908	-0.2620	-0.5967	文本	[8, 12)	原文字符级
09	+4.0872	+0.4352	+0.1656	文本	[2, 8)	原文字符级
10	+3.6626	+0.4324	+0.0621	文本	[21, 31)	原文字符级
11	+2.0970	+0.2465	+0.7610	文本	[1, 6)	原文字符级
12	+2.1874	-0.0032	+0.8495	文本	[31, 44)	原文字符级
13	+0.5928	+0.0180	+0.0000	文本	[0, 10)	原文字符级
14	+1.5361	+0.0546	-1.0233	文本	[1, 12)	原文字符级
15	+2.9847	-0.3149	-0.0090	文本	[14, 21)	原文字符级
16	+3.8314	+0.4557	+0.3986	文本	[8, 12)	原文字符级
17	+3.4202	-0.1421	+0.1781	文本	[9, 17)	原文字符级
18	+0.8431	-0.0933	-0.0955	文本	[6, 21)	原文字符级
19	+0.6310	-0.4071	-0.1692	文本	[29, 41)	原文字符级
20	+2.0873	-0.2851	+0.1195	文本	[0, 14)	原文字符级

同一类别内部的输出也有明显差异。样本 02 与样本 09 均被预测为消极，连续强度却分别为 -0.027301 和 -1.987819 ，分类置信度分别为 0.3898 和 0.9671 。类别、强度和置信度描述不同方面，逐样本结果将它们分别保留，避免用一个类别标签替代连续输出。

5.8 典型样本分析与本问小结

附件 4 多数样本由文本主导，但也存在视觉主导的个例。为比较不同模态主导时的贡献和来源回溯结果，图 17 选取文本主导的样本 14 和视觉主导的样本 02 进行分析。

样本 14 预测为中性，连续强度为 $+0.154869$ 。三模态分类贡献为 $\phi_T = +1.536072$ 、 $\phi_A = +0.054570$ 、 $\phi_V = -1.023311$ ，文本是主要正向输入，视觉对当前中性类别起反向作用，语音贡献较小。文本关键特征区间 $[1, 12)$ 对应原文字符 $[0, 38)$ ，片段为 “He is the co-founder of Rossen and Vet”。所选文本区间可进一步回查到上述原文片段，从而明确模型中主要文本支持对应的具体内容。贡献的正向指对中性类别的支持，与积极情感标签含义不同。

样本 02 预测为消极，连续强度为 -0.027301 。其贡献为 $\phi_T = -0.197115$ 、 $\phi_A = +0.227718$ 、 $\phi_V = +0.829375$ ，视觉支持最大，语音同向但较小，文本产生反向作用。视觉关键特征区间 $[1, 7)$ 包含对齐槽位 1–6，可逐行对应到未对齐视觉特征行 36–41。因此，视觉主导样本的关键位置可以进一步对应到已有的未对齐视觉特征记录。图中的场景画面提供观看上下文。

A 文本主导典型案例（样本14）




视频上下文示意

预测类别 中性 情感强度 +0.155
置信度 0.557 分类主导模态 文本


原文字符级

"He is the co-founder of Rossen and Vet"

分类 Shapley 贡献



局部遮挡曲线



关键区间（槽位） [1, 12]


B 视觉主导典型案例（样本02）




视频上下文示意

预测类别 消极 情感强度 -0.027
置信度 0.390 分类主导模态 视觉

分类 Shapley 贡献



局部遮挡曲线



关键区间（槽位） [1, 7]

视觉证据：对齐槽位 1-6 → 未对齐特征行 36-41

图 17 附件 4 的典型样本。（A）样本 14 的文本贡献、局部遮挡曲线与原文片段；（B）样本 02 的视觉贡献、局部遮挡曲线与未对齐特征行对应。浅色带标出所选特征区间，视频画面为上下文示意。

两个案例的回溯终点不同：样本 14 可以直接读取原文字符，样本 02 当前可查到未对齐视觉特征行。同一遮挡方法给出特征区间，而能够进一步阅读或展示何种输入，取决于该模态保存的来源记录。

本问固定问题二的预测模型，以模态组合输出计算三模态贡献与两两交互，再用连续窗口遮挡定位局部影响。随机等长窗口、删除曲线和跨种子比较分别考察局部响应、累计影响及初始化变化，使解释结果可以结合模型的实际输出评估。

附件 4 的 20 条样本均得到类别、连续强度、模态贡献和关键区间，并按已有来源记录连接到原文或未对齐特征行。逐样本的同向与反向贡献、不同主导模态及不同位置，共同呈现固定模型使用三路输入的差异，也为检查具体预测提供了可复查的记录。

参考文献

- [1] Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *Proceedings of Machine Learning Research*, pages 28492–28518. PMLR, 2023.
- [2] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa: A robustly optimized BERT pretraining approach. *arXiv preprint arXiv:1907.11692*, 2019.
- [3] Sanyuan Chen, Chengyi Wang, Zhengyang Chen, Yu Wu, Shujie Liu, Zhuo Chen, Jinyu Li, Naoyuki Kanda, Takuya Yoshioka, Xiong Xiao, Jian Wu, Long Zhou, Shuo Ren, Yanmin Qian, Yao Qian, Jian Wu, Michael Zeng, Xiangzhan Yu, and Furu Wei. WavLM: Large-scale self-supervised pre-training for full stack speech processing. *IEEE Journal of Selected Topics in Signal Processing*, 16(6):1505–1518, 2022.
- [4] Michael Tschannen, Alexey Gritsenko, Xiao Wang, Muhammad Ferjad Naeem, Nikhil Alabdulmohsin, Nikhil Parthasarathy, Talfan Evans, Lucas Beyer, Ye Xia, Basil Mustafa, Olivier Hénaff, Jeremiah Harmsen, Andreas Steiner, and Xiaohua Zhai. SigLIP 2: Multilingual vision-language encoders with improved semantic understanding, localization, and dense features. *arXiv preprint arXiv:2502.14786*, 2025.
- [5] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, et al. DINOv3: Self-supervised learning for vision at unprecedented scale. *arXiv preprint arXiv:2508.10104*, 2025.
- [6] Zadeh A, Chen M, Poria S, et al. Tensor Fusion Network for Multimodal Sentiment Analysis[C]//Proceedings of EMNLP. 2017: 1103–1114. DOI: 10.18653/v1/D17-1115.
- [7] Liu Z, Shen Y, Lakshminarasimhan V B, et al. Efficient Low-rank Multimodal Fusion With Modality-Specific Factors[C]//Proceedings of ACL, Volume 1. 2018: 2247–2256. DOI: 10.18653/v1/P18-1209.
- [8] Zadeh A, Liang P P, Mazumder N, et al. Memory Fusion Network for Multi-view Sequential Learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2018, 32(1): 5634–5641. DOI: 10.1609/aaai.v32i1.12021.
- [9] Tsai Y H H, Bai S, Liang P P, et al. Multimodal Transformer for Unaligned Multimodal Language Sequences[C]//Proceedings of ACL. 2019: 6558–6569. DOI: 10.18653/v1/P19-1656.
- [10] Hazarika D, Zimmermann R, Poria S. MISA: Modality-Invariant and -Specific Representations for Multimodal Sentiment Analysis[C]//Proceedings of ACM Multimedia. 2020: 1122–1131. DOI: 10.1145/3394171.3413678.
- [11] Yu W, Xu H, Yuan Z, et al. Learning Modality-Specific Representations with Self-Supervised Multi-Task Learning for Multimodal Sentiment Analysis[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2021, 35(12): 10790–10797. DOI: 10.1609/aaai.v35i12.17289.
- [12] Han W, Chen H, Poria S. Improving Multimodal Fusion with Hierarchical Mutual Information Maximization for Multimodal Sentiment Analysis[C]//Proceedings of EMNLP. 2021: 9180–9192. DOI: 10.18653/v1/2021.emnlp-main.723.

- [13] Yuan Z, Li W, Xu H, et al. Transformer-based Feature Reconstruction Network for Robust Multimodal Sentiment Analysis[C]//Proceedings of ACM Multimedia. 2021: 4400–4407. DOI: 10.1145/3474085.3475585.
- [14] Lin R, Hu H. MissModal: Increasing Robustness to Missing Modality in Multimodal Sentiment Analysis[J]. Transactions of the Association for Computational Linguistics. 2023, 11: 1686–1702. DOI: 10.1162/tac1_a_00628.
- [15] Chi H, Yang M, Zhu J, et al. Missing Modality meets Meta Sampling (M3S): An Efficient Universal Approach for Multimodal Sentiment Analysis with Missing Modality[C]//Proceedings of AACL-IJCNLP, Volume 1. 2022: 121–130. DOI: 10.18653/v1/2022.aacl-main.10.
- [16] Zhao J, Li R, Jin Q. Missing Modality Imagination Network for Emotion Recognition with Uncertain Missing Modalities[C]//Proceedings of ACL-IJCNLP, Volume 1. 2021: 2608–2618. DOI: 10.18653/v1/2021.acl-long.203.