

三模态原始输入

文本

Best

things

in

life

are

free

音频

视频



RoBERTa

Text Encoder

文本特征及时间区间

WavLM

Audio Encoder

语音特征及时间区间

SigLip2

Visual Encoder

视觉特征及显示时间

最大时间重叠对齐

$$\hat{j}_{ik}^{(m)} = \arg \max_j |I_{ij}^{(m)} \cap B_{ik}|$$

仅映射具有正时间交叠特征

可追溯对齐结果

