

2 问题二：缺失场景下的多模态情感预测模型

2.1 问题分析与总体方案

附件 2 已经提供对齐到 50 个时间位置的文本、语音和视觉特征。局部连续缺失发生时，一种或多种模态会在一段时间内失去观测，其影响随模态、位置和持续长度而变化。本问据此研究情感极性分类与连续强度回归：完整输入能保留多少预测信息，连续缺失后性能如何变化，以及能否通过轻量的结构调整改善跨场景表现。

先以掩码均值池化（MMP）建立基线，分别聚合三模态有效槽位，再拼接融合并输出情感类别与强度。均值池化对所有有效位置赋予相同权重，难以区分剩余内容的信息量。本文在该路径上加入轻量时间注意力残差池化（LTARP），由内容打分形成补充表示，与均值表示共同参与预测，整体流程见图 8。




图 8 LTARP 三模态池化与双任务预测流程。

2.2 数据表示与预测任务

两种池化方式共用附件 2 的对齐输入与任务标签。对齐特征文件为 aligned-50.pkl，训练、验证和测试划分分别含 3395、728 和 727 条样本。训练集用于学习参数，验证集用于结构选择与评价；测试划分和无标签附件 3 不参与选模。

统一最大长度为 $T = 50$ ，样本 i 的三模态输入为

$$\mathbf{X}_i^{(T)} \in \mathbb{R}^{50 \times 768}, \quad \mathbf{X}_i^{(A)} \in \mathbb{R}^{50 \times 74}, \quad \mathbf{X}_i^{(V)} \in \mathbb{R}^{50 \times 35}. \quad (1)$$

样本有效长度为 L_i ($3 \leq L_i \leq 50$)，由随附注意力掩码确定。定义有效槽位指示变量

$$p_{it} = \begin{cases} 1, & t \in \{1, 2, \dots, L_i\}, \\ 0, & t \in \{L_i + 1, \dots, 50\}. \end{cases} \quad (2)$$

缺失实验仅作用于原本有效的时位置。附件 2 中已有的零值输入保持原始状态，并与后续人为构造的连续缺失分别记录。填充后缀由掩码排除，原始有效范围在遮挡前后保持一致。人工置零的位置仍位于有效前缀中，均值聚合的分母继续使用原有效长度，模

型因而接收相同长度、局部内容受损的序列。

连续情感强度标签记为 $y_i \in [-3.0, +3.0]$ ，三类极性由其符号确定：

$$c_i = \begin{cases} 0 & (\text{消极 Negative}), & y_i < 0, \\ 1 & (\text{中性 Neutral}), & y_i = 0, \\ 2 & (\text{积极 Positive}), & y_i > 0. \end{cases} \quad (3)$$

其中 $y_i = 0$ 对应中性类，分类与回归分别描述极性类别和连续强度。

训练集与验证集均以积极样本为最多，中性样本相对较少，类别比例呈现不均衡；连续强度集中于零附近，两侧分布覆盖不同程度的极性。有效序列长度也有明显差异，训练与验证的中位数分别为 22 和 23.5，小于统一长度 50。因此，类别权重和有效位掩码分别进入损失计算与特征聚合（图 9）。




图 9 附件 2 的样本、情感标签与有效序列长度分布。

2.3 掩码均值池化基线

为单独观察连续缺失对预测的影响，先构造不含复杂时序模块的简单基线。MMP 只在有效槽位上计算均值，再完成模态映射、融合和双任务预测。均值表示将不同有效长度的序列组织为固定维度，使各样本可以进入同一融合网络；同时保留一条明确的等权聚

合路径，便于后续观察内容加权的增量。对模态 $m \in \{T, A, V\}$ ，其均值为

$$\boldsymbol{\mu}_i^{(m)} = \frac{\sum_{t=1}^{50} p_{it} \mathbf{x}_{it}^{(m)}}{\sum_{t=1}^{50} p_{it}}. \quad (4)$$

均值向量通过模态专属映射 $P_m(\cdot)$ 得到 128 维表示：

$$\mathbf{h}_{i,0}^{(m)} = P_m(\boldsymbol{\mu}_i^{(m)}) = \text{Dropout}\left(\text{GELU}\left(\text{LayerNorm}(\mathbf{W}_m \boldsymbol{\mu}_i^{(m)} + \mathbf{b}_m)\right)\right). \quad (5)$$

三路表示拼接为 384 维向量 $\mathbf{h}_i^{\text{concat}} = [\mathbf{h}_{i,0}^{(T)}; \mathbf{h}_{i,0}^{(A)}; \mathbf{h}_{i,0}^{(V)}]$ ，再经 128 维融合层得到

$$\mathbf{z}_i = \text{Dropout}\left(\text{GELU}\left(\text{LayerNorm}(\mathbf{W}_f \mathbf{h}_i^{\text{concat}} + \mathbf{b}_f)\right)\right). \quad (6)$$

联合表征分别连接三分类与强度回归输出：

$$\hat{\mathbf{p}}_i = \text{Softmax}(\mathbf{W}_c \mathbf{z}_i + \mathbf{b}_c) \in \mathbb{R}^3, \quad \hat{y}_i = \mathbf{W}_r \mathbf{z}_i + b_r \in \mathbb{R}. \quad (7)$$

预测类别取 $\hat{c}_i = \arg \max_{k \in \{0,1,2\}} \hat{p}_{ik}$ 。

训练集的消极、中性和积极样本数分别为 967、758 和 1670。采用类别频数逆加权交叉熵，使三类在分类目标中获得相应权重：

$$w_c = \frac{N_{\text{train}}}{3 \cdot N_c}, \quad \mathcal{L}_{\text{WCE}} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=0}^2 w_k \cdot \mathbb{I}(c_i = k) \log \hat{p}_{ik}. \quad (8)$$

回归采用 SmoothL1 损失：

$$\mathcal{L}_{\text{SmoothL1}} = \frac{1}{N} \sum_{i=1}^N \ell_{\text{smooth}}(\hat{y}_i - y_i), \quad \ell_{\text{smooth}}(u) = \begin{cases} 0.5u^2, & |u| < 1, \\ |u| - 0.5, & |u| \geq 1. \end{cases} \quad (9)$$

两项任务以相同权重联合优化：

$$\mathcal{L} = \mathcal{L}_{\text{WCE}} + \lambda_r \mathcal{L}_{\text{SmoothL1}}, \quad \lambda_r = 1.0. \quad (10)$$

MMP 共含 163460 个参数，直接使用附件 2 的原始数值特征，不额外标准化。采用 AdamW，学习率 10^{-3} 、权重衰减 10^{-4} 、批量大小 128、随机失活率 0.1；最多训练 80 轮，提前停止耐心轮数为 12 轮。基线在完整输入上训练。

2.4 轻量时间注意力残差池化模型

MMP 结构简单、参数较少，均值聚合为比较缺失影响提供了稳定起点。但连续缺失发生后，剩余位置所含情感信息并不均等。LTARP 保留均值路径，增加逐槽位内容打分器，使模型能为剩余内容形成不同权重。模态 m 的打分记为

$$e_{it}^{(m)} = f_m(\mathbf{x}_{it}^{(m)}) = \mathbf{w}_{m,2}^\top \tanh(\mathbf{W}_{m,1} \mathbf{x}_{it}^{(m)} + \mathbf{b}_{m,1}) + b_{m,2}. \quad (11)$$

权重在原始有效槽位内归一化，并形成内容加权表示：

$$\alpha_{it}^{(m)} = \frac{p_{it} \exp(e_{it}^{(m)})}{\sum_{s:p_{is}=1} \exp(e_{is}^{(m)})}, \quad \mathbf{a}_i^{(m)} = \sum_{t=1}^{50} \alpha_{it}^{(m)} \mathbf{x}_{it}^{(m)}. \quad (12)$$

填充位的 $\alpha_{it}^{(m)}$ 恒为 0。人工遮挡后的零值仍按原有效指示参与打分与聚合，权重变化由当前输入内容决定。

内容加权表示作为均值表示的补充，两路共享模态映射 P_m ，以可学习系数 γ_m 进行残差组合：

$$\mathbf{h}_i^{(m)} = P_m(\boldsymbol{\mu}_i^{(m)}) + \gamma_m \cdot P_m(\mathbf{a}_i^{(m)}), \quad m \in \{T, A, V\}. \quad (13)$$

该表示继续进入原有融合层与双任务输出，新增分支只改变模态内的聚合方式。共享映射使两路表示具有相同维度，均值路径保留整体信息，内容加权路径提供随样本变化的补充；残差系数控制补充分支进入预测的程度。

训练首先完成 MMP 的模态映射、融合与双任务输出学习，再以其参数初始化 LTARP。第二阶段保持这些已有参数不变，仅学习三个模态打分器及三个残差系数。令 γ_m 初值为 0，初始模态输出为

$$\mathbf{h}_i^{(m)} = P_m(\boldsymbol{\mu}_i^{(m)}), \quad (14)$$

与 MMP 保持一致。随后，内容加权分支通过残差系数逐步参与预测。新增可训练参数为 883 个，总参数量增至 164343，从而以较小的参数增量补充时间位置的内容差异。

2.5 连续缺失场景与评价协议

两种池化方式的差异需要在相同受损输入上比较。连续缺失主要由三个因素决定：缺失哪种模态、发生在哪个位置，以及持续多长。因此，评价在完整输入之外分别组合模态、比例和位置，形成固定的 54 种场景。单模态场景沿比例变化观察各输入的敏感程度，双模态场景在同一比例下观察信息同时受损的影响；三个位置区分起始、中央和末段缺失，连接受损范围与时间组织。

- 单模态场景集 $\mathcal{C}_1$: $m \in \{T, A, V\}$ ，目标比例 $\mathcal{R} = \{0.1, 0.2, 0.3, 0.4, 0.5\}$ ，位置 $\mathcal{P} = \{\text{front}, \text{middle}, \text{rear}\}$ ，共 $3 \times 5 \times 3 = 45$ 种。
- 双模态场景集 $\mathcal{C}_2$: 模态对为 $\{T, A\}$ 、 $\{T, V\}$ 、 $\{A, V\}$ ，固定 $\rho_{\text{target}} = 0.3$ ，分别取三个位置，共 $3 \times 1 \times 3 = 9$ 种。

对有效长度 L_i ，遮挡槽位数与实际比例为

$$\ell_i = \max(1, \text{round}(\rho_{\text{target}} \cdot L_i)), \quad \rho_{\text{actual}, i} = \frac{\ell_i}{L_i}. \quad (15)$$

槽位数必须取整数，短序列的实际比例会偏离目标比例；验证集中，目标比例 0.1 的实际范围为 0.0714–0.3333，目标比例 0.5 为 0.4000–0.6667，对应均值为 0.1040 和 0.5009。图表横轴用目标比例标识场景，实际比例逐样本记录。

前、中、后段的起点 s_i 分别为 0、 $\lfloor (L_i - \ell_i)/2 \rfloor$ 和 $L_i - \ell_i$ 。遮挡将指定模态在 $[s_i, s_i + \ell_i - 1]$ 内的特征置零，其余模态和填充掩码保持原样。每个场景都在完整的 728 条验证样本上评价，各样本按自身有效长度计算区间。

分类评价同时采用准确率与宏平均 F1，分别观察总体识别与类别均衡表现；回归采用 MAE 和皮尔逊相关系数，分别观察绝对误差与变化趋势。四项指标定义为：

- 准确率 (Accuracy, $\uparrow$): $\text{Acc} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\hat{c}_i = c_i)$;
- 宏平均 F1 (Macro-F1, $\uparrow$): $\text{MacroF1} = \frac{1}{3} \sum_{k=0}^2 \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k}$;
- 平均绝对误差 (MAE, $\downarrow$): $\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i|$;
- 皮尔逊相关系数 (Pearson, r , $\uparrow$): $\text{Pearson} = \frac{\sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})^2} \sqrt{\sum_{i=1}^N (y_i - \bar{y})^2}}$.

将分类与回归表现组合为得分 S :

$$S = \frac{1}{4} \text{Acc} + \frac{1}{4} \text{MacroF1} + \frac{1}{4} \left(1 - \frac{\text{MAE}}{6} \right) + \frac{1}{8} (\text{Pearson} + 1). \quad (16)$$

完整输入对应 S_{clean} ; 跨场景得分 R 对完整输入及 54 场景平均等权组合:

$$R = \frac{1}{2} \left(S_{\text{clean}} + \frac{1}{54} \sum_{j=1}^{54} S_j \right). \quad (17)$$

结构比较表 8 和公开方法结果表 11、12 统一按 S_{clean} 选择模型参数, 再评价完整与缺失输入。缺失敏感性分析关注跨场景表现, 图 10–13 沿用按 R 选择的 LTARP 参数及对应 MMP 基线。两组评价各自共用一套已选参数, 对所有场景执行相同流程。

场景统计先在种子内汇总, 再计算种子间均值与样本标准差。设第 s 个种子在场景 j 的指标为 $M_{s,j}$, 其缺失场景均值为

$$\bar{M}_s = \frac{1}{54} \sum_{j=1}^{54} M_{s,j}, \quad s \in \{42, 43, 44\}. \quad (18)$$

三次初始化是统计重复单位, 54 个场景在各自初始化内等权平均。这样, 场景平均表示模型在固定受损条件集合中的总体表现, 种子间标准差则描述同一训练设置的初始化波动。算法 1 概括执行步骤。

算法 1 连续缺失场景评价

输入: 验证集三模态特征、有效掩码与已选模型。

输出: 完整输入及 54 场景指标、 S_{clean} 与 R 。

1. 预测完整输入, 计算四项指标及 S_{clean} 。
 2. 遍历场景配置 $(\mathcal{M}_{\text{target}}, \rho_{\text{target}}, \text{pos})$ 。
 3. 对各样本读取 L_i , 按式 (15) 计算 ℓ_i 并确定 s_i 。
 4. 在原输入副本中置零目标模态的连续区间, 保持有效掩码。
 5. 预测当前场景, 记录四项指标与 S_j 。
 6. 汇总 54 场景结果, 按式 (17) 计算 R 。
-

2.6 基线与 LTARP 的结构比较

在统一完整输入选模标准下, LTARP 在宏平均 F1、MAE 和相关系数上均优于 MMP 均值, 准确率变化较小。对相同模型参数施加 54 种缺失后, 三项指标的平均改善仍保留, 准确率则略有下降 (表 8)。内容加权分支的收益主要体现于类别均衡性和连续强度预测。宏平均 F1 按类别等权汇总, 能够呈现准确率之外的类别差异; MAE 与相关系数的同步改善, 则分别对应强度误差及预测趋势的变化。

表 8 统一完整输入选模规则下的 MMP 与 LTARP 比较（三随机种子均值 $\pm$ 样本标准差）

条件	模型	准确率 $\uparrow$	宏平均 F1 $\uparrow$	MAE $\downarrow$	相关系数 $\uparrow$
完整输入	MMP	0.6401 ± 0.0048	0.6139 ± 0.0091	0.6079 ± 0.0103	0.6409 ± 0.0043
完整输入	LTARP	0.6415 ± 0.0050	0.6243 ± 0.0026	0.6052 ± 0.0063	0.6475 ± 0.0024
54 场景平均	MMP	0.6349 ± 0.0062	0.6092 ± 0.0075	0.6111 ± 0.0098	0.6359 ± 0.0038
54 场景平均	LTARP	0.6334 ± 0.0038	0.6163 ± 0.0013	0.6086 ± 0.0059	0.6417 ± 0.0024

以跨场景综合得分考察三次初始化，种子 42 和 43 呈正增益，种子 44 近乎持平；配对差 $\Delta R = R_{\text{LTARP}} - R_{\text{MMP}}$ 分别为 $+0.005600$ 、 $+0.003791$ 和 -0.000090 ，平均为 $+0.003100 \pm 0.002907$ 。总体收益较小，同时存在初始化敏感性。

2.7 缺失类型、位置与比例分析

总体平均保留了改善，但不同模态的缺失影响有所差异。图 10 中，文本随遮挡比例增大退化最明显，语音和视觉变化较平缓；分类与回归对输入损失的响应程度也不同。文本遮挡由 0.1 增至 0.5 时，宏平均 F1 从 0.6163 降至 0.5933，显示语言内容在这组样本中的较强作用。




图 10 单模态缺失比例与验证集性能。阴影为三随机种子的样本标准差，虚线为完整输入均值。

缺失长度相同，发生位置仍会改变预测。固定目标比例 0.3 后，文本前段与后段遮挡对宏平均 F1 的影响大于中段；包含文本的双模态缺失也呈相近规律，语音、视觉及语音-视觉组合的影响较小。分类与回归的位置响应并不完全一致，例如文本中段遮挡降低宏平均 F1，却使 MAE 略有下降（图 11）。




图 11 不同模态与位置相对完整输入指标变化。各指标使用独立色标。

相同模态、位置和比例下的配对差进一步体现 LTARP 的作用（图 12）。宏平均 F1 和 Pearson 的改善更为一致，在语音、视觉及语音-视觉缺失条件下较明显；准确率随位置与模态组合出现正负波动。内容加权补充有助于保持部分剩余信息，其效果仍随受损输入而变化。包含文本的受损场景影响较大，而仅语音或视觉受损时仍有文本输入；配对差和相对完整输入的退化分别描述结构收益与信息损失，两者共同刻画缺失规律。




图 12 LTARP 相对 MMP 的配对改善。MAE 取 MMP 减 LTARP，其余指标取 LTARP 减 MMP；正值表示改善。

2.8 稳定性、错误分布与消融分析

2.8.1 随机初始化稳定性与验证集错误分布

模态与位置的平均规律之外，初始化变化、类别混淆和特殊输入条件进一步反映模型的适用边界。三次训练的配对收益较小，因而需结合完整输入的分类误差及原生视觉全零样本，观察这些改善在不同条件下的保持程度（图 13）。




图 13 随机初始化稳定性与误差分析。(a) 配对综合分数; (b) 混淆矩阵; (c) 场景分组; (d) 原生视觉全零子集。

三次初始化中有两次提高, 一次近乎持平, 场景分组后的平均差也较小。完整输入下, 消极与积极类的召回相对较高, 中性类最低, 为 43.48%; 中性样本更容易被分到两侧极性类别, 弱极性与类别边界仍是主要混淆位置。

验证集另有 15 条原生视觉特征整段全零样本。该子集中, 部分初始化的 LTARP 分类表现低于 MMP, 说明较小的总体平均收益可以与特殊输入上的退化同时出现。原生全零输入在有效前缀内保持原值, 它所对应的观测条件与人工遮挡实验分别记录。该子集样本量较少, 其表现结合三次初始化单独观察。

2.8.2 候选结构与训练策略消融

为比较改善来自何种结构或训练调整, 保留时间编码、训练期连续遮挡和均值-最大值残差池化三种候选, 与 MMP 及 LTARP 并列 (表 9)。

表 9 候选结构与训练策略消融。均值-最大值残差池化仅有一次初始化。

方案	初始化次数	总参数量	综合分数 R
MMP (基线)	3	163460	0.7417 ± 0.0015
单模态时间编码	3	957572	0.7351 ± 0.0020
训练期连续遮挡	3	163460	0.7385 ± 0.0025
均值-最大值残差池化	1	163463	0.7443
LTARP (本文方案)	3	164343	0.7448 ± 0.0015

单模态时间编码在聚合前加入顺序建模, 参数量明显增加, 综合得分却低于 MMP。训练期连续遮挡保持网络不变: 每条样本以 0.5 概率保留完整输入, 其余样本中 75% 遮

挡一个模态、25% 遮挡两个模态，比例从 $\{0.1, 0.2, 0.3, 0.4, 0.5\}$ 选择，起点在有效范围内随机确定，掩码保持原值。这种缺失增强也未带来综合得分改善。

均值-最大值残差池化保留均值分支

$$\mu_i^{(m)} = \frac{\sum_t p_{it} \mathbf{x}_{it}^{(m)}}{\sum_t p_{it}}, \quad (19)$$

并以有效槽位内逐特征维的最大值提供补充，再经残差组合接入原有网络。其得分接近 LTARP，但仅保留一次初始化结果，主要作为结构探索参考，不与三随机种子结果作精细统计比较。LTARP 的三种子综合均值在本组最高，同时只增加 883 个参数，支持采用轻量内容加权补充的选择。

2.9 公开方法适配与对比

在基线及候选结构之外，进一步观察 LTARP 与其他多模态建模路线的相对表现。选取 11 种公开方法，统一适配到附件 2 的 aligned-50 输入与分类、回归双任务接口；三模态维度、数据划分、指标和完整输入选模标准保持一致，各方法按既有适配配置训练。表 10 概括适配中的机制与规模。

表 10 公开方法的统一接口适配概览

方法	类型	本文适配中的核心机制	参数量
TFN[1]	常规融合	张量外积融合	4,840,670
LMF[2]	常规融合	低秩张量分解	323,276
MFN[3]	时序融合	跨模态记忆更新	261,764
MuT[4]	时序融合	定向跨模态注意力	624,094
MISA[5]	表征解耦	共享与特有空间约束	1,118,852
Self-MM[6]	多任务	单模态辅助监督	82,119
MMIM[7]	信息约束	互信息约束与联合融合	163,204
TFR-Net[8]	缺失增强	连续掩码与表征重构	415,620
MissModal[9]	缺失增强	完整与缺失表征对齐	163,204
M3S[10]	缺失增强	缺失采样与元更新	323,276
MMIN[11]	缺失增强	潜在缺失推断与循环约束	292,164

常规融合路线通过张量、时序注意力、表征解耦或辅助任务组织多模态信息；缺失增强路线进一步引入重构、表征对齐、元更新和缺失推断。它们保留相应机制并接入本问的特征与双任务接口，以下结果均限定在本文统一适配与评价设置下。

完整输入下，LTARP 四项指标均处于较优水平（表 11）。部分轻量方法及缺失增强方法的表现接近 LTARP，而更复杂的融合结构未呈现同等的平均优势。Self-MM 和 MMIM 借助辅助任务或信息约束，在较小规模下也保留了较强预测信息；TFR-Net 的宏平均 F1 接近 LTARP，但回归指标有所差异。因此，分类均衡性和回归结果需要结合观察。

表 11 公开方法与 LTARP 的完整输入验证集结果（三随机种子均值 $\pm$ 样本标准差）

模型	方法类别	参数量	准确率 $\uparrow$	宏平均 F1 $\uparrow$	MAE $\downarrow$	相关系数 $\uparrow$
TFN	常规融合	4,840,670	0.6099 $\pm$ 0.0076	0.5872 $\pm$ 0.0083	0.6336 $\pm$ 0.0102	0.6056 $\pm$ 0.0098
LMF	常规融合	323,276	0.5925 $\pm$ 0.0114	0.5719 $\pm$ 0.0090	0.6682 $\pm$ 0.0196	0.5807 $\pm$ 0.0188
MFN	常规融合	261,764	0.5966 $\pm$ 0.0080	0.5824 $\pm$ 0.0062	0.6418 $\pm$ 0.0124	0.5908 $\pm$ 0.0125
MuT	常规融合	624,094	0.6172 $\pm$ 0.0148	0.5891 $\pm$ 0.0236	0.6221 $\pm$ 0.0260	0.6369 $\pm$ 0.0115
MISA	常规融合	1,118,852	0.6131 $\pm$ 0.0083	0.6010 $\pm$ 0.0060	0.9175 $\pm$ 0.1005	0.6269 $\pm$ 0.0087
Self-MM	常规融合	82,119	0.6355 $\pm$ 0.0052	0.6107 $\pm$ 0.0084	0.6099 $\pm$ 0.0066	0.6423 $\pm$ 0.0042
MMIM	常规融合	163,204	0.6360 $\pm$ 0.0048	0.6110 $\pm$ 0.0007	0.6102 $\pm$ 0.0098	0.6375 $\pm$ 0.0054
TFR-Net	缺失增强	415,620	0.6374 $\pm$ 0.0071	0.6230 $\pm$ 0.0080	0.6145 $\pm$ 0.0118	0.6267 $\pm$ 0.0142
MissModal	缺失增强	163,204	0.6305 $\pm$ 0.0071	0.6108 $\pm$ 0.0069	0.6084 $\pm$ 0.0113	0.6431 $\pm$ 0.0006
M3S	缺失增强	323,276	0.6035 $\pm$ 0.0063	0.5775 $\pm$ 0.0169	0.6706 $\pm$ 0.0173	0.5793 $\pm$ 0.0171
MMIN	缺失增强	292,164	0.6383 $\pm$ 0.0062	0.6117 $\pm$ 0.0079	0.6279 $\pm$ 0.0247	0.6401 $\pm$ 0.0027
LTARP	本文模型	164,343	0.6415 $\pm$ 0.0050	0.6243 $\pm$ 0.0026	0.6052 $\pm$ 0.0063	0.6475 $\pm$ 0.0024

54 种连续缺失等权平均后，LTARP 在宏平均 F1、MAE 和 Pearson 上保持较好的综合表现，准确率与 TFR-Net、MMIN 接近（表 12）。完整输入表现与缺失后保持程度共同决定跨场景结果；缺失增强方法之间也存在差异。

表 12 公开方法与 LTARP 的 54 种连续缺失场景平均结果（三随机种子均值 $\pm$ 样本标准差）

模型	训练方式	参数量	准确率 $\uparrow$	宏平均 F1 $\uparrow$	MAE $\downarrow$	相关系数 $\uparrow$
TFN	完整输入训练	4,840,670	0.5767 $\pm$ 0.0197	0.5582 $\pm$ 0.0127	0.6451 $\pm$ 0.0101	0.5784 $\pm$ 0.0070
LMF	完整输入训练	323,276	0.5616 $\pm$ 0.0054	0.5392 $\pm$ 0.0066	0.6630 $\pm$ 0.0123	0.5539 $\pm$ 0.0185
MFN	完整输入训练	261,764	0.5657 $\pm$ 0.0070	0.5532 $\pm$ 0.0081	0.6559 $\pm$ 0.0097	0.5540 $\pm$ 0.0092
MuT	完整输入训练	624,094	0.6000 $\pm$ 0.0209	0.5749 $\pm$ 0.0230	0.6309 $\pm$ 0.0189	0.6232 $\pm$ 0.0057
MISA	完整输入训练	1,118,852	0.6079 $\pm$ 0.0095	0.5958 $\pm$ 0.0080	0.9247 $\pm$ 0.1025	0.6198 $\pm$ 0.0077
Self-MM	完整输入训练	82,119	0.6302 $\pm$ 0.0016	0.6053 $\pm$ 0.0042	0.6131 $\pm$ 0.0068	0.6371 $\pm$ 0.0040
MMIM	完整输入训练	163,204	0.6302 $\pm$ 0.0041	0.6059 $\pm$ 0.0004	0.6135 $\pm$ 0.0101	0.6332 $\pm$ 0.0051
TFR-Net	缺失增强训练	415,620	0.6336 $\pm$ 0.0099	0.6154 $\pm$ 0.0098	0.6232 $\pm$ 0.0146	0.6220 $\pm$ 0.0143
MissModal	缺失增强训练	163,204	0.6260 $\pm$ 0.0096	0.6068 $\pm$ 0.0048	0.6111 $\pm$ 0.0112	0.6381 $\pm$ 0.0013
M3S	缺失增强训练	323,276	0.5733 $\pm$ 0.0056	0.5493 $\pm$ 0.0102	0.6620 $\pm$ 0.0071	0.5581 $\pm$ 0.0192
MMIN	缺失增强训练	292,164	0.6341 $\pm$ 0.0049	0.6072 $\pm$ 0.0039	0.6318 $\pm$ 0.0259	0.6346 $\pm$ 0.0037
LTARP	完整输入训练	164,343	0.6334 $\pm$ 0.0038	0.6163 $\pm$ 0.0013	0.6086 $\pm$ 0.0059	0.6417 $\pm$ 0.0024

参数规模进一步体现性能与复杂度的折中。LTARP 总参数量为 164343，约 16.4 万，明显小于 TFN、MuT 和 MISA 等结构，与 MMIM 和 MissModal 处于相近量级。在表 11–12 所列模型中，其完整输入和缺失平均宏平均 F1 均保持较高水平（图 14），较小规模仍保留了两类任务的有效表示。




图 14 公开多模态模型的参数规模与宏平均 F1 比较。(a) 完整输入验证集；(b) 54 种连续缺失场景平均。横轴为总参数量（对数尺度），误差线为三随机种子的样本标准差。

2.10 附件 3 预测

2.10.1 文本特征重构与核验

完成模型选择后，将 LTARP 用于附件 3 的 30 条无标签样本。附件 3 对齐版提供 text_bert、audio 和 vision，缺少预计算的 768 维 text，因此先以 bert-base-uncased 编码给定词元输入，重构 50×768 文本表示。

接口检查沿用 20 条同时具有词元输入与预计算文本表示的样本，对 604 个有效槽位逐行比较。重构行的最大余弦相似度位置均为同索引，特征最大绝对差为 3.0041×10^{-5} 、RMSE 为 8.3977×10^{-7} 。输入同一固定参数模型后，分类输出最大绝对差为 2.44×10^{-6} ，回归为 1.12×10^{-6} 。该检查连接重构文本表示与既有预测接口，随后按固定路径完成附件 3 推理。

2.10.2 预测结果汇总

30 条样本预测为消极、中性和积极的数量分别为 7、11 和 12，对应 23.33%、36.67% 和 40.00%。连续强度均值为 +0.123114、样本标准差为 0.611792，范围为 $[-1.642545, +1.539758]$ ；平均分类置信度为 0.624599。逐样本类别、强度和置信度见表 13，与独立 CSV 保存的同批结果对应。附件 3 不提供真实标签，因此本节仅报告预测结果，不计算 Accuracy、Macro-F1、MAE 等监督评价指标。

表 13 附件 3 全部 30 条无标签样本的最终预测

样本 ID	预测类别	连续情感强度	分类置信度
附件 3_01	消极	-0.405876	0.7460
附件 3_02	中性	-0.144469	0.6501
附件 3_03	中性	-0.128127	0.6101
附件 3_04	积极	+0.514640	0.6097
附件 3_05	消极	-1.642545	0.9405
附件 3_06	积极	+0.765383	0.7435
附件 3_07	中性	+0.249776	0.4401
附件 3_08	消极	-0.337494	0.5324
附件 3_09	积极	+1.076601	0.8747
附件 3_10	中性	-0.178815	0.7725
附件 3_11	中性	+0.010376	0.5348
附件 3_12	积极	+0.922382	0.6466
附件 3_13	积极	+0.237651	0.4991
附件 3_14	消极	-0.550781	0.7443
附件 3_15	积极	+0.684222	0.7227
附件 3_16	积极	+1.539758	0.9228
附件 3_17	消极	-0.589950	0.4977
附件 3_18	积极	+0.246677	0.4397
附件 3_19	消极	-0.320886	0.4778
附件 3_20	中性	-0.246796	0.6422
附件 3_21	积极	+0.667961	0.7211
附件 3_22	中性	+0.186271	0.4059
附件 3_23	中性	+0.138655	0.6286
附件 3_24	消极	-0.458430	0.5284
附件 3_25	中性	+0.048311	0.5231
附件 3_26	积极	+0.574989	0.7292
附件 3_27	积极	+0.567220	0.6708
附件 3_28	积极	+0.397136	0.4846
附件 3_29	中性	+0.071600	0.4322
附件 3_30	中性	-0.202034	0.5667

2.11 本问小结

本问从附件 2 的三模态对齐特征出发,以 MMP 建立简单的双任务基线,再通过 LTARP 内容加权残差分支补充不同时间位置的信息差异。第二阶段仅新增 883 个参数,沿用原有融合与输出路径,在相同结构下处理完整输入和连续缺失输入。

文本局部缺失的影响最明显,分类与回归对位置的响应有所不同。LTARP 相对基线在宏平均 F1、MAE 和 Pearson 上总体改善,同时保留小幅收益与初始化敏感性的边界;公开方法比较中也呈现较好的性能-规模折中,并完成附件 3 预测。下一问固定该预测模型,进一步分析不同模态及局部时间区域对模型输出的贡献。

参考文献

- [1] Zadeh A, Chen M, Poria S, et al. Tensor fusion network for multimodal sentiment analysis[C]//Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2017: 1103–1114.
- [2] Liu Z, Shen Y, Lakshminarasimhan V B, et al. Efficient low-rank multimodal fusion with

- modality-specific factors[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL). 2018: 2247–2256.
- [3] Zadeh A, Liang P P, Mazumder N, et al. Memory fusion network for multi-view sequential learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2018: 5634–5641.
- [4] Tsai Y H H, Bai S, Liang P P, et al. Multimodal transformer for unaligned multimodal language sequences[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL). 2019: 6558–6569.
- [5] Hazarika D, Zimmermann R, Poria S. MISA: Modality-invariant and -specific representations for multimodal sentiment analysis[C]//Proceedings of the 28th ACM International Conference on Multimedia (MM). 2020: 1122–1131.
- [6] Han W, Chen H, Poria S. Improving multimodal fusion with hierarchical mutual information maximization for multimodal sentiment analysis[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2021: 9180–9192.
- [7] Han W, Chen H, Gelbukh A, et al. Bi-bimodal information bottleneck for multimodal sentiment analysis[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2021: 9180–9192.
- [8] Yuan Z, Li W, Xu H, et al. Transformer-based feature reconstruction network for robust multimodal sentiment analysis[C]//Proceedings of the 29th ACM International Conference on Multimedia (MM). 2021: 4400–4408.
- [9] Yang D, Huang S, Kuang H, et al. Disentangled representation learning for multimodal emotion recognition with missing modalities[C]//Proceedings of the 30th ACM International Conference on Multimedia (MM). 2022: 4434–4443.
- [10] Wang Y, Shen Y, Liu Z, et al. Meta-mining multimodal missing states for incomplete multimodal learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 15422–15431.
- [11] Zhao J, Li R, Qin J. Missing modality imagination network for emotion recognition with uncertain missing modalities[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (ACL). 2021: 2608–2618.