

3 问题三：多模态情感预测的可解释分析与证据定位

3.1 问题分析与总体方案

问题二利用文本、语音和视觉特征建立了情感预测模型，能够输出情感类别和连续强度。问题三沿用这一已训练模型，以同一条样本的预测结果为起点，分析三种输入对结果的影响。

类别和强度给出了模型的输出，却没有显示各模态在预测中的作用。同一段话的文字内容、说话方式和画面特征可能提供不同线索；仅看最终类别，难以判断模型主要依赖哪种输入。局部输入也可能对结果产生较大影响，因此还需要定位关键区域，并检查其与原始资料的对应关系。

基于上述需求，问题三需要回答三个问题：（1）文本、语音和视觉中，哪个模态对当前预测影响最大，各自贡献多少？（2）多个模态共同输入时，是否产生额外的协同或削弱作用？（3）影响预测的关键输入位置在哪里？三个问题分别对应模态贡献、模态关系和关键区域。

问题三可转化为固定预测模型下的输入扰动分析。保持样本和模型参数不变，先改变参与预测的模态组合，观察类别与强度输出如何变化；再缩小到某一模态的对齐序列，逐段去除局部信息。前一步比较输入模态的作用，后一步寻找关键位置。两步共用问题二的模型，使解释结果与该样本的预测值对应。

本文按“模态贡献—模态交互—关键区域”的顺序展开。首先计算 Shapley 贡献值，确定各模态的贡献和主导模态（即对当前预测影响最大的模态）。其次比较共同输入与分别输入的效果，分析模态之间的增强或削弱关系。最后逐段遮挡主导模态的特征，找出关键输入位置。位置以特征对齐后的序列索引表示，其输入对应关系在第 3.6 节核对。所选区域还与随机等长区域比较，检验其对模型输出的影响。上述步骤组成多层次解释框架（Hierarchical Evidence Attribution Framework, HEAF），详见第 3.2—3.6 节。

三个层次依次回答不同问题。模态贡献确定重要输入模态；模态交互分析两路信息共同输入时的影响；连续窗口遮挡在重要模态中寻找关键区域。删除对照检验所选区域对模型输出的影响，来源回溯则把区域位置连接到现有数据记录。因此，该方法既能分析不同模态的整体贡献，也能定位单个样本中的关键区域。

三个问题的分析尺度不同，但都围绕同一条预测展开。模态贡献以三路输入为单位，确定各模态的作用；交互分析以两路输入的组合为单位，考察共同输入的效果；关键区域分析以对齐序列为单位，确定可核对的连续片段。这样的顺序先找到重要模态，再定位其中的具体位置。分类和连续强度分别作为解释目标，同一模态在两个目标下可以呈现不同作用。

方法选择依据。注意力权重显示模型关注的特征，输入扰动直接测量去除特征后的预测变化。本文计算八种模态组合的输出，再逐段遮挡特征，观察模型的响应。各步骤均使用同一个固定预测模型。本文关注不同输入信息在模型预测中的作用，不涉及情绪产生机制的因果分析。

图 16 按“输入—分析—输出”展示总体方案。问题二训练好的模型接收文本、语音和视觉特征，解释部分依次分析模态贡献、共同作用和关键区域。最终输出包括情感类别、情感强度、主要模态、贡献值及关键输入位置。贡献值的绝对值可归一化为相对比例，其正负方向仍由原值表示。删除实验检验所选区域的影响，来源核对说明这些区域对应的输入信息。

图 16 中，预测模型接收三种输入：50×768 的文本特征、50×74 的语音特征和 50×35 的视觉特征。模型输出类别概率与连续强度。第 3.2—3.6 节依次说明贡献计算、模态交互、关键区域定位、删除验证和来源核对，将预测结果逐步对应到重要模态及关键输入位置。

3.2 模态贡献分析

模态贡献分析以单条样本为对象。比较不同模态组合下的预测输出，可以估计文本、语音和视觉各自对当前结果的影响，并为后续局部定位选定分析对象。




图 16 问题三的预测与多层次解释流程。输入问题二的固定预测模型和三模态特征，分别分析模态贡献、模态交互与关键时间区域，输出情感类别、情感强度及相应解释。

3.2.1 Shapley 贡献值的计算依据

本文将文本、语音和视觉看作共同影响预测的三种输入模态。在 Shapley 计算中，它们相当于合作博弈中的三个参与者。任取若干模态输入模型，可得到相应组合的预测结果。再加入一个模态，前后的输出变化反映该模态在这一组合中的作用。由于已有输入不同，同一模态的作用也会变化，因此需要综合多种组合。

单模态预测结果只反映一路信息独立输入时的模型输出。某模态对完整预测的贡献，还取决于它与其他模态共同输入后的变化。如果两种模态提供相近信息，它们单独输入时都可能影响较大，联合输入后的增量则会改变。若两种模态互为补充，单独输入的作用可能较小，合用时才产生较大变化。当线索方向相反时，单独输入与联合输入的结果也会不同。因此，贡献计算需要覆盖多种模态组合。

模态的总体预测能力通常在一批样本上评价。本节关注单条样本，计算各模态对其当前预测的贡献。计算过程中始终使用问题二训练好的模型，只改变保留的输入模态。各组合在同一模型下比较，输出差反映不同输入组合对该条预测的影响。

“加入一个模态”的效果随已有输入而变化。例如，已有语音信息时，加入文本主要补充文字内容；视觉同时参与时，同一句文字还会与画面特征共同改变输出。单一加入顺序会影响计算结果。Shapley 贡献值汇总各种先后条件下的预测变化，使三种模态按照相同规则比较，也适用于它们相互关联的联合预测。

Shapley 贡献值对模态加入不同组合时的输出变化加权汇总。各模态贡献之和等于完整输入与空输入的预测差。作用相同的模态获得相同贡献，在所有组合中都不起作用的模态贡献为零。计算兼顾单独输入与联合输入，使共同作用按统一规则分配。

以文本为例，分别考察它加入空组合、仅有语音、仅有视觉以及同时具有语音和视觉的组合时，模型输出如何改变。四次比较的已有输入不同，文本的增量作用也不同。Shapley 贡献值按加入顺序对应的权重汇总这些变化，得到文本对该样本的贡献。语音和视觉按同样方式计算，三者使用同一预测目标和空输入基准。

本题只有三个模态，共有 $2^3 = 8$ 种组合。逐一计算即可得到 Shapley 贡献值。下一节的模态交互也使用这八种组合的输出。

完整枚举八种组合，可以省去随机采样近似，使贡献值由各组合的实际预测结果直接计算。每条样本采用相同的组合和遮挡方式。这样既能检查贡献的加和关系，也能保持样本间一致的计算口径。模态交互则直接复用这些组合输出，无须另设一套输入方案。

3.2.2 解释目标与计算步骤

令 $\mathcal{M} = \{T, A, V\}$, $S \subseteq \mathcal{M}$ 表示保留的模态集合。未保留模态只在有效位置清零，填充与原生零记录不变。分类解释固定完整输入时预测的类别 c^* ，以该类别相对其余类别的对数优势衡量各组合的输出：

$$v_c(S) = z_{c^*}(S) - \log \sum_{k \neq c^*} \exp z_k(S), \quad v_r(S) = \hat{y}(S). \quad (16)$$

空组合对应所有有效模态均被清零后的模型输出。对分类或回归目标分别计算 Shapley 贡献值：

$$\phi_m = \sum_{S \subseteq \mathcal{M} \setminus \{m\}} \frac{|S|!(2 - |S|)!}{3!} [v(S \cup \{m\}) - v(S)]. \quad (17)$$

实际计算时，先为同一条样本生成八种模态组合，再用固定模型取得各组合的分类与回归输出。随后按式 (17) 汇总每个模态加入前后的变化。分类目标始终是完整输入所预测的类别 c^* 。分类正贡献表示增强当前类别判断，负贡献表示削弱；回归贡献的正负分别表示连续强度增加或减少。

八种组合均以完整输入所预测的类别 c^* 为分类目标。这样，每次遮挡前后比较的都是同一类别相对于其余类别的对数优势，贡献值的方向便有一致含义。回归目标直接比较连续强度的数值变化。分类与回归分别计算，并分别报告各模态的作用。

分类对数优势表示当前类别相对其他类别的支持程度。遮挡某个模态后，预测类别即使未翻转，相对优势仍可能改变；这一数值变化也应计入贡献。连续强度直接使用预测值比较。两种输出的量纲不同，因此分别报告贡献值，并分别确定分类与回归的主导模态。

由此有 $\sum_m \phi_m = v(\mathcal{M}) - v(\emptyset)$ ，可用作计算完整性检查。分类贡献的单位是对数优势，回归贡献的单位是连续情感强度，两者不可直接混合排序。分类主导模态取最大正贡献；若三者均不为正，则取绝对贡献最大者并标明其非正性质。回归主导模态取绝对贡献最大者；并列时按文本、语音、视觉的固定顺序处理。下述时间分析遵循分类主导模态。

贡献值的绝对值表示影响幅度，符号表示作用方向。较大的正值说明该模态更强地支持当前类别，较大的负值说明它明显削弱这一判断。分类主导模态优先选最大正贡献，定位主要的支持信息。回归任务关注连续强度变化幅度，因此按绝对贡献选主导模态。两种选取规则对应不同目标，贡献值均按式 (17) 计算。

单条结果先确定完整输入的预测类别，再比较各模态贡献的大小和方向。主导模态给出最主要的支持信息，其他模态仍参与最终预测。例如，文本可以成为主导模态，视觉同时对当前类别给出负贡献。归一化比例便于比较影响大小，原贡献值保留方向和量纲。二者共同呈现三种模态的作用。

上述贡献以“所有有效模态清零”时的输出为比较基准。八种组合只改变原本有效的观测位置；分类和回归分别计算，以比较同一模态在两个任务中的作用。

3.3 模态交互分析

模态贡献给出各输入的单独影响，模态交互分析两种信息共同输入后的额外作用。以空组合为基准，若文本与视觉共同输入带来的变化超过两者单独作用之和，就表现为协同作用。

Shapley 贡献值将完整输入相对于空输入的变化分配给三种模态，用于比较各模态的影响。交互量则衡量两路信息共同输入时，模型输出偏离简单相加的程度。例如，文本和视觉分别支持某一类别，合用后还可能进一步提高该类别的对数优势。若两路信息相近或方向相反，联合变化也可能小于简单相加。交互分析据此区分协同与削弱。

计算一对模态的交互时，分别考虑第三个模态参与和不参与两种情况，并对结果取平均。三模态条件下共有文本-语音、文本-视觉和语音-视觉三对关系。对模态 i, j 及剩余模态 k ，令

$$I_{ij} = \frac{1}{2} \{v(\{i, j\}) - v(\{i\}) - v(\{j\}) + v(\emptyset) + v(\mathcal{M}) - v(\{i, k\}) - v(\{j, k\}) + v(\{k\})\}. \quad (18)$$

正交互表示两个模态共同输入的效果高于相应的简单相加结果，体现协同作用；负交互表示联合效果低于简单相加，体现削弱作用。分类和回归分别计算交互量。

式 (18) 同时包含第三模态参与和不参与时的比较。文本-视觉的交互由“有语音”和“无语音”两种条件共同确定，其他两对模态也按相同口径处理。交互的正负针对式 (16) 定义的模型输出。分类正交互表示两路信息合用后提高当前类别的相对优势；回归正交互表示连续强度高于简单相加的基准。

贡献值描述各模态对完整预测差的作用，交互量描述两种模态的共同影响。因此，贡献较大的模态与其他模态仍可能出现正交互或负交互。分类交互对应固定类别的对数优势，回归交互对应连续强度输出；两类目标分别计算。

在附件 2 验证集 728 条样本上，两种目标的二阶交互统计见表 11。分类目标中，文本-语音和语音-视觉的平均交互为负，文本-视觉为正；回归目标中，文本-语音为负，其余两对为正。符号描述的是固定模型在联合输入下相对简单相加结果的预测变化。

表 11 显示，交互方向与预测目标有关。文本-视觉在分类和回归目标上平均为正。语音-视觉在分类目标上平均为负，在回归目标上平均为正。文本-语音在两个目标上平均为负；符号比例同时显示，个别样本具有不同方向。验证集均值概括总体作用，单条预测仍按其自身的组合结果解释。

文本-视觉的分类交互平均为 +0.0781，正向符号比例为 60.3%。两路信息在多数验证样本中共同增强当前类别判断。文本-语音的分类交互平均为 -0.0706，负向符号比例为 69.4%，表现出相反的共同影响方向。文本即使占主导，与语音、视觉合用时仍可能产生不同的交互效果。

“主要符号比例”反映某种交互方向出现的频率。文本-视觉的分类交互平均为正，正向共同作用出现在 60.3% 的验证样本中。附件 4 样本 16 的文本-视觉交互为 -0.724，与平均方向相反。表 11 描述群体分布，逐条解释则保留每个样本自身的交互方向。

均值反映交互量的平均大小，符号比例反映该方向出现的频率。平均交互接近零时，结合符号比例可区分普遍较弱与正负作用相互抵消两种情况。表 11 同时给出这两个量，展示共同影响的大小和分布。附件 4 的交互由各样本的八种组合输出计算，保留了个体差异。

表 11 附件 2 验证集分类与回归解释目标的二阶模态交互 ($n = 728$)

解释目标	模态对	平均交互	主要符号比例	主要符号
分类	文本-语音	-0.0706	69.4%	负
	文本-视觉	+0.0781	60.3%	正
	语音-视觉	-0.0372	64.4%	负
回归	文本-语音	-0.1592	85.7%	负
	文本-视觉	+0.0503	65.4%	正
	语音-视觉	+0.0592	84.1%	正

3.4 连续窗口遮挡与关键位置定位

确定重要模态后，进一步寻找其中影响预测的具体区域。本文依次遮挡特征对齐后的连续位置，观察预测如何变化，并找出影响最大的区间。与注意力权重相比，遮挡结果直接反映去除局部信息前后的输出变化。计算时保持其他模态不变，只遮挡分类主导模态的有效特征。

选择连续区域，可以保留一段输入的前后关系。文本标记和音视频特征均按时间顺序排列，单个位置往往只包含片段信息。相邻位置共同变化时，用区间描述模型的响应更合适。遮挡后重新计算固定模型的输出，便可分析局部输入的作用；这一过程与模态贡献分析使用同一个输出目标。

3.4.1 连续窗口定位步骤

对分类主导模态，先根据有效长度 L_i 确定窗口长度 $w_i = \max(1, \text{round}(0.30L_i))$ 。窗口以步长 1 遍历有效序列。记 $g(\mathbf{x})$ 为式 (16) 的固定类别对数优势，则窗口 W 的遮挡效应为

$$D_i(W) = g(\mathbf{x}_i) - g(\mathbf{x}_i^{\setminus W}), \quad (19)$$

其中仅清零该模态在窗口 W 内的有效特征。若存在正效应，取 $D_i(W)$ 最大的窗口；否则取绝对效应最大的窗口并标注方向。平局时选择最早位置。覆盖某位置的窗口效应最大值形成 50 位局部曲线。图中的区间以从零开始的对齐特征槽位表示。回归结果同时报告有符号变化和绝对变化，以反映强度变化的方向与幅度。

式 (19) 的差值直接表明窗口的作用方向。遮挡后当前类别的对数优势下降， $D_i(W)$ 为正，说明该窗口原本支持这一类别；遮挡后优势上升，则说明它起抑制作用。两种方向都反映模型对局部输入的响应。若所有窗口均无正效应，记录绝对变化最大的区域，并标明抑制方向。

遮挡时只改变主导模态在窗口内的有效位置，其他模态和窗口外的位置保持原样。前后输出差因此对应同一连续区域。对齐后的 50 个槽位还包含填充或原生零记录，这些位置不参与有效窗口的选取。候选窗口按每条样本的有效长度生成，最终结果再用统一的对齐索引报告。

定位流程从分类主导模态的有效特征序列开始。先按有效长度确定窗口宽度，再从序列起点逐格移动窗口。每次清零窗口内的有效特征，计算固定类别对数优势的变化。遍历结束后，输出影响最大的窗口及其起止位置。若所有效应均非正，则输出绝对变化最大的窗口并注明方向。

窗口的起止点记录为 50 位对齐特征中的索引；第 3.6 节再核对这些索引能够对应到哪些输入来源。

窗口比例 0.30 在第 3.5 节的设计子集上确定。窗口太短，遮挡结果易受少量特征的波动影响；窗口太长，多个线索会同时被去除，定位范围也随之变宽。该比例兼顾连续片段的信息量和定位精度。窗口宽度按有效长度计算，使长短不同的序列采用同一比例；最终仍报告每条样本实际选中的对齐位置。

窗口比例固定后，所有样本按同一规则生成候选窗口。有效长度不同，窗口在 50 位对齐数组中的实际宽度也随之变化。附件 4 表 17 中的区间宽度因此不完全相同，分别对应各样本有效序列上的定位结果。

3.4.2 计算规模与复现条件

每条样本的 Shapley 贡献需要计算八种模态组合，三对模态交互直接复用这些结果。设主导模态的有效序列长度为 L_i ，连续窗口的候选数为 $L_i - w_i + 1$ 。局部定位因此需要约 $O(L_i)$ 次固定模型计算。随机窗口和分段删除用于后续验证，其计算次数由预设对照次数和删除比例确定。

上述方法只改变模型输入，不重新训练模型。空组合的清零方式、有效掩码、窗口比例、平局规则和分类目标均已固定，使同一样本的计算过程可以复现。在本题的三模态和 50 位对齐序列条件下，单样本计算规模可控。

3.5 删除实验与解释可靠性验证

问题三复用问题二的固定预测模型 (seed 42)，类别与强度的预测接口保持一致。模型在附件 2 验证集上的基础性能见表 12。中性类别 F1 为 0.467836、召回率为 0.434783，低于另外两类，是主要分类误差来源之一。本节通过删除实验，检验所选区域是否比随机区

域更明显地影响预测结果。

局部位先按遮挡效应选出一个窗口。删除验证再将该窗口与同一样本中随机选取的等长区域比较。两次遮挡使用相同模型和相同删除范围，输出差异对应位置变化。表 12 给出的分类与回归性能，则为解释实验提供预测性能背景。

表 12 Q3 固定预测模型在附件 2 验证集上的基础性能 (seed 42, $n = 728$)

Accuracy	Macro-F1	MAE	Pearson
0.648352	0.623435	0.608260	0.646170
消极 F1	中性 F1	积极 F1	中性召回率
0.689655	0.467836	0.712813	0.434783

时间窗口比例 0.30 在附件 2 验证集的设计子集上确定。按视频标识分组后，设计子集含 332 条片段、113 个视频标识；独立验证子集含 396 条片段、126 个视频标识，两组没有共同的视频标识。解释可靠性验证将所选窗口与 32 次随机抽取的等长窗口比较。同时按时间曲线删除 10%、20%、30%、40% 的有效位置，区间估计采用视频分组自助采样。

以视频为分组单位，是因为同一视频的片段可能共享说话人、场景和采集条件。设计子集确定窗口比例，独立验证子集报告干预结果，两组视频标识互不交叉。随机对照采用相同窗口长度，使比较聚焦于遮挡位置的差异；区间估计也按视频分组。

设计子集用于选取窗口比例，独立验证子集用于报告删除结果。随机窗口比较控制删除位置的数量，删除比例曲线展示去除位置逐步增加后的输出变化。两种比较分别检验局部窗口的作用和高影响位置的累积作用，共同评价关键区域的可靠性。

随机等长窗口提供了同一删除范围下的对照基准。不同删除比例的曲线记录高影响位置逐步去除时的模型响应。基础预测性能回答模型预测质量如何，窗口对照回答所选位置是否更重要，删除曲线回答这种影响是否随删除范围扩大而持续。三类结果共同支撑解释可靠性分析。

表 13 显示，在独立验证子集上，遮挡所选窗口使分类对数优势平均下降 0.482771；遮挡随机等长窗口时，平均下降 0.082036。两者相差 0.400735，视频分组自助采样的 95% 区间为 [0.3635, 0.4372]。以每条样本 32 次随机抽样的均值为对照，所选窗口效应更大的验证样本比例为 1.0。分类置信度下降差为 0.077718，类别 logit 下降差为 0.239688。回归输出的有符号变化差为 -0.018095 且区间跨零，绝对变化差为 0.103545。图 17 同时展示 728 条验证样本的主导模态分布和独立验证子集的删除曲线。

分类对数优势、分类置信度和类别 logit 采用不同数值尺度，三个指标却给出一致结果：所选窗口的删除效应大于随机等长窗口。分类对数优势下降差的 95% 区间完全位于零以上。在按视频分组的区间估计下，所选区域仍表现出明确的分类影响。

三个分类指标一致显示，删除所选区域比删除随机等长区域引起更明显的输出变化。所选区域因此是模型进行当前分类判断时的重要输入信息。回归结果呈现另一特点：有符号变化差的区间跨零，强度变化没有统一方向；绝对变化差为正，说明所选位置同样影响强度预测。

所选窗口的平均分类对数优势下降大于随机窗口，表明当前类别判断对这些局部输入更敏感。以每条样本的随机窗口均值为对照，所选窗口效应更大的比例为 1.0，比较方向在独立验证子集内保持一致。该比例受到最大效应窗口选择规则的影响；平均差、视频分组区间和删除曲线进一步给出作用大小与变化过程。

回归结果要同时观察变化方向和幅度。有符号差接近零且区间跨零，说明删除高影响位置后，情感强度没有统一的变化方向。绝对变化差为正，说明这些位置仍能明显改变连续输出。分类窗口按固定类别的对数优势选取，回归分析则考察连续强度，两种目标对同一区域表现出不同响应。

不同样本的强度预测会向正向或负向移动，直接平均时可能相互抵消；绝对变化保留

移动幅度。表 13 中，回归绝对变化的平均差及其区间均为正，有符号差的区间跨零。所选区域对强度数值有明确影响，方向则随样本变化。分别报告有符号变化和绝对变化，完整呈现连续预测的响应。

表 13 附件 2 独立验证子集的解释干预一致性结果（396 条片段；按视频分组的 95% 自助采样区间）

输出量	所选窗口	随机等长窗口	平均差	95% 区间
分类对数优势下降	0.482771	0.082036	0.400735	[0.3635, 0.4372]
分类置信度下降	0.093286	0.015567	0.077718	[0.0712, 0.0843]
分类 logit 下降	0.292982	0.053294	0.239688	[0.2195, 0.2603]
回归有符号变化	0.002082	0.020177	−0.018095	[−0.0526, 0.0141]
回归绝对变化	0.202760	0.099215	0.103545	[0.0883, 0.1203]




图 17 验证集的主导模态与删除干预结果。（A）728 条样本的分类/回归主导模态计数；（B）独立验证子集的删除比例曲线及视频分组 95% 区间；（C）所选窗口与随机窗口的配对变化。

图 17 分三部分展示验证结果。面板 (A) 统计 728 条样本的分类与回归主导模态，面板 (B) 给出 396 条独立验证片段的删除比例曲线，面板 (C) 比较所选窗口与随机等长窗口。删除 10%、20%、30%、40% 有效位置时，两者的平均分类边际下降差分别为 0.108296、0.237758、0.418076 和 0.465465。所选位置在各比例下均引起更大的分类输出变化。

随着删除比例增加，所选位置与随机位置的平均差扩大。高影响位置在较大遮挡范围内仍持续影响分类输出。删除曲线给出逐步去除特征的总体趋势，单窗口比较则呈现连续区域的局部作用。面板 (A) 还显示，分类与回归任务及不同样本依赖的主要模态存在差异。

删除比例从 10% 增加到 40% 时，固定预测模型和验证子集保持一致。实验依次比较按局部效应排序的位置与随机位置。随着更多高影响位置被去除，两类位置的分类输出差

异持续存在。删除比例曲线与单窗口对照相互补充，表明关键区域定位具有稳定的模型响应。

关键窗口按候选窗口中的最大影响值选取，与随机窗口的差异因此包含选择效应。删除实验表明，所选区域是固定模型的输出敏感位置。表 14 进一步给出独立验证子集上的跨种子结果：主导模态与贡献排序总体一致，关键区间的位置波动更明显。

表 14 中，两组种子对的分类主导模态一致率分别为 0.869 和 0.831，关键区间 IoU 分别为 0.579 和 0.527。不同随机初始化下，模型仍保持较稳定的重要输入模态，具体区间边界则更易变化。回归结果报告主导模态与贡献排序的稳定性；区间定位按分类目标定义。

两种稳定性指标对应不同的解释尺度。主导模态比较三种模态的贡献大小；关键区间要在同一模态的多个连续窗口中选择最大效应位置。若几个窗口效应接近，模型初始化引起的小幅变化就可能改变区间边界，而模态排序仍保持不变。这与表 14 中模态层较稳、区间层波动更大的结果一致。逐条解释同时报告主导模态和具体窗口，分别呈现重要输入模态与局部关键位置。

表 14 附件 2 独立验证子集的跨种子解释稳定性（seed 42 分别与 43、44 比较； $n = 396$ ）

解释目标	种子对	主导模态一致率	Shapley 排序相关	关键区间 IoU
分类	42/43	0.869	0.818	0.579
	42/44	0.831	0.783	0.527
回归	42/43	0.778	0.745	—
	42/44	0.783	0.760	—

分类排序相关仅统计两种子预测类别一致的样本；区间定位按分类目标定义，回归未单独定义关键区间。

3.6 关键位置的证据来源核对

模态贡献指出重要输入模态，窗口遮挡给出对齐序列中的关键位置。局部解释（针对单条样本寻找影响区域）还需把特征索引对应到实际输入。本文沿问题一保留的对齐记录查找对应关系：文本回到可阅读的原句，语音和视觉回到未对齐特征。两类记录能确认的位置精度不同，因此分别报告。

文本采用“对齐特征槽位 $\rightarrow$ BERT 标记 $\rightarrow$ 原文字符区间”的对应关系。附件 4 的 20 条样本共有 604 个有效文本槽位，同索引余弦相似度的最大值均位于对应行。平均同索引余弦为 0.999999994，最大绝对特征差为 3.0041×10^{-5} ，重构均方根误差为 8.3977×10^{-7} 。这些结果验证了关键文本位置与原文片段的稳定对应，为字符级解释提供了依据。

文本位置的核对分两步进行。先检查对齐特征与相应标记特征的匹配情况，再利用保存的字符跨度，把对齐位置转换为原文中的连续片段。样本 14 的关键区间由此对应到实际文字，给出可以阅读和复查的关键片段。

对齐槽位、标记和字符跨度构成逐级对应关系。特征匹配确认位置关系，字符跨度给出原文中的具体片段。附件 4 表中的文本关键区间因此能够对应到模型实际接收的文字内容，形成字符级结果。

语音与视觉采用“对齐特征槽位 $\rightarrow$ 未对齐特征行”的对应关系。附件 4 中，564/564 个非零音频对齐行和 534/534 个非零视觉对齐行，均能在对应样本的未对齐特征数组中找到唯一且逐元素相等的行。这一结果验证了两种模态的特征行对应关系，关键区间可报告相应索引。

逐行匹配覆盖了附件 4 中所有非零音频和视觉对齐行。关键区域落在这些位置时，可沿索引关系找到未对齐数组中的对应行。样本 02 及附件 4 其他音视频位置均按这一规则核对。文本使用字符跨度，音视频使用特征行索引，报告精度与各自保存的数据记录一致。

逐元素相等为音视频特征的来源提供了直接依据：选中某个对齐位置后，可以在对应样本的未对齐数组中找到同一行特征。因此，样本 02 的视觉结果以特征行 36–41 表示。现有记录定位到特征行；图 18 中的视频画面仅作场景示意，不承担精确时间定位的作用。

文本与音视频的报告精度取决于各自保存的对应记录。三种模态先按相同遮挡规则确定对齐位置。随后，文本通过字符跨度回到原句，语音和视觉通过逐行特征匹配回到未对齐数组。关键位置因此都有对应的输入记录，便于逐条核查。

3.7 附件 4 预测解释结果

采用第 3.2—3.6 节的方法，本文对附件 4 的 20 条对齐样本逐条给出预测及解释。表 15 汇总预测类别、主导模态和对应的输入记录。表 16 列出全部预测，表 17 列出三模态分类贡献及关键区间。附件 4 没有真实标签，本节分析模型输出的分布及其影响因素。

每条样本的解释都与其情感类别、连续强度对应。解释结果同时给出三模态贡献、主导模态、关键区间和可核对的输入记录，从而展示单条预测依赖的重要输入信息及其具体位置。

表 15 中，三种预测类别都在 20 条样本中出现。表 16 列出每条样本的类别、强度和置信度，表 17 给出相应的主要模态与关键区间。三张表按“预测结果—模态贡献—输入位置”的顺序组织，展示各条无标签样本的输出及解释。

表 15 附件 4 的无标签预测及解释摘要（共 20 条样本）

统计项	类别或状态	数量	比例
预测情感类别	消极	7	35%
	中性	5	25%
	积极	8	40%
分类主导模态	文本	19	95%
	语音	0	0%
	视觉	1	5%
回归主导模态	文本	18	90%
	语音	0	0%
	视觉	2	10%
分类主导证据层级	原文字符级	19	95%
	未对齐特征行级	1	5%

表 16 附件 4 全部 20 条无标签样本的预测结果

样本 ID	预测类别	情感强度	分类置信度
01	中性	+0.177915	0.5359
02	消极	-0.027301	0.3898
03	中性	-0.064430	0.5441
04	消极	-0.398096	0.6741
05	积极	+0.886586	0.7131
06	积极	+0.759221	0.7287
07	积极	+0.799232	0.7699
08	积极	+0.678992	0.7512
09	消极	-1.987819	0.9671
10	消极	-1.556107	0.9453
11	消极	-0.965641	0.8577
12	消极	-0.981858	0.8488
13	中性	+0.173788	0.5675
14	中性	+0.154869	0.5568
15	积极	+1.267568	0.8941
16	消极	-2.030377	0.9670
17	积极	+1.656759	0.9493
18	中性	-0.158624	0.5781
19	积极	+0.276115	0.3840
20	积极	+0.875848	0.8013

表 17 附件 4 全部 20 条样本的分类贡献与证据层级；区间为从零开始的对齐特征槽位 $[a, b)$

ID	ϕ_T	ϕ_A	ϕ_V	主导模态	关键区间	证据层级
01	+0.4448	+0.0283	+0.0097	文本	[17, 24)	原文字符级
02	-0.1971	+0.2277	+0.8294	视觉	[1, 7)	特征行级
03	+0.6919	-0.1267	-0.0492	文本	[0, 10)	原文字符级
04	+1.9249	+0.1198	-0.0096	文本	[20, 28)	原文字符级
05	+1.1092	-0.3336	+0.6619	文本	[0, 5)	原文字符级
06	+2.2790	-0.2529	-0.5109	文本	[14, 25)	原文字符级
07	+1.6925	-0.3365	+0.3790	文本	[13, 28)	原文字符级
08	+2.4908	-0.2620	-0.5967	文本	[8, 12)	原文字符级
09	+4.0872	+0.4352	+0.1656	文本	[2, 8)	原文字符级
10	+3.6626	+0.4324	+0.0621	文本	[21, 31)	原文字符级
11	+2.0970	+0.2465	+0.7610	文本	[1, 6)	原文字符级
12	+2.1874	-0.0032	+0.8495	文本	[31, 44)	原文字符级
13	+0.5928	+0.0180	+0.0000	文本	[0, 10)	原文字符级
14	+1.5361	+0.0546	-1.0233	文本	[1, 12)	原文字符级
15	+2.9847	-0.3149	-0.0090	文本	[14, 21)	原文字符级
16	+3.8314	+0.4557	+0.3986	文本	[8, 12)	原文字符级
17	+3.4202	-0.1421	+0.1781	文本	[9, 17)	原文字符级
18	+0.8431	-0.0933	-0.0955	文本	[6, 21)	原文字符级
19	+0.6310	-0.4071	-0.1692	文本	[29, 41)	原文字符级
20	+2.0873	-0.2851	+0.1195	文本	[0, 14)	原文字符级

分类与回归的主导模态在 17 条样本上相同，占 85%。19 条文本主导样本对应原文字

符级证据；一条视觉主导样本对应未对齐特征行级证据。表中的 ϕ 均为分类对数优势目标的 Shapley 贡献。

表 15 显示，分类预测大多由文本主导，也存在视觉主导的样本。分类与回归的主导模态并非完全一致，因此模态贡献按样本和预测目标分别计算。表 17 保留贡献值的正负方向，呈现各模态对当前类别的增强或削弱作用。

表 16 的类别和强度共同描述模型输出。例如，样本 09 和 16 都被预测为消极，其连续强度分别为 -1.987819 和 -2.030377 ；样本 02 同样被预测为消极，但强度仅为 -0.027301 ，分类置信度为 0.3898 。同一类别下的强度和置信度存在明显差异，因此逐条解释同时保留类别与连续输出，并分别阅读两个目标下的模态贡献。

附件 4 的关键区间既有序列前部，也有中后部。例如，样本 05 的文本区间为 $[0, 5)$ ，样本 12 为 $[31, 44)$ ，样本 19 为 $[29, 41)$ 。这些区间均记录各样本在对齐特征序列中的位置。通过来源回溯，模态贡献结果进一步对应到模型实际利用的文本片段。

文本在分类目标上主导 19 条样本，在回归目标上主导 18 条样本。语音没有成为这批样本的主导模态，视觉则出现在少数个例中。固定模型在附件 4 上主要使用文本输入，样本 02 呈现视觉主导的不同情况。表中的正负贡献还显示，非主导模态也会增强或削弱当前类别，逐条结果比总体分布更具体。

对照表 16 与表 17 可见，文本主导分布于消极、中性和积极三类预测，覆盖了不同的情感判断。附件 4 中的文本优势体现为模型对这一路信息的普遍使用；具体类别仍随样本内容以及三模态共同作用而变化。视觉主导的样本 02 则展示了总体分布之外的个体差异。

分类与回归主导模态在 17 条样本上一致，表明两种输出通常依赖相同的主要输入模态。其余样本体现了类别判断与强度预测的差异，因此两个目标分别给出模态贡献。附件 4 以无标签预测及解释形式交付，本节据此分析模型输出及样本间的重要输入信息。

3.8 典型样本分析

图 18 展示两条按既定规则选取的案例。样本 14 由文本主导，预测类别为中性，连续强度为 $+0.154869$ 。三模态分类贡献分别为 $\phi_T = +1.536072$ 、 $\phi_A = +0.054570$ 、 $\phi_V = -1.023311$ 。关键特征区间 $[1, 12)$ 对应原文字符区间 $[0, 38)$ ，文本片段为 “He is the co-founder of Rossen and Vet”。

样本 14 的文本正贡献明显大于语音，视觉贡献为负，文本因此成为分类主导模态。相对于空输入基准，文本增强了 “中性” 判断，视觉则削弱这一判断。连续窗口比较选出 $[1, 12)$ ，这是文本序列中影响当前输出最大的区域。该区域对应原文字符区间 $[0, 38)$ ，内容以身份介绍为主。贡献值和窗口结果共同表明，这段文字是当前分类的重要输入信息。

“文本贡献最大” 还可落实到原句。完整输入得到中性预测，文本提供主要的正向支持。关键窗口对应身份介绍片段，是文本序列中影响这一判断最大的连续区域。贡献数值、窗口范围和原文内容相互对应，验证了关键位置与模型输入的关系。视觉的负贡献显示，这条预测包含方向不同的模态作用。

三模态贡献在样本 14 上方向不同：文本提供主要正贡献，语音贡献较小，视觉与当前类别判断方向相反。连续窗口分析再指出文本序列中的关键区间，字符跨度把区间对应到原句。该案例由此展示了从模态贡献到关键片段的逐步分析，解释结果既有数值，也有实际文字。

样本 02 由视觉主导，预测类别为消极，连续强度为 -0.027301 。分类贡献分别为 $\phi_T = -0.197115$ 、 $\phi_A = +0.227718$ 、 $\phi_V = +0.829375$ 。视觉关键区间 $[1, 7)$ 包含从零开始的对齐槽位 1–6，逐行对应未对齐视觉特征行 36–41。图中的视频画面仅作场景示意。两个案例共同展示模态贡献、关键位置和输入对应关系。

样本 02 的视觉正贡献最大，最明显地增强了模型对 “消极” 类别的判断；文本负贡献削弱了这一判断。连续窗口实验在视觉有效序列中选出 $[1, 7)$ ，将重要模态进一步定位到具体位置。来源记录把这一区间对应到未对齐视觉特征行 36–41，确认了视觉输入中的关键区域。

样本 02 的分类置信度为 0.3898 ，连续强度为 -0.027301 ，与同属消极预测的样本 09、

16 相比，输出强度明显不同。三模态贡献说明这一预测的输入作用：视觉贡献最大，语音同向支持，文本产生反向影响。关键视觉区间进一步缩小了分析范围，为视觉主导的结果提供了明确的特征位置。

语音的分类贡献为正，与视觉同向，但数值小于视觉。文本贡献为负，与当前“消极”判断方向相反。三路输入的作用方向各异，视觉仍是模型进行分类的重要输入模态。对齐槽位 1-6 与未对齐视觉行 36-41 逐行对应，使关键区域能够在已有特征文件中复查。

两个案例均从预测类别出发，先确定重要模态，再定位关键区域。文本位置进一步对应到原文字符，视觉位置对应到特征行。两种模态的输入记录提供了不同精度的对应结果。

两条样本的主要输入模态不同：样本 14 预测为中性，文本贡献最大；样本 02 预测为消极，视觉贡献最大。主导模态均由八种组合下的输出变化确定，局部窗口再定位其中的关键区域。字符片段和视觉特征行分别对应两条样本的预测，显示了同一方法在不同输入上的解释结果。




图 18 附件 4 两条典型样本的多层次解释。（A）样本 14 的文本关键时间位置映射至原文字符区间；（B）样本 02 的视觉关键时间位置 1-6 映射至未对齐视觉特征行 36-41。视频画面为“视频上下文示意”。

上述两个案例采用同一分析流程，均复用问题二训练好的情感预测模型。改变输入并重新计算输出后，依次得到模态贡献、模态交互和关键区域，无需增加训练步骤。对单条样本，八种模态组合用于贡献计算，三对交互分析共同输入的作用，连续窗口把位置缩小到对齐序列中的一段区域。贡献和交互分别对应情感类别与连续强度，局部窗口按分类目标定位。由整体模态到局部片段，形成了针对单条样本的解释过程。

三模态条件下，组合输出可以完整枚举，交互分析复用同一批结果。局部遮挡的候选数随有效序列长度线性增加，单样本计算规模可控。分类目标、清零范围和窗口选择规则

固定后，贡献值、交互量及关键区间都能通过模型输入与输出重新计算。表格保留类别和强度结果，案例展示具体的输入对应关系，使总体统计与单样本解释能够相互对照。

解释结果经过三类检查。所选窗口与随机等长窗口比较，检验关键区域对模型输出的影响；跨种子比较，考察主导模态和区间的稳定性；来源回溯，确认局部索引对应的输入记录。表 13 给出删除结果，表 14 给出稳定性，第 3.6 节给出输入对应关系。这些结果共同支撑附件 4 的逐条解释。

解释结果依赖问题二的预测模型，需要结合基础性能分析。表 12 中，中性类别的 F1 和召回率低于另外两类。对中性样本，类别、置信度和模态贡献应一并考察。附件 4 没有真实标签，逐条结果展示的是模型预测及其重要输入信息；附件 2 的验证指标则反映模型对有标签样本的预测性能。

关键位置的精度由数据记录和模型稳定性共同决定。文本对齐位置已经核对到原文字符，语音和视觉核对到未对齐特征行，三种模态据此报告不同精度的位置。跨种子比较中，主导模态的一致性高于关键区间的重合程度，说明窗口边界比模态排序更易随模型变化。逐条解释先给出模态贡献和交互，再报告关键位置及其输入对应关系。

解释结果按计算顺序呈现。模态贡献和交互用数值说明三路输入的作用方向与相对大小，局部窗口给出可复查的索引区间，来源回溯把区间对应到原文片段或特征行。模态、位置和原始记录依次衔接，呈现模型使用的重要输入信息。各步结果都有相应表格或案例，可据此核对。

删除对照显示模型对关键区域的响应，跨种子比较显示主要输入模态保持较稳定的结果，来源回溯给出可核查的原文或特征行。三类检验与 Shapley 贡献、模态交互相配合，使每条预测沿“模态贡献—关键位置—输入记录”逐步展开。情感类别和连续强度分别报告预测值与解释结果，构成问题三的预测解释与验证结果。

Shapley 贡献值确定影响最大的模态，模态交互量分析共同输入的额外作用，连续窗口遮挡定位关键区域。文本位置进一步对应到原文字符，语音和视觉位置对应到未对齐特征行。独立验证子集的删除实验表明，所选区域是固定模型进行当前分类判断的重要输入信息。附件 4 的 20 条无标签样本均给出了预测结果、模态贡献与关键位置。