

华为杯第二十三届中国研究生数学建模竞赛

论文题目（待定）

摘要：摘要将在全文模型与结果确定后撰写。

关键词：待定

问题重述

本题要求在复杂场景下形成从多模态观测到情感预测、再到可核验证据的分析链。问题一针对附件 1 的原始媒体，分别提取文本、语音和视觉特征，将不同采样粒度的观测映射到公共时间轴，并保留每个有效位置的来源。问题二使用附件 2 已提供的对齐数值特征，预测三类情感及连续情感强度，重点考察局部连续时间段缺失时的性能。问题三在确定的预测模型上分析模态贡献、模态交互和关键特征区间，并对附件 4 的无标签样本给出预测与解释。

三个问题在时间位置、有效掩码和证据可追溯性方面相互衔接，但各自使用的官方附件不同。问题一构建的附件 1 特征并未替代问题二的附件 2 输入；问题三的附件 4 推理也不提供有标签性能评价。本文据此分别报告特征构建的完整性、附件 2 验证集上的预测与缺失场景表现，以及附件 4 上的解释结果。

基本假设

1. 原始媒体的呈现时间、音频采样位置和视频解码时间可作为问题一对齐的共同时间基准；无法获得可靠时间支持的位置由掩码标记。
2. 附件 2 与附件 4 的对齐特征已完成数值预计算。其有效序列位置由附带的文本有效位字段确定，不能仅凭某一模态的零向量判定填充或人为缺失。
3. 人工缺失只作用于原本有效的连续位置；原生零值保留为观测内容或数据质量状态，不自动解释为人工缺失。
4. 附件 4 无真实情感标签，因而其预测分布和解释卡不用于计算分类准确率、宏平均 F1 值、平均绝对误差或相关系数。

符号说明

符号	含义
$m \in \{T, A, V\}$	文本、语音、视觉模态； $\mathcal{M} = \{T, A, V\}$ 。
L_i, p_{it}	样本 i 的有效序列长度及位置 t 的有效位掩码。
$\mathbf{x}_{it}^{(m)}$	样本 i 在模态 m 、位置 t 的数值特征。
ρ, ℓ_i	连续缺失比例及对应的有效位置遮挡长度。
y_i^c, y_i^r	三分类标签及连续情感强度标签。
$\hat{\mathbf{z}}_i, \hat{y}_i^r$	分类输出向量及回归预测值。
$v(S), \phi_m, I_{mn}$	模态联盟 S 的预测目标值、模态贡献及模态对交互量。

1 问题一：多模态特征提取与时序对齐

1.1 问题分析与总体方案

问题一要求从原始视频构造能够逐时刻比较的文本、语音和视觉表示。三种模态的原生采样粒度不同，序列下标因而缺少直接的时间对应关系；部分片段的官方转写与当前视频实际语音也存在差异。本文先分别构造带时间支持区间的三模态原生特征，再按照真实媒体时间映射至公共时间窗，并为每个有效位置保留来源索引。整体流程如图 1 所示。

该流程以附件 1 中的原始视频为唯一媒体输入。文本、音频和视频先各自形成“特征向量—媒体时间区间”序列，再投影到同一时间基准下的 50 个时间窗。对每个模态和时间窗，最大时间重叠硬对齐只选取与目标窗具有正交叠且交叠最长的一个原生特征；未覆盖位置由掩码标记，并保留来源追踪信息。




图 1 问题一的三模态特征构建与最大时间重叠对齐框架。文本、语音和视觉原生特征分别关联媒体时间区间，再映射至统一时间窗；图中高亮时间窗用于示意映射规则。

1.2 原始数据预处理与时间基准构建

对附件 1 的 100 条视频核验样本标识与标签对应关系，并读取媒体时长、音轨及解码帧时间。另由 MP4 提取 16 kHz 单声道 WAV；音频支持区间按 WAV 样本位置换算，视觉按固定时间间隔采样，并以真实帧显示时间定位，原始视频保持不变。

记第 i 个样本相对于媒体呈现起点的有效时长为 T_i ，其统一时间域定义为

$$\mathcal{T}_i = [0, T_i]. \quad (1)$$

后续文本时间区间、音频帧支持区间和视觉帧支持区间均以秒表示，并相对于该样本的媒体起点。视觉特征的支持区间由相邻采样帧的真实显示时间构造。由此，不同采样频率下的特征均可在同一时间坐标中进行比较。

1.3 三模态原生特征提取

每种模态先独立提取时间有序的原生向量。文本和音频以其语义或声学帧区间为时间支持，视觉向量则关联到实际采样帧及其显示时间。下文记模态 m 的第 j 个原生向量为 $\mathbf{h}_{ij}^{(m)}$ ，其时间支持为 $I_{ij}^{(m)}$ 。

1.3.1 文本特征提取

文本特征中，75 条样本使用官方文本，并匹配同一样本的 Whisper 识别时间信息；25 条样本使用当前媒体的识别文本及其时间信息。Whisper large-v3-turbo 提供识别片段和词级时间戳 [1]。官方文本在特征元数据中原样保留，文本来源与时间来源分别记录。

原始审计记录包含 46 个需要从词级时间回退至所属识别片段时间的区间，其中 21 个实际参与最终文本特征映射。回退后的片段时间提供较粗粒度的支持范围。对选定文本片段使用 RoBERTa-base 提取语义向量 [2]，并保存其文本来源、时间支持、特征索引和模型

信息。第 j 个文本特征写为

$$\mathbf{h}_{ij}^{(T)} \in \mathbb{R}^{768}, \quad I_{ij}^{(T)} = [s_{ij}^{(T)}, e_{ij}^{(T)}]. \quad (2)$$

1.3.2 语音特征提取

语音输入为 16 kHz 单声道 WAV，使用 WavLM-base-plus 生成逐帧声学表示 [3]。每个输出向量关联到原始 WAV 中对应的样本支持区间；该区间经采样率换算到视频相对时间，并随特征索引一并保存。因此，语音序列不仅保留向量顺序，还能回溯到 WAV 样本范围和 MP4 时间。

$$\mathbf{h}_{ij}^{(A)} \in \mathbb{R}^{768}, \quad I_{ij}^{(A)} = [s_{ij}^{(A)}, e_{ij}^{(A)}]. \quad (3)$$

1.3.3 视觉特征提取

视觉特征采用 SigLIP2-base-patch16-224 提取 [4]。固定采样策略在每秒 4 帧的时间网格上选取观测帧，再以 MP4 解码得到的真实帧显示时间戳确定采样位置。相邻采样时刻用于构造每帧的支持区间，使视觉向量保留到源视频帧索引及呈现时间的对应关系。视觉原生特征表示为

$$\mathbf{h}_{ij}^{(V)} \in \mathbb{R}^{768}, \quad I_{ij}^{(V)} = [s_{ij}^{(V)}, e_{ij}^{(V)}]. \quad (4)$$

因此，三种模态均表示为按时间排序的向量与半开支持区间对，为后续按时间交叠进行映射提供共同输入形式。

1.4 基于最大时间重叠的跨模态时序对齐模型

将样本 i 的有效时长 T_i 均分为 $K = 50$ 个半开时间窗：

$$B_{ik} = \left[\frac{kT_i}{K}, \frac{(k+1)T_i}{K} \right), \quad k = 0, 1, \dots, K-1. \quad (5)$$

记 $b_{ik} = kT_i/K$ 为第 k 个时间窗的起点。模态 $m \in \{T, A, V\}$ 的第 j 个原生特征时间支持为

$$I_{ij}^{(m)} = [s_{ij}^{(m)}, e_{ij}^{(m)}]. \quad (6)$$

该区间与公共时间窗的交叠时长定义为

$$\omega_{ijk}^{(m)} = \max\left(0, \min(e_{ij}^{(m)}, b_{i,k+1}) - \max(s_{ij}^{(m)}, b_{ik})\right). \quad (7)$$

当存在正交叠时，最大时间重叠硬对齐选取交叠时长最大的原生特征索引：

$$j_{ik}^{(m)} = \arg \max_j \omega_{ijk}^{(m)}, \quad \omega_{i,j_{ik}^{(m)},k}^{(m)} > 0. \quad (8)$$

选中后，统一位置直接继承该原生特征：

$$\mathbf{z}_{ik}^{(m)} = \mathbf{h}_{i,j_{ik}^{(m)}}^{(m)}, \quad M_{ik}^{(m)} = 1. \quad (9)$$

若不存在正交叠，则令 $\mathbf{z}_{ik}^{(m)} = \mathbf{0}$ 且 $M_{ik}^{(m)} = 0$ 。此时零向量仅表示该位置没有有效映射，是否有效由掩码 $M_{ik}^{(m)}$ 区分。于是单个样本的模态张量及全体样本张量分别为

$$\mathbf{Z}_i^{(m)} \in \mathbb{R}^{50 \times d_m}, \quad \mathcal{Z}^{(m)} \in \mathbb{R}^{100 \times 50 \times d_m}, \quad d_T = d_A = d_V = 768. \quad (10)$$

每个有效对齐位置还保存样本标识、统一时间窗索引、原生特征索引及源时间区间，构成从统一序列位置回溯至原始媒体的来源追踪链。

图 2 进一步展开原生时间轴与统一时间窗之间的对应关系。不同模态的特征间隔和数量可以不同；对齐依据媒体时间区间的交叠，不依据各模态序列中的相同下标。图中未获得有效映射的位置由掩码区分，避免将空缺位置解释为真实观测。




图 2 三模态原生时间轴到公共时间窗的映射示意。文本片段、音频帧和视觉采样帧首先关联各自的媒体时间；统一时间窗根据正时间交叠选择原生特征，并记录有效位与来源。图中热图及采样间隔只用于展示时间粒度差异，不代表本文实际特征值或采样率。

1.5 特征构建结果与完整性检验

最终处理流程覆盖 100 条样本，三种模态均形成维数为 768 的原生向量，并映射至长度为 50 的公共序列。表 1 汇总各模态的原生特征数、单样本对齐形状和平均有效时间覆盖率。文本覆盖率低于音频和视觉，反映部分时间窗缺少文本片段的时间支持；这些位置由掩码标记为空缺。

表 1 三模态特征构建与时间覆盖结果

模态	特征提取方法	原生特征数	特征维数	单样本	
				对齐形状	平均时间覆盖率
文本	RoBERTa-base	1847	768	50×768	0.8242
语音	WavLM-base-plus	38776	768	50×768	0.9910
视觉	SigLIP2-B/16	3205	768	50×768	1.0000

完整性检查基于完整性检验清单及来源追踪记录，覆盖样本处理状态、特征形状、有限值、有效映射比例和时间来源可回溯性。三模态输出均可由统一时间窗回溯到对应的原生特征及源媒体时间信息。图 3 展示样本 -a55Q6RWvTA__3 的一个具体时间窗及其原生来源。




图 3 典型样本的三模态时间映射与来源追踪。阴影表示第 24 个统一时间窗，局部图放大其源时间位置。

1.6 对齐方案与特征有效性分析

为比较不同时间映射和模态组合的情感信息保留情况，采用统一的轻量下游评价模型及重复分层五折划分。分类任务报告准确率和宏平均 F1 值；连续预测报告平均绝对误差 (MAE) 和皮尔逊相关系数。该评价仅用于比较不同特征构建与时间对齐方案的信息保持能力，不作为独立泛化性能或统计显著性结论。

1.6.1 时序对齐方法比较

比较最大时间重叠法、最近中心法和重叠加权平均法。表 2 与附录图 A1 给出四项辅助评价指标在固定设置下的结果。三种方法的均值整体接近；最近中心法在部分指标上的均值略高，但在 152 个有效文本时间窗中选择了与目标窗没有正时间交叠的特征。重叠加权平均法未在四项指标上呈现一致优势。

本文采用最大时间重叠硬对齐。该方法以原生区间与公共时间窗的真实交叠确定映射，在每个有效位置保留唯一来源索引，满足时间对应与来源追踪要求。

表 2 不同时序对齐方法的定量比较

对齐方法	准确率	宏平均 F1 值	平均绝对误差 (MAE)	皮尔逊相关系数
最大时间重叠法	0.6129 ± 0.0938	0.4816 ± 0.0850	0.5258 ± 0.0966	0.5419 ± 0.1470
最近中心法	0.6148 ± 0.0913	0.4832 ± 0.0849	0.5210 ± 0.0967	0.5535 ± 0.1492
重叠加权平均法	0.6074 ± 0.0945	0.4712 ± 0.0868	0.5237 ± 0.0977	0.5482 ± 0.1506

注：最近中心法有 152 个有效文本时间窗选择了与目标时间窗零交叠的特征。

1.6.2 视觉特征提取方法比较

视觉骨干比较仅改变图像编码器，采样帧及时间映射保持一致。两种方案均产生 3205 条视觉原生特征，并具有相同的来源追踪结构。表 3 显示，在当前轻量评价设置下，SigLIP2 的四项指标均值均较 DINOv3 有利，且其特征提取用时更短，因此选用 SigLIP2。DINOv3 的自监督视觉表示作为单变量对照 [5]。

表 3 不同视觉特征提取方法的比较

视觉编码器	准确率	宏平均 F1	MAE	皮尔逊 r	提取时长 (秒)
SigLIP2	0.6129 ± 0.0938	0.4816 ± 0.0850	0.5258 ± 0.0966	0.5419 ± 0.1470	52.37
DINOv3 (ViT-B/16)	0.5899 ± 0.0857	0.4427 ± 0.0760	0.5401 ± 0.0819	0.5155 ± 0.1473	70.38

1.6.3 模态贡献分析

模态组合比较包括文本、语音、视觉三个单模态，三种双模态组合，以及三模态组合。表 4 和附录图 A2 表明，文本单模态已保留较强的情感信息；文本与语音组合在分类指标上表现较好，文本与视觉组合在皮尔逊相关系数上更高。三模态简单拼接未在全部指标上同时取得最优结果。

在相同评价设置下，文本与语音组合的准确率和宏平均 F1 值高于文本单模态；文本与视觉组合的 MAE 更低、皮尔逊相关系数更高，但分类指标低于文本单模态。各组合的优势指标并不相同，因此需要按分类与连续预测目标分别比较其表现。

表 4 不同模态组合的定量比较

模态组合	准确率	宏平均 F1 值	平均绝对误差 (MAE)	皮尔逊 相关系数
文本	0.6519 ± 0.0772	0.5202 ± 0.0935	0.5516 ± 0.0797	0.4998 ± 0.1148
语音	0.6230 ± 0.0756	0.3927 ± 0.1050	0.5936 ± 0.0986	0.2254 ± 0.1800
视觉	0.5332 ± 0.0857	0.4195 ± 0.0942	0.6064 ± 0.0872	0.4428 ± 0.1550
文本 + 语音	0.6783 ± 0.0726	0.5454 ± 0.0900	0.5409 ± 0.0836	0.5135 ± 0.1145
文本 + 视觉	0.5992 ± 0.1049	0.4711 ± 0.0969	0.5257 ± 0.1021	0.5493 ± 0.1580
语音 + 视觉	0.5744 ± 0.0893	0.4617 ± 0.0991	0.5949 ± 0.0833	0.4274 ± 0.1597
文本 + 语音 + 视觉	0.6129 ± 0.0938	0.4816 ± 0.0850	0.5258 ± 0.0966	0.5419 ± 0.1470

1.7 典型样本分析与本问小结

图 3 中的样本时间窗对应文本原生特征索引 34、音频特征索引 542 和视觉特征索引 43；相应元数据分别保留词段时间、WAV 样本支持范围以及原始帧索引和显示时间戳。各模态来源索引可将统一位置回溯至实际媒体时间。对于官方文本与当前片段语音不一致的样本 -NFrJFQijFE__2，最终处理流程采用该 MP4 的识别文本及其真实时间戳构造文本特征，同时在元数据中保留官方文本。

综上，本文完成了附件 1 全部样本的媒体时间审计、三模态原生特征构造和公共时间轴映射。最大时间重叠硬对齐将不同采样粒度的特征统一为每个样本 50 个时间位置，并通过掩码区分有效特征与无观测位置；样本标识、时间窗、原生索引和媒体时间共同构成可核查的来源链。辅助比较显示，所选方法保持明确的时间交叠与唯一来源索引，各模态组合在不同评价指标上的表现各有侧重。

2 问题二：缺失场景下的多模态情感预测模型

2.1 问题分析与总体方案

局部连续缺失会使部分模态在统一序列中的一段时间没有可用观测，而文本、语音和视觉原本的有效位置仍需区分。问题二直接使用附件 2 已经预计算并对齐的三模态数值特征。本文先建立以掩码均值池化和简单融合为核心的基线模型，再以轻量时间注意力残差池化补充序列内的信息选择能力。图 4 概括本文模型；两个预测分支分别给出三类情感和连续强度。




图4 问题二的轻量时间注意力残差池化结构。三模态分别计算有效位置上的掩码均值与模态内时间注意力池化；共享模态映射后的残差表示经拼接融合，分别输出三类情感和连续强度。

2.2 数据表示与预测任务

附件2的训练、验证和测试划分分别包含3395、728和727条样本。每条样本的文本、语音和视觉特征长度均为50，特征维数依次为768、74和35。本文仅利用训练集拟合参数，使用验证集进行模型确定、三次随机初始化比较及缺失场景分析；附件2测试划分不参与上述选择与结论。附件3为无标签推理数据，不参与本节评价。

记 $p_{it} \in \{0, 1\}$ 为样本 i 在位置 t 的有效位。该掩码依据附件中的 `text_bert[:, 1, :]` 有效位字段构造；经数据审计，三模态在文本填充区间之外没有非零特征。有效位置中的原生全零向量仍保留在观测序列内。另设观测可用性掩码，仅在构造人工缺失时把指定连续区间置为不可用；模型不将该掩码作为额外输入。三分类按连续标注的负值、零值和正值分别对应消极、中性和积极，并沿用附件给出的实际类别编码。

2.3 基线多模态情感预测模型

基线模型对各模态分别进行有效位置上的均值池化，然后以独立映射将每个模态压缩至128维。对样本 i 的模态 m ，定义

$$\mu_i^{(m)} = \frac{\sum_{t=1}^{50} p_{it} \mathbf{x}_{it}^{(m)}}{\sum_{t=1}^{50} p_{it}}, \quad \mathbf{h}_{i,0}^{(m)} = P_m(\mu_i^{(m)}), \quad (11)$$

其中 P_m 依次包含线性映射、层归一化、GELU和随机失活。原生零向量只要位于有效位置，就按原值参与式(11)。三个128维表示拼接为384维，经128维融合层后送入三分类分支与单值回归分支。基线模型共有163460个参数。

分类采用仅由训练集类别频数确定的平衡加权交叉熵， $w_c = N/(3N_c)$ ；回归采用SmoothL1损失。总目标为

$$\mathcal{L} = \mathcal{L}_{\text{WCE}} + \lambda_r \mathcal{L}_{\text{SmoothL1}}, \quad \lambda_r = 1. \quad (12)$$

输入不作默认标准化，也不在训练时加入人工连续缺失。优化采用 AdamW，学习率 10^{-3} 、权重衰减 10^{-4} 、批量大小 128，随机失活率 0.1；最多训练 80 轮，提前停止耐心轮数为 12。这些设定对应实际实验配置，未依据附件 2 测试划分调整。

2.4 轻量时间注意力残差池化模型

均值池化对有效位置赋予相同权重，可能削弱短暂但关键的情绪线索。为补充时间维度信息，本文对每一模态增加一个标量打分器，并在有效位置上归一化：

$$e_{it}^{(m)} = f_m(\mathbf{x}_{it}^{(m)}), \quad \alpha_{it}^{(m)} = \frac{p_{it} \exp(e_{it}^{(m)})}{\sum_{s:p_{is}=1} \exp(e_{is}^{(m)})}, \quad \mathbf{a}_i^{(m)} = \sum_{t=1}^{50} \alpha_{it}^{(m)} \mathbf{x}_{it}^{(m)}. \quad (13)$$

填充位置在归一化前屏蔽，因此其注意力权重为零。时间表示使用与均值路径相同的模态映射，最终表示为

$$\mathbf{h}_i^{(m)} = P_m(\boldsymbol{\mu}_i^{(m)}) + \gamma_m P_m(\mathbf{a}_i^{(m)}). \quad (14)$$

三个残差系数初始为零，使模型初始预测与相应基线完全一致。改进模型保持已确定的模态映射、融合层和预测分支参数不变，仅估计新增的模态打分器及残差系数，使性能变化集中于池化方式。新增可调参数为 883 个，约为基线参数量的 0.54%；总参数量为 164343。该结构不使用跨模态注意力或额外的重建网络。

2.5 缺失场景构造与鲁棒性评价

评估协议由完整输入和 54 个预定的连续缺失场景组成。单模态场景对文本、语音或视觉分别设置 $\rho \in \{0.1, 0.2, 0.3, 0.4, 0.5\}$ ，并在有效前缀的前段、中段和后段放置遮挡，共 45 种。双模态场景取文本与语音、文本与视觉、语音与视觉三种组合，统一使用 $\rho = 0.3$ 及三个位置，共 9 种。若有效长度为 L_i ，遮挡长度为 $\ell_i = \max(1, \text{round}(\rho L_i))$ ；三个起点依次为 0、 $\lfloor (L_i - \ell_i)/2 \rfloor$ 和 $L_i - \ell_i$ 。人工缺失在模型输入中覆盖为精确零向量，填充区间与原生零记录均不因此改写。各模型使用相同的预定场景定义。

完整输入与各缺失条件均报告准确率、宏平均 F1、平均绝对误差 (MAE) 和皮尔逊相关系数。为在开发验证中同时兼顾分类与回归，另定义内部综合分数

$$S = \frac{1}{4} \text{Acc} + \frac{1}{4} \text{MacroF1} + \frac{1}{4} (1 - \text{MAE} / 6) + \frac{1}{8} (\text{Pearson} + 1), \quad R = \frac{1}{2} \left(S_{\text{clean}} + \frac{1}{54} \sum_{j=1}^{54} S_j \right). \quad (15)$$

R 仅为本项目的验证比较指标，不是竞赛官方评分。基线参数按完整输入验证分数确定，改进模型按预定的 R 确定；比较时保留这一选择口径差异。图 5 和图 6 分别用于展示比例变化与模态/位置组合。

2.6 实验结果与分析

2.6.1 完整输入与平均缺失条件

表 5 给出三次随机初始化的验证集均值及样本标准差。完整输入下，本文模型的宏平均 F1 由 0.6139 增至 0.6241，MAE 由 0.6079 降至 0.6059；平均缺失条件下，宏平均 F1 由 0.6092 增至 0.6163，MAE 由 0.6111 降至 0.6091，相关系数由 0.6359 增至 0.6414。与此同时，平均缺失准确率从 0.6349 略降为 0.6340。这些结果支持小幅平均改进，不支持所有指标均改善的表述。

2.6.2 缺失比例、模态与位置

不同遮挡比例的分组结果如图 5 所示。随着缺失范围扩大，两个模型的内部综合分数整体下降；在比例 0.5 的分组中，本文模型与基线模型的平均综合分数分别为 0.7392 与 0.7372。图 6 进一步显示，收益依赖模态和缺失位置：18 个模态/位置组合中，宏平均 F1 有 17 个均值差为正，相关系数有 18 个为正，MAE 改善有 16 个为正，而准确率仅 6 个为




图 5 不同单模态连续缺失比例下的验证集性能。每个比例先对三种模态与前、中、后三种遮挡位置取平均，再绘制三次随机初始化的均值与样本标准差；阴影为样本标准差。蓝线为掩码均值池化基线，红线为时间注意力残差池化模型；MAE 越低越好，其余指标越高越好。

表 5 附件 2 验证集上完整输入与 54 种缺失条件的预测结果（三次随机初始化均值 $\pm$ 样本标准差）

模型	条件	准确率 $\uparrow$	宏平均 F1 $\uparrow$	MAE $\downarrow$	相关系数 $\uparrow$
基线模型	完整	0.6401 ± 0.0048	0.6139 ± 0.0091	0.6079 ± 0.0103	0.6409 ± 0.0043
本文模型	完整	0.6419 ± 0.0057	0.6241 ± 0.0026	0.6059 ± 0.0066	0.6472 ± 0.0025
基线模型	平均缺失	0.6349 ± 0.0062	0.6092 ± 0.0075	0.6111 ± 0.0098	0.6359 ± 0.0038
本文模型	平均缺失	0.6340 ± 0.0049	0.6163 ± 0.0012	0.6091 ± 0.0060	0.6414 ± 0.0025

图5 缺失模态与位置下的相对性能变化




图 6 缺失模态及位置对模型间性能差异的影响。宏平均 F1、相关系数和准确率为“本文模型减基线模型”，MAE 为“基线模型减本文模型”，故正值均表示本文模型较优；色块为验证集三次随机初始化均值之差。

正。该方向计数不表示每次随机初始化或每个样本均受益。文本与语音、文本与视觉同时缺失时，综合收益接近零，说明关键模态同时失去观测后，简单池化残差的补偿能力有限。

2.6.3 随机初始化稳定性与误差分析

三次对应初始化下，本文模型相对基线模型的综合鲁棒分数差依次为 +0.005600、+0.003791 和 -0.000090，平均为 $+0.003100 \pm 0.002907$ （样本标准差）。两次获得正向改进，一次基本持平，表明改进具有一定初始化敏感性；图 7 预留配对结果及错误类别分析。基线与本文模型的鲁棒分数均值分别为 0.741677 ± 0.001458 和 0.744777 ± 0.001492 。验证集中有 15 个视觉整段原生全零样本，保留该子集及原标签后观察到部分初始化下本文模型在该子集的分类表现低于基线，因此不能用总体均值掩盖这一局部风险。

待替换：三次初始化的配对综合鲁棒分数变化、验证集混淆矩阵及原生视觉全零子集诊断。

图 7 随机初始化稳定性与误差分析。配对点对应相同初始化；标准差表示三次初始化间的离散程度，不作置信区间解释。当前为占位。

2.7 消融分析与本问小结

表 6 压缩展示主要结构选择。更深的单模态时间编码器与训练阶段连续遮挡增强，在三次初始化的相同验证协议下均未超过基线。均值与最大值残差池化在一次初始化下有正向迹象，但缺少重复验证；低秩模态交互分支在同次初始化下降。跨模态重建的非零混合

比例未在三次初始化中给出一致正收益；文本单独标准化下降，增大回归损失权重的收益很小且伴随准确率下降。可靠性加权分支有单次初始化的正向诊断，但没有同样完整的重复证据。因而本文保留参数开销较小、具有三次初始化配对结果的时间注意力残差池化方案。

表 6 主要结构与训练策略的验证集消融摘要。一次初始化结果仅为筛选证据，不与三次初始化均值作统计等同解释

方案	初始化次数	总参数量	综合鲁棒分数
基线模型	3	163460	0.7417 ± 0.0015
单模态时间编码	3	957572	0.7351 ± 0.0020
基线加训练期连续遮挡	3	163460	0.7385 ± 0.0025
均值与最大值残差池化	1	163463	0.7443
轻量时间注意力残差池化	3	164343	0.7448 ± 0.0015

本问直接利用预计算特征，依靠有效位掩码防止填充进入池化，并以固定连续缺失场景检验预测模型。轻量时间注意力残差池化在宏平均 F1、MAE 及相关性上取得小幅平均收益，但准确率、个别双模态缺失条件及原生视觉全零子集仍有限制。下一问据此在同一预测函数上分析模型决策依据，而不把内部归因直接等同于真实媒体的因果解释。

3 问题三：多模态情感预测的层级证据归因

3.1 问题分析与总体框架

情感预测给出类别与强度，却不能直接说明哪种模态、哪一段有效序列以及哪项原始证据影响了输出。为此，在问题二确定的多模态情感预测模型基础上，本文构建层级式多模态证据归因框架（Hierarchical Evidence Attribution Framework，HEAF）。该框架依次计算模态级精确贡献、模态对交互、连续窗口遮挡效应、删除干预一致性，并在可核验时将特征位置映射回原始文本。总体流程见图 8。以下解释的是固定预测函数对输入干预的响应，不直接等同于情绪的现实因果来源。




图 8 多模态情感预测与层级证据归因框架。三模态联盟用于模态贡献和交互分析，连续遮挡定位特征空间关键区间；原始文本证据可核验，音频与视觉的秒数和帧号映射尚未核

3.2 模态级精确 Shapley 归因

三种模态的联盟共有 $2^3 = 8$ 个，故可逐一计算所有组合，无需采样近似。令 $\mathcal{M} = \{T, A, V\}$, $S \subseteq \mathcal{M}$ 表示保留的模态集合；未保留模态只在有效位置清零，填充与原生零记录不变。分类解释固定完整输入时预测的类别 c^* ，以该类别相对其余类别的对数优势为联盟目标：

$$v_c(S) = z_{c^*}(S) - \log \sum_{k \neq c^*} \exp z_k(S), \quad v_r(S) = \hat{y}^r(S). \quad (16)$$

空联盟对应所有有效模态均被清零后的模型输出。对分类或回归目标分别计算

$$\phi_m = \sum_{S \subseteq \mathcal{M} \setminus \{m\}} \frac{|S|!(2 - |S|)!}{3!} [v(S \cup \{m\}) - v(S)]. \quad (17)$$

由此有 $\sum_m \phi_m = v(\mathcal{M}) - v(\emptyset)$ ，可用作计算完整性检查。分类贡献的单位是对数优势，回归贡献的单位是连续情感强度，两者不可直接混合排序。分类主导模态取最大正贡献；若三者均不为正，则取绝对贡献最大者并标明其非正性质。回归主导模态取绝对贡献最大者；并列时按文本、语音、视觉的固定顺序处理。下述时间分析遵循分类主导模态。

3.3 模态间交互分析

单个模态贡献之外，本文对文本-语音、文本-视觉和语音-视觉分别计算二阶交互。对模态 i, j 及剩余模态 k ，令

$$I_{ij} = \frac{1}{2} \{v(\{i, j\}) - v(\{i\}) - v(\{j\}) + v(\emptyset) + v(\mathcal{M}) - v(\{i, k\}) - v(\{j, k\}) + v(\{k\})\}. \quad (18)$$

该量平均了不含和包含第三模态两种背景下的二阶差分。正值表示联合贡献超过相应加性基准；负值表示联合贡献低于该基准，其具体含义还需结合样本与目标函数解释，不能一概称为冗余。分类和回归仍分别计算交互量。

3.4 连续窗口时间遮挡与关键区间定位

模态级归因给出重要模态，却未确定模态序列中的局部位置。对分类主导模态，在有效长度 L_i 内设窗口长度 $w_i = \max(1, \text{round}(0.30L_i))$ ，以步长 1 遍历所有连续窗口。记 $g(\mathbf{x})$ 为式 (16) 的固定类别对数优势，窗口 W 的遮挡效应为

$$D_i(W) = g(\mathbf{x}_i) - g(\mathbf{x}_i^{\setminus W}), \quad (19)$$

其中仅该模态在窗口 W 内的有效特征被清零。若存在正效应，取 $D_i(W)$ 最大的窗口；否则取绝对效应最大的窗口并标注方向。平局选择最早位置。覆盖某位置的窗口效应最大值形成 50 位局部曲线。图中的区间均为对齐特征槽位，不自动对应原媒体的秒数或帧号。对回归可报告有符号或绝对输出变化，不能预设遮挡使情感强度单向下降。

3.5 解释忠实性的干预一致性检验

时间窗口比例 0.30 是在附件 2 验证集的设计子集上确定的。按视频标识分组后，设计子集含 332 条片段、113 个视频标识，独立的审计子集含 396 条片段、126 个视频标识，两组视频标识无交集。审计时把所选窗口与 32 次随机抽取的等长窗口比较，并按时间曲线删除 10%、20%、30%、40% 的有效位置；区间估计采用视频分组自助采样。

表 7 显示，审计子集上所选窗口的平均分类对数优势下降为 0.482771，随机窗口为 0.082036，差值 0.400735，对应分组自助采样 95% 区间为 [0.3635, 0.4372]；以每条样本 32 次随机抽样的均值为对照，所选窗口效应更大的审计样本比例为 1.0。置信度下降差为 0.077718，类别 logit 下降差为 0.239688。连续回归输出的有符号差为 -0.018095 且区间跨

零，但绝对变化差为 0.103545。图 9 同时展示 728 条验证样本的主导模态分布及审计子集的删除曲线。

表 7 附件 2 验证集审计子集的解释干预一致性结果（396 条片段；按视频分组的 95% 自助采样区间）

输出量	所选窗口	随机等长窗口	平均差	95% 区间
分类对数优势下降	0.482771	0.082036	0.400735	[0.3635, 0.4372]
分类置信度下降	0.093286	0.015567	0.077718	[0.0712, 0.0843]
分类 logit 下降	0.292982	0.053294	0.239688	[0.2195, 0.2603]
回归有符号变化	0.002082	0.020177	-0.018095	[-0.0526, 0.0141]
回归绝对变化	0.202760	0.099215	0.103545	[0.0883, 0.1203]

图8 解释有效性与主导模态统计




图 9 验证集上的主导模态与删除干预结果。（A）728 条样本的分类/回归主导模态计数；（B）审计子集上所选与随机窗口的分类边际下降及视频分组 95% 区间；（C）两种删除方式的配对差。所选窗口来自同一候选集合的最大影响值，因此相对随机窗口的优势含选择效应。

删除 10%、20%、30%、40% 有效位置时，所选位置相对随机位置的平均分类边际下降差分别为 0.108296、0.237758、0.418076 和 0.465465。但单个关键窗口原本就是从候选窗口中选出最大影响者，所选窗口对同一预测函数的平均优势带有内生选择效应。该结果应解释为模型扰动响应的一致性检验，而非独立的预测正确性或现实因果证明。对另外两次随机初始化，仅在固定审计样本上检查解释方向：分类主导模态一致率分别为 0.869 和 0.831，回归主导模态一致率为 0.778 和 0.783，分类贡献排序的平均 Spearman 相关系数分别为 0.758 和 0.694，回归贡献排序分别为 0.745 和 0.760，同模态关键区间平均交并比分别为 0.579 和 0.527。这些数值说明解释存在模型初始化差异，不能称为高度稳定。

3.6 原始证据映射与可核验边界

特征槽位上的解释只有在能核实预处理来源时才能回到原始媒体。附件 4 的文本链路通过同一索引的 BERT 最后层向量重构、标记序列及分词偏移量核验：20 条样本共 604 个有效文本槽位的完整行间余弦最大值均位于同一索引，平均同索引余弦为 0.999999994，最大绝对特征差为 3.0041×10^{-5} ，重构均方根误差为 8.3977×10^{-7} 。因此，文本特征槽位可连接到对应标记及原始文本字符跨度；特殊标记不生成伪造文本证据。历史文本编码权重的确切版本未留存，限制了对原始生成过程的版本追溯。

音频和视觉方面，附件 4 没有提供可验证的“特征槽位 $\rightarrow$ 媒体秒数/视频帧”映射，也不能仅凭视频时长将 50 个槽位均分。故本文对音频与视觉只报告特征空间中的关键区间，原始秒级时间与帧号保持未验证。图 10 中的视频截图只表示对应视频的场景背景，不是由解释算法定位出的关键视觉帧。

3.7 附件 4 预测解释结果

依据前述方法对附件 4 的 20 条对齐样本生成预测与解释卡，20 个标识均有对应的视频文件，输出字段、有限值及模态贡献加和关系完成一致性检查。附件 4 没有真实情感标签，所以表 8 仅汇总预测类别、主导模态和原始证据核验状态，不报告准确率、宏平均 F1、MAE、相关系数或预测正确性。

表 8 附件 4 的无标签预测及解释摘要（共 20 条样本）

统计项	类别或状态	数量	比例
预测情感类别	消极	7	35%
	中性	5	25%
	积极	8	40%
分类主导模态	文本	19	95%
	语音	0	0%
	视觉	1	5%
回归主导模态	文本	18	90%
	语音	0	0%
	视觉	2	10%
原始证据核验状态	已核验	19	95%
	未核验	1	5%

分类与回归的主导模态在 17 条样本上相同，占 85%。原始证据核验的 19 条为文本主导样本；视觉主导的一条只保留特征槽位区间及未核验标记。以上计数只描述该 20 条无标签样本上的模型输出，不构成性能估计。

3.8 典型样本分析与本问小结

图 10 展示两条按既定规则选取的案例。样本 14 预测为中性，连续强度 +0.155，分类置信度 0.557；分类模态贡献依次为文本 +1.54、语音 +0.05、视觉 -1.02。其文本主导关键特征区间为 [1, 12)，经核验可连接至原文片段“*He is the co-founder of Rossen and Vet*”。这些贡献解释该模型的当前决策，不代表真实情感标签已被验证。

样本 02 预测为消极，连续强度 -0.027，分类置信度 0.390；文本、语音、视觉的分类贡献分别为 -0.20、+0.23 和 +0.83。视觉为主导模态，关键区间 [1, 7) 只能解释为视觉特征槽位。图中的视频帧来自原片固定相对位置，提供场景背景，不能称为对应关键区间的原始帧。两个案例共同说明，解释卡应同时呈现可计算的模态贡献和证据映射的核验状态。

本问实现了由八种模态联盟到连续时间窗口、再到可核验原始文本证据的逐层解释。验证集干预结果支持解释与模型输出变化之间的一致性；附件 4 展示了无标签样本的具体

A 文本主导典型案例 (样本14)




原视频场景

预测类别 中性 情感强度 +0.155
置信度 0.557 分类主模态 文本


已验证文本证据

"He is the co-founder of Rossen and Vet"

分类 Shapley 贡献



时间遮挡曲线




B 视觉主导边界案例 (样本02)




原视频上下文 (非关键帧定位)

预测类别 负面 情感强度 -0.027
置信度 0.390 分类主模态 视觉

分类 Shapley 贡献



时间遮挡曲线



原始视觉位置未验证, 仅展示特征槽位区间

图 10 附件 4 两条典型样本的层级解释。样本 14 给出已核验文本片段；样本 02 只定位视觉特征槽位，视频帧为原视频上下文展示，不表示算法定位出的关键帧。

预测和解释形式。音频及视觉的原始时间映射尚未核验，解释的适用范围止于特征空间，不应外推为真实情绪形成机制。

4 模型评价与进一步讨论

4.1 三个问题的衔接与适用范围

本文按照“可追溯特征构建—缺失场景预测—决策证据解释”组织三项工作。问题一在附件 1 原始媒体上建立统一时间窗和来源链，保证特征位置有明确的媒体时间依据；问题二使用附件 2 已经提供的对齐特征，检验轻量预测模型在有效位置局部连续缺失时的开发验证表现；问题三将确定的预测函数用于附件 4，生成模态贡献、交互、关键特征槽位与可核验文本片段。三项工作共享掩码和时间语义的审慎原则，但不应被误写为附件 1 特征直接输入问题二模型。

4.2 预测收益、复杂度与误差边界

问题二的改进结构仅比基线增加 883 个参数，三次随机初始化的平均综合鲁棒分数增加 0.003100，但其中一次基本持平。平均缺失条件下的宏平均 F1、MAE 及相关系数方向较好，准确率略低；部分双模态缺失组合的改进接近零，原生视觉全零样本也存在不利结果。因此，较小的参数开销和平均分数收益是本方法的主要优势，而非对所有缺失类型的普遍优势。基线按完整输入分数、改进模型按综合分数选取参数的口径差异也限制了二者的严格横向解释。综合分数只是内部验证工具，正式判断仍须同时查看四项原始指标。

问题一的重复分层五折评价用于比较特征构建与对齐方案的信息保持能力。该评价的训练/评价折间存在同一视频标识的片段，因此不能将这些数值解释为独立视频上的泛化性能或统计显著性证据。问题二使用附件 2 预定训练与验证划分，所有模型选择及缺失场景比较限于验证集；附件 2 测试划分与附件 3 不支撑本文所报告的验证结论。

4.3 解释证据的层级边界

问题三的八联盟精确计算保证了模态贡献满足加和关系；连续遮挡和删除曲线提供预测函数内部的干预响应证据。然而关键窗口由最大响应准则选取，故其相对随机窗口的优势包含选择效应。文本特征行到标记、再到原始字符片段的链路在附件 4 得到数值核验，语音与视觉特征槽位仍无可靠的媒体时间映射。模型解释可以定位“哪种模态、哪个特征槽位影响当前输出”，但不能据此直接断言真实情绪因果、精确音频秒数或关键视频帧。附件 4 缺乏标签，也无法评估其预测准确性。

在实际应用中，可将类别与强度预测、模态贡献、局部敏感性及证据核验状态同时输出，使用户区分模型决策依据与原始媒体证据。后续若获取可验证的音视频预处理记录和原始时间映射，才能把当前特征槽位层的解释进一步扩展到音频时间和视频帧。

5 结论

针对复杂场景下多模态情感识别的三个问题，本文形成了由原始媒体特征构建、局部缺失预测到层级证据解释的完整方案。问题一对附件 1 三模态媒体分别构造带时间支持的原生特征，以最大时间重叠映射至 50 个公共时间窗，并保留有效掩码和来源索引，得到可追溯的时序表示。其辅助交叉验证帮助比较构建方案，但不作为独立泛化结论。

问题二直接利用附件 2 预计算对齐特征，建立三分类与连续强度的双任务基线，并用轻量时间注意力残差池化补充均值池化的时间选择能力。在验证集的完整输入和 54 种连续缺失条件下，三次初始化的平均综合鲁棒分数取得小幅改进；宏平均 F1、MAE 与相关系数的平均方向较好，准确率略有下降，而且收益随初始化与缺失场景变化。该结果支持选择低参数开销的模型，同时要求对具体应用场景继续检查误差。

问题三提出层级式多模态证据归因框架，通过八种模态联盟的精确贡献、模态间交互、连续时间遮挡和删除干预，构建由模态到局部区间的解释。附件 4 的 20 条无标签样本均生成预测与解释卡；文本证据可映射到经核验的原始字符片段，语音与视觉目前仅能定位到特征槽位。后续工作应以独立来源的音视频时间映射和有标签外部评价扩展现有证据边界，而不能把无标签预测或模型干预响应当作真实情感的正确性与因果证明。

参考文献

- [1] Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *Proceedings of Machine Learning Research*, pages 28492–28518. PMLR, 2023.
- [2] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa: A robustly optimized BERT pretraining approach. *arXiv preprint arXiv:1907.11692*, 2019.
- [3] Sanyuan Chen, Chengyi Wang, Zhengyang Chen, Yu Wu, Shujie Liu, Zhuo Chen, Jinyu Li, Naoyuki Kanda, Takuya Yoshioka, Xiong Xiao, Jian Wu, Long Zhou, Shuo Ren, Yanmin Qian, Yao Qian, Jian Wu, Michael Zeng, Xiangzhan Yu, and Furu Wei. WavLM: Large-scale self-supervised pre-training for full stack speech processing. *IEEE Journal of Selected Topics in Signal Processing*, 16(6):1505–1518, 2022.
- [4] Michael Tschanen, Alexey Gritsenko, Xiao Wang, Muhammad Ferjad Naeem, Nikhil Alabulmohsin, Nikhil Parthasarathy, Talfan Evans, Lucas Beyer, Ye Xia, Basil Mustafa, Olivier Hénaff, Jeremiah Harmsen, Andreas Steiner, and Xiaohua Zhai. SigLIP 2: Multilingual vision-language encoders with improved semantic understanding, localization, and dense features. *arXiv preprint arXiv:2502.14786*, 2025.
- [5] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, et al. DINOv3: Self-supervised learning for vision at unprecedented scale. *arXiv preprint arXiv:2508.10104*, 2025.

A 典型样本映射材料

典型样本 -a55Q6RWvTA__3 的逐特征时间映射记录保存在附带 CSV 文件，案例级源信息保存在 JSON 文件；两项均为问题一结果的原始材料。完整样本汇总表的 CSV 副本也保存在论文工程中。




图 A1 不同时序对齐方法的辅助评价结果。点和半透明区间分别表示均值及其上下一个标准差。




图 A2 不同模态组合的辅助评价结果。点表示均值，独立的半透明区间表示均值上下一个标准差；圆形、方形和菱形分别表示单模态、双模态和三模态组合。