

华为杯第二十三届中国研究生数学建模竞赛

论文题目（待定）

摘要：摘要将在全文模型与结果确定后撰写。

关键词：待定

问题重述

本题要求在复杂场景下形成从多模态观测到情感预测、再到可核验证据的分析链。问题一针对附件 1 的原始媒体，分别提取文本、语音和视觉特征，将不同采样粒度的观测映射到公共时间轴，并保留每个有效位置的来源。问题二使用附件 2 已提供的对齐数值特征，预测三类情感及连续情感强度，重点考察局部连续时间段缺失时的性能。问题三在确定的预测模型上分析模态贡献、模态交互和关键特征区间，并对附件 4 的无标签样本给出预测与解释。

三个问题在时间位置、有效掩码和证据可追溯性方面相互衔接，但各自使用的官方附件不同。问题一构建的附件 1 特征并未替代问题二的附件 2 输入；问题三的附件 4 推理也不提供有标签性能评价。本文据此分别报告特征构建的完整性、附件 2 验证集上的预测与缺失场景表现，以及附件 4 上的解释结果。

基本假设

1. 原始媒体的呈现时间、音频采样位置和视频解码时间可作为问题一对齐的共同时间基准；无法获得可靠时间支持的位置由掩码标记。
2. 附件 2 与附件 4 的对齐特征已完成数值预计算。其有效序列位置由附带的文本有效位字段确定，不能仅凭某一模态的零向量判定填充或人为缺失。
3. 人工缺失只作用于原本有效的连续位置；原生零值保留为观测内容或数据质量状态，不自动解释为人工缺失。
4. 附件 4 无真实情感标签，因而其预测分布和解释卡不用于计算分类准确率、宏平均 F1 值、平均绝对误差或相关系数。

符号说明

符号	含义
$m \in \{T, A, V\}$	文本、语音、视觉模态； $\mathcal{M} = \{T, A, V\}$ 。
L_i, p_{it}	样本 i 的有效序列长度及位置 t 的有效位掩码。
$\mathbf{x}_{it}^{(m)}$	样本 i 在模态 m 、位置 t 的数值特征。
ρ, ℓ_i	连续缺失比例及对应的有效位置遮挡长度。
y_i^c, y_i^r	三分类标签及连续情感强度标签。
$\hat{\mathbf{z}}_i, \hat{y}_i^r$	分类输出向量及回归预测值。
$v(S), \phi_m, I_{mn}$	模态联盟 S 的预测目标值、模态贡献及模态对交互量。

1 问题一：多模态特征提取与时序对齐

1.1 问题分析与总体方案

问题一要求从原始视频构造能够逐时刻比较的文本、语音和视觉表示。三种模态的原生采样粒度不同，序列下标因而缺少直接的时间对应关系；部分片段的官方转写与当前视频实际语音也存在差异。本文先分别构造带时间支持区间的三模态原生特征，再按照真实媒体时间映射至公共时间窗，并为每个有效位置保留来源索引。整体流程如图 1 所示。

方法由原生特征构建、公共时间基准建立、跨模态映射和来源追踪四部分组成。文本、语音与视频分别形成带时间支持区间的向量序列；随后将样本媒体时长划分为 50 个统一时间窗，依据区间交叠为各窗选择对应的原生特征，并输出有效位和来源索引。

这一结构将特征提取与时间对齐分开处理，适应三种模态在采样粒度、序列长度和时间支持上的差异。最大时间重叠规则保留单一原生特征及可回溯索引；显式有效位则区分未覆盖时间窗与真实零值，避免仅凭序列下标或特征数值解释模态对应关系。

图 2、图 3 和图 4 依次预留文本、语音和视觉特征构建示意位置。三类输入分别经过上下文语义编码、逐帧声学编码和逐帧视觉编码后，形成后续时间对齐所需的特征序列。




图 1 问题一的三模态特征构建与最大时间重叠对齐框架。文本、语音和视觉原生特征分别关联媒体时间区间，再映射至统一时间窗；图中高亮时间窗用于示意映射规则。

图 2 占位：文本片段分词为子词序列，并由上下文语义编码器生成对应的文本特征向量。

图 2 文本模态特征提取示意图（待绘）。文本片段经分词后输入 RoBERTa-base，生成上下文相关的语义表示，并保留片段时间支持。

图 3 占位：原始语音波形按时间形成帧级输入，经声学编码后输出有序特征序列。

图 3 语音模态特征提取示意图（待绘）。单声道波形按帧处理，WavLM-base-plus 为各声学时间位置提取表示，并保留其样本时间支持。

图 4 占位：原始视频按固定时间间隔采样为帧，经视觉编码器生成逐帧特征。

图 4 视频模态特征提取示意图（待绘）。原始视频帧按固定时间网格采样，SigLIP2-base-patch16-224 提取视觉向量，并依据实际显示时间戳记录帧的时间支持。

该流程以附件 1 中的原始视频为唯一媒体输入。文本、音频和视频先各自形成“特征向量—媒体时间区间”序列，再投影到同一时间基准下的 50 个时间窗。对每个模态和时间窗，最大时间重叠硬对齐只选取与目标窗具有正交叠且交叠最长的一个原生特征；未覆盖位置由掩码标记，并保留来源追踪信息。

1.2 原始数据预处理与时间基准构建

对附件 1 的 100 条视频核验样本标识与标签对应关系，并读取媒体时长、音轨及解码帧时间。另由 MP4 提取 16 kHz 单声道 WAV；音频支持区间按 WAV 样本位置换算，视觉按固定时间间隔采样，并以真实帧显示时间定位，原始视频保持不变。

记第 i 个样本相对于媒体呈现起点的有效时长为 T_i ，其统一时间域定义为

$$\mathcal{T}_i = [0, T_i]. \quad (1)$$

后续文本时间区间、音频帧支持区间和视觉帧支持区间均以秒表示，并相对于该样本的媒体起点。视觉特征的支持区间由相邻采样帧的真实显示时间构造。由此，不同采样频率下的特征均可在同一时间坐标中进行比较。

图 5 汇总附件 1 样本的媒体时长、情感类别、三模态有效时间窗以及文本来源和时间戳回退记录。样本时长存在差异，文本有效覆盖在样本间波动较大，而语音与视觉覆盖相对完整；文本来源统计也保留了官方文本与媒体 ASR 的区分。上述描述性结果说明时间掩码和来源信息需要随特征一并保存，但不构成模型性能比较。




图 5 附件 1 原始样本及特征覆盖的描述性统计。(a) 100 条视频的原始时长分布；(b) 三类情感标签样本数量；(c) 文本、语音和视觉在 50 个公共时间窗中的有效位置分布；(d) 文本来源及时间戳回退情况。统计均由最终 Q1 处理清单直接计算。

1.3 三模态原生特征提取

每种模态先独立提取时间有序的原生向量。文本和音频以其语义或声学帧区间为时间支持，视觉向量则关联到实际采样帧及其显示时间。下文记模态 m 的第 j 个原生向量为 $\mathbf{h}_{ij}^{(m)}$ ，其时间支持为 $I_{ij}^{(m)}$ 。

1.3.1 文本特征提取

文本特征中，75 条样本使用官方文本，并匹配同一样本的 Whisper 识别时间信息；25 条样本使用当前媒体的识别文本及其时间信息。Whisper large-v3-turbo 提供识别片段和词级时间戳 [1]。官方文本在特征元数据中原样保留，文本来源与时间来源分别记录。

原始审计记录包含 46 个需要从词级时间回退至所属识别片段时间的区间，其中 21 个实际参与最终文本特征映射。回退后的片段时间提供较粗粒度的支持范围。对选定文本片段使用 RoBERTa-base 提取语义向量 [2]，并保存其文本来源、时间支持、特征索引和模型信息。第 j 个文本特征写为

$$\mathbf{h}_{ij}^{(T)} \in \mathbb{R}^{768}, \quad I_{ij}^{(T)} = [s_{ij}^{(T)}, e_{ij}^{(T)}]. \quad (2)$$

1.3.2 语音特征提取

语音输入为 16 kHz 单声道 WAV，使用 WavLM-base-plus 生成逐帧声学表示 [3]。每个输出向量关联到原始 WAV 中对应的样本支持区间；该区间经采样率换算到视频相对时间，并随特征索引一并保存。因此，语音序列不仅保留向量顺序，还能回溯到 WAV 样本范围和 MP4 时间。

$$\mathbf{h}_{ij}^{(A)} \in \mathbb{R}^{768}, \quad I_{ij}^{(A)} = [s_{ij}^{(A)}, e_{ij}^{(A)}]. \quad (3)$$

1.3.3 视觉特征提取

视觉特征采用 SigLIP2-base-patch16-224 提取 [4]。固定采样策略在每秒 4 帧的时间网格上选取观测帧，再以 MP4 解码得到的真实帧显示时间戳确定采样位置。相邻采样时刻用于构造每帧的支持区间，使视觉向量保留到源视频帧索引及呈现时间的对应关系。视觉原生特征表示为

$$\mathbf{h}_{ij}^{(V)} \in \mathbb{R}^{768}, \quad I_{ij}^{(V)} = [s_{ij}^{(V)}, e_{ij}^{(V)}]. \quad (4)$$

因此，三种模态均表示为按时间排序的向量与半开支持区间对，为后续按时间交叠进行映射提供共同输入形式。

1.4 基于最大时间重叠的跨模态时序对齐模型

将样本 i 的有效时长 T_i 均分为 $K = 50$ 个半开时间窗：

$$B_{ik} = \left[\frac{kT_i}{K}, \frac{(k+1)T_i}{K} \right), \quad k = 0, 1, \dots, K-1. \quad (5)$$

记 $b_{ik} = kT_i/K$ 为第 k 个时间窗的起点。模态 $m \in \{T, A, V\}$ 的第 j 个原生特征时间支持为

$$I_{ij}^{(m)} = [s_{ij}^{(m)}, e_{ij}^{(m)}]. \quad (6)$$

该区间与公共时间窗的交叠时长定义为

$$\omega_{ijk}^{(m)} = \max\left(0, \min(e_{ij}^{(m)}, b_{i,k+1}) - \max(s_{ij}^{(m)}, b_{ik})\right). \quad (7)$$

当存在正交叠时，最大时间重叠硬对齐选取交叠时长最大的原生特征索引：

$$j_{ik}^{(m)} = \arg \max_j \omega_{ijk}^{(m)}, \quad \omega_{i,j_{ik}^{(m)},k}^{(m)} > 0. \quad (8)$$

选中后，统一位置直接继承该原生特征：

$$\mathbf{z}_{ik}^{(m)} = \mathbf{h}_{i,j_{ik}^{(m)}}^{(m)}, \quad M_{ik}^{(m)} = 1. \quad (9)$$

若不存在正交叠，则令 $\mathbf{z}_{ik}^{(m)} = \mathbf{0}$ 且 $M_{ik}^{(m)} = 0$ 。此时零向量仅表示该位置没有有效映射，是否有效由掩码 $M_{ik}^{(m)}$ 区分。于是单个样本的模态张量及全体样本张量分别为

$$\mathbf{Z}_i^{(m)} \in \mathbb{R}^{50 \times d_m}, \quad \mathbf{Z}^{(m)} \in \mathbb{R}^{100 \times 50 \times d_m}, \quad d_T = d_A = d_V = 768. \quad (10)$$

每个有效对齐位置还保存样本标识、统一时间窗索引、原生特征索引及源时间区间，构成从统一序列位置回溯至原始媒体的来源追踪链。

图 6 进一步展开原生时间轴与统一时间窗之间的对应关系。不同模态的特征间隔和数量可以不同；对齐依据媒体时间区间的交叠，不依据各模态序列中的相同下标。图中未获得有效映射的位置由掩码区分，避免将空缺位置解释为真实观测。




图 6 三模态原生时间轴到公共时间窗的映射示意。文本片段、音频帧和视觉采样帧首先关联各自的媒体时间；统一时间窗根据正时间交叠选择原生特征，并记录有效位与来源。

图中热图及采样间隔只用于展示时间粒度差异，不代表本文实际特征值或采样率。

1.5 特征构建结果与完整性检验

最终处理流程覆盖 100 条样本，三种模态均形成维数为 768 的原生向量，并映射至长度为 50 的公共序列。表 1 汇总各模态的原生特征数、单样本对齐形状和平均有效时间覆盖率。文本覆盖率低于音频和视觉，反映部分时间窗缺少文本片段的时间支持；这些位置由掩码标记为空缺。

表 1 三模态特征构建与时间覆盖结果

模态	特征提取方法	原生特征数	特征维数	单样本	平均时间覆盖率
				对齐形状	
文本	RoBERTa-base	1847	768	50×768	0.8242
语音	WavLM-base-plus	38776	768	50×768	0.9910
视觉	SigLIP2-B/16	3205	768	50×768	1.0000

完整性检查基于完整性检验清单及来源追踪记录，覆盖样本处理状态、特征形状、有限值、有效映射比例和时间来源可回溯性。三模态输出均可由统一时间窗回溯到对应的原生特征及源媒体时间信息。图 8 展示样本 -a55Q6RWvTA__3 的一个具体时间窗及其原生来源。

1.6 全量样本特征构建结果

表 2 列出附件 1 全部 100 条样本的最终特征构建结果，每条样本对应一个唯一标识。三模态的对齐形状在所有样本中均为 50×768 ，视觉有效窗数均为 50，故这两项统一在此说明。表中保留文本来源和时间戳回退次数，未排除带有文本审计提示或回退记录的样本。

表 2 附件 1 全部 100 条样本的特征构建结果（逐样本汇总）

样本 ID	时长/s	文本有效窗	语音有效窗	文本来源	时间戳回退次数
-3g5yACwYnA__13	5.514	33	49	官方文本	0
-3g5yACwYnA__2	9.394	28	50	官方文本	0
-3g5yACwYnA__3	14.389	43	50	官方文本	0
-3g5yACwYnA__9	8.817	43	50	官方文本	0
-3nNcZdcvU__5	7.868	37	50	官方文本	0
-571d8cVauQ__0	5.167	34	49	官方文本	0
-571d8cVauQ__5	15.273	47	50	官方文本	0
-6rXp3zJ3kc__8	12.805	44	50	官方文本	0
-9y-fZ3swSY__0	6.900	41	49	官方文本	0
-9y-fZ3swSY__4	2.821	44	47	官方文本	0
-9y-fZ3swSY__8	4.989	41	50	官方文本	0
-AUZQgSxyPQ__2	22.511	45	50	官方文本	0
-HeZS2-Prhc__2	8.262	40	50	官方文本	0
-HwX2H8Z4hY__2	3.982	26	50	媒体 ASR	0
-HwX2H8Z4hY__5	5.653	44	49	官方文本	0
-HwX2H8Z4hY__6	3.358	38	49	官方文本	0
-HwX2H8Z4hY__9	7.734	46	50	官方文本	0
-I_e4mIh0yE__1	7.622	44	49	官方文本	0
-I_e4mIh0yE__3	9.163	46	50	官方文本	0
-MeTTeMJBnc__0	9.333	42	50	官方文本	0
-MeTTeMJBnc__13	5.430	39	49	官方文本	0
-MeTTeMJBnc__7	10.517	45	50	官方文本	0
-NFrJFQijFE__1	5.746	13	50	媒体 ASR	5
-NFrJFQijFE__2	6.856	25	49	媒体 ASR	0
-RfYyzHpjk4__11	5.239	43	49	官方文本	0
-RfYyzHpjk4__2	5.516	42	49	官方文本	1
-RfYyzHpjk4__8	4.589	37	50	官方文本	0
-THoVjtIkeU__12	14.896	40	50	官方文本	0

续下页

续表 2

样本 ID	时长/s	文本有效窗	语音有效窗	文本来源	时间戳回退次数
-THoVjtIkeU__2	4.292	43	50	官方文本	0
-THoVjtIkeU__6	8.097	45	50	官方文本	0
-UUCSKoHeMA__0	7.867	37	50	官方文本	0
-UacrmKiTn4__10	7.362	41	50	官方文本	0
-UacrmKiTn4__4	4.741	43	50	官方文本	0
-UuX1xuaiiE__0	3.700	40	49	官方文本	0
-UuX1xuaiiE__1	10.350	47	50	官方文本	0
-UuX1xuaiiE__3	4.130	43	49	官方文本	0
-UuX1xuaiiE__6	8.114	45	49	官方文本	1
-a55Q6RWvTA__3	22.154	48	50	官方文本	0
-aNfi7CP8vM__7	8.695	46	50	官方文本	0
-aqamKhZ1Ec__0	11.000	33	50	官方文本	0
-dxftGcXJoc__0	20.533	47	50	官方文本	0
-dxftGcXJoc__1	16.161	47	50	官方文本	0
-dxftGcXJoc__2	16.698	46	50	官方文本	0
-dxftGcXJoc__6	12.735	48	50	官方文本	0
-egA8-b7-3M__1	10.266	44	50	官方文本	0
-egA8-b7-3M__13	4.184	40	48	官方文本	0
-egA8-b7-3M__16	5.538	41	50	官方文本	0
-egA8-b7-3M__17	7.271	43	49	官方文本	0
-egA8-b7-3M__18	8.386	47	50	官方文本	0
-egA8-b7-3M__20	6.645	43	49	官方文本	0
-egA8-b7-3M__26	6.031	42	49	官方文本	0
-egA8-b7-3M__6	6.265	40	50	官方文本	0
-egA8-b7-3M__9	5.090	40	49	官方文本	0
-hnBHBn8p5A__6	6.401	43	50	媒体 ASR	0
-hnBHBn8p5A__7	7.372	46	50	媒体 ASR	0
-iRBcNs9oI8__3	5.621	47	50	媒体 ASR	0
-iRBcNs9oI8__6	2.903	42	49	媒体 ASR	0
-iRBcNs9oI8__7	4.104	44	49	媒体 ASR	0
-iRBcNs9oI8__8	8.093	41	50	媒体 ASR	0
-iRBcNs9oI8__9	3.416	34	50	媒体 ASR	0
-lzEya4AM_4__5	7.675	42	50	官方文本	0
-lzEya4AM_4__6	14.792	48	50	官方文本	0
-mJ2ud6oKI8__1	6.103	45	50	媒体 ASR	0
-mJ2ud6oKI8__2	5.731	45	50	媒体 ASR	0
-mJ2ud6oKI8__6	2.257	45	50	媒体 ASR	0
-mJ2ud6oKI8__8	4.192	45	50	媒体 ASR	4
-mJ2ud6oKI8__9	7.033	49	50	媒体 ASR	1
-mqbVkbCndg__0	6.500	41	50	官方文本	0
-qDkUBOGgYY__6	4.678	37	50	官方文本	0
-ri04Z7vwnc__0	2.807	19	49	媒体 ASR	0
-ri04Z7vwnc__2	6.027	14	49	媒体 ASR	0
-ri04Z7vwnc__5	3.545	48	49	媒体 ASR	1
-s9qJ7ATP7w__0	6.867	43	49	媒体 ASR	0
-s9qJ7ATP7w__1	4.792	38	49	官方文本	0
-s9qJ7ATP7w__4	4.427	31	48	官方文本	0
-s9qJ7ATP7w__5	8.561	46	49	官方文本	0

续下页

续表 2

样本 ID	时长/s	文本有效窗	语音有效窗	文本来源	时间戳回退次数
-s9qJ7ATP7w__6	2.475	29	47	官方文本	0
-s9qJ7ATP7w__7	6.966	42	49	官方文本	0
-s9qJ7ATP7w__8	3.295	36	49	官方文本	0
-t217m2on-s__2	5.686	39	50	官方文本	0
-t217m2on-s__7	17.183	48	50	官方文本	0
-tANM6ETl_M__3	6.758	45	49	官方文本	0
-tPCyztz4rww__10	4.789	48	49	媒体 ASR	0
-tPCyztz4rww__11	5.467	49	50	媒体 ASR	0
-tPCyztz4rww__12	11.864	47	50	媒体 ASR	0
-tPCyztz4rww__16	7.206	45	50	官方文本	0
-tPCyztz4rww__18	6.645	42	50	官方文本	0
-uywlfIYOS8__4	6.045	34	49	官方文本	0
-vxjVx0eScU__4	9.127	45	50	官方文本	0
-wMB_hJL-3o__7	6.044	39	50	官方文本	0
-wny00Az3g8__0	3.333	41	49	官方文本	0
-wny00Az3g8__1	6.844	46	50	官方文本	0
-wny00Az3g8__2	6.687	42	49	官方文本	0
-wny00Az3g8__3	6.146	41	50	官方文本	0
-wny00Az3g8__5	6.912	43	49	官方文本	0
-wny00Az3g8__7	8.068	46	49	官方文本	0
-wny00Az3g8__9	6.213	42	49	官方文本	0
-yRb-Jum7EQ__1	29.288	38	50	媒体 ASR	8
-yRb-Jum7EQ__5	13.169	45	50	媒体 ASR	0
-yRb-Jum7EQ__6	11.242	47	50	媒体 ASR	0

100 条样本的平均有效窗覆盖率分别为文本 0.8242、语音 0.9910、视觉 1.0000。未获得有效映射的时间位置由掩码标记；全部最终输出均保留统一时间窗到原生特征和源媒体时间的来源追踪记录。

1.7 对齐方案与特征有效性分析

为比较不同时间映射和模态组合的情感信息保留情况，采用统一的轻量下游评价模型及重复分层五折划分。分类任务报告准确率和宏平均 F1 值；连续预测报告平均绝对误差 (MAE) 和皮尔逊相关系数。该评价仅用于比较不同特征构建与时间对齐方案的信息保持能力，不作为独立泛化性能或统计显著性结论。

1.7.1 时序对齐方法比较

比较最大时间重叠法、最近中心法和重叠加权平均法。表 3 与图 7 给出四项辅助评价指标在固定设置下的结果。三种方法的均值整体接近；最近中心法在部分指标上的均值略高，但在 152 个有效文本时间窗中选择了与目标窗没有正时间交叠的特征。重叠加权平均法未在四项指标上呈现一致优势。因此，最大时间重叠硬对齐的选择依据是明确的时间对应与来源可追踪性，而不是声称其辅助指标绝对最优。

本文采用最大时间重叠硬对齐。该方法以原生区间与公共时间窗的真实交叠确定映射，在每个有效位置保留唯一来源索引，满足时间对应与来源追踪要求。

表 3 不同时序对齐方法的定量比较

对齐方法	准确率	宏平均 F1 值	平均绝对误差 (MAE)	皮尔逊相关系数
最大时间重叠法	0.6129 ± 0.0938	0.4816 ± 0.0850	0.5258 ± 0.0966	0.5419 ± 0.1470
最近中心法	0.6148 ± 0.0913	0.4832 ± 0.0849	0.5210 ± 0.0967	0.5535 ± 0.1492
重叠加权平均法	0.6074 ± 0.0945	0.4712 ± 0.0868	0.5237 ± 0.0977	0.5482 ± 0.1506

注：最近中心法有 152 个有效文本时间窗选择了与目标时间窗零交叠的特征。




图 7 不同时序对齐方法的辅助评价结果。点表示重复分层五折评价均值，半透明区间表示均值上下一个样本标准差。该评价仅用于比较不同特征构建方案的信息保持情况，不作为独立泛化性能或统计显著性结论。

1.7.2 视觉特征提取方法比较

视觉骨干比较仅改变图像编码器，采样帧及时间映射保持一致。两种方案均产生 3205 条视觉原生特征，并具有相同的来源追踪结构。表 4 显示，在当前轻量评价设置下，SigLIP2 的四项指标均值均较 DINOv3 有利，且其特征提取用时更短，因此选用 SigLIP2。DINOv3 的自监督视觉表示作为单变量对照 [5]。

表 4 不同视觉特征提取方法的比较

视觉编码器	准确率	宏平均 F1	MAE	皮尔逊 r	提取时长 (秒)
SigLIP2	0.6129 ± 0.0938	0.4816 ± 0.0850	0.5258 ± 0.0966	0.5419 ± 0.1470	52.37
DINOv3 (ViT-B/16)	0.5899 ± 0.0857	0.4427 ± 0.0760	0.5401 ± 0.0819	0.5155 ± 0.1473	70.38

1.7.3 模态贡献分析

模态组合比较包括文本、语音、视觉三个单模态，三种双模态组合，以及三模态组合。表 5 和附录图 A1 表明，文本单模态已保留较强的情感信息；文本与语音组合在分类指标上表现较好，文本与视觉组合在皮尔逊相关系数上更高。三模态简单拼接未在全部指标上同时取得最优结果。

在相同评价设置下，文本与语音组合的准确率和宏平均 F1 值高于文本单模态；文本与视觉组合的 MAE 更低、皮尔逊相关系数更高，但分类指标低于文本单模态。各组合的优势指标并不相同，因此需要按分类与连续预测目标分别比较其表现。

表 5 不同模态组合的定量比较

模态组合	准确率	宏平均 F1 值	平均绝对误差 (MAE)	皮尔逊 相关系数
文本	0.6519 ± 0.0772	0.5202 ± 0.0935	0.5516 ± 0.0797	0.4998 ± 0.1148
语音	0.6230 ± 0.0756	0.3927 ± 0.1050	0.5936 ± 0.0986	0.2254 ± 0.1800
视觉	0.5332 ± 0.0857	0.4195 ± 0.0942	0.6064 ± 0.0872	0.4428 ± 0.1550
文本 + 语音	0.6783 ± 0.0726	0.5454 ± 0.0900	0.5409 ± 0.0836	0.5135 ± 0.1145
文本 + 视觉	0.5992 ± 0.1049	0.4711 ± 0.0969	0.5257 ± 0.1021	0.5493 ± 0.1580
语音 + 视觉	0.5744 ± 0.0893	0.4617 ± 0.0991	0.5949 ± 0.0833	0.4274 ± 0.1597
文本 + 语音 + 视觉	0.6129 ± 0.0938	0.4816 ± 0.0850	0.5258 ± 0.0966	0.5419 ± 0.1470

1.8 典型样本分析与本问小结

图 8 展示样本 -a55Q6RWvTA__3 的典型时间映射；其中第 24 个统一时间窗对应文本原生特征索引 34、音频特征索引 542 和视觉特征索引 43。三种模态均保留来源索引及时间信息，该案例直接用于核验赛题要求的典型样本映射。本文仅报告来源记录中的索引与时间支持，不外推未记录的原始时间或帧信息。对于官方文本与当前片段语音不一致的样本 -NFrJFQijFE__2，最终处理流程采用该 MP4 的识别文本及其真实时间戳构造文本特征，同时在元数据中保留官方文本。

综上，本文完成了附件 1 全部样本的媒体时间审计、三模态原生特征构造和公共时间轴映射。最大时间重叠硬对齐将不同采样粒度的特征统一为每个样本 50 个时间位置，并通过掩码区分有效特征与无观测位置；样本标识、时间窗、原生索引和媒体时间共同构成可核查的来源链。辅助比较显示，所选方法保持明确的时间交叠与唯一来源索引，各模态组合在不同评价指标上的表现各有侧重。

2 问题二：缺失场景下的多模态情感预测模型

2.1 问题分析与总体方案

局部连续缺失会使部分模态在统一序列中的一段时间没有可用观测，而文本、语音和视觉原本的有效位置仍需区分。问题二直接使用附件 2 已经预计算并对齐的三模态数值特征。本文以掩码均值池化和轻量时间注意力残差池化构成预测主干，图 9 概括其结构；两个预测分支分别输出三类情感和连续强度。




图 8 典型样本的三模态时间映射与来源追踪。以样本 -a55Q6RWvTA__3 为例，展示视觉采样帧显示时间、语音原生特征时间区间和文本特征区间，并放大第 24 个公共时间窗对应的原生来源。该图用于验证统一时间位置能够回溯至实际媒体时间。

模型结构由三条并行的单模态路径和一个共享预测部分构成。每条路径仅在有效时间位置聚合特征，均值表示经独立线性映射、层归一化、GELU 及随机失活后，再与同一映射下的时间注意力表示作残差相加；三模态表示拼接后输入融合层，并连接分类和回归两个输出头。时间打分仅在各模态内部计算，填充位置在 `softmax` 前屏蔽。

该设计保留均值池化对整体上下文的概括，同时允许模型依据输入内容对局部时间位置赋予不同权重。残差系数以零初始化，使新增注意力分支开始时不改变基线表示；模态内打分则避免引入额外的跨模态交互假设。因而该结构以较少新增参数考察时间池化的作用，并保持分类与连续强度预测共享同一融合表示。

2.2 数据表示与预测任务

附件 2 的训练、验证和测试划分分别包含 3395、728 和 727 条样本。每条样本的文本、语音和视觉特征长度均为 50，特征维数依次为 768、74 和 35。本文仅利用训练集拟合参数，使用验证集进行模型确定、三次随机初始化比较及缺失场景分析；附件 2 测试划分不参与上述选择与结论。附件 3 为无标签推理数据，不参与本节评价。

记 $p_{it} \in \{0, 1\}$ 为样本 i 在位置 t 的有效位。该掩码依据附件中的 `text_bert[:, 1, :]` 有效位字段构造；经数据审计，三模态在文本填充区间之外没有非零特征。有效位置中的原生全零向量仍保留在观测序列内。另设观测可用性掩码，仅在构造人工缺失时把指定连续区间置为不可用；模型不把该掩码作为额外输入。三分类按连续标注的负值、零值和正值分别对应消极、中性和积极，并沿用附件给出的实际类别编码。

图 10 描述附件 2 各划分规模，并展示训练集和验证集的三分类标签、连续情感强度及有效序列长度。训练集与验证集的积极类均为多数类、中性类样本相对较少，这一分布构成采用训练集频数计算平衡加权交叉熵的背景；有效长度从 3 至 50 个时间位置不等，说明池化时需显式屏蔽填充位置。图中测试集只显示样本数，其标签未用于此处统计；这些描述性分布不用于推断模型泛化性能。




图9 问题二的轻量时间注意力残差池化结构。三模态分别计算有效位置上的掩码均值与模态内时间注意力池化；共享模态映射后的残差表示经拼接融合，分别输出三类情感和连续强度。




图 10 附件 2 aligned-50 特征的数据划分与标签统计。(a) 训练、验证和测试划分的样本规模；(b) 训练集与验证集的三分类标签分布；(c) 连续情感强度分布；(d) 根据文本有效位字统计的有效序列长度分布。测试划分仅展示样本数量，不参与标签统计、模型选择或性能分析。

2.3 基线多模态情感预测模型

基线模型对各模态分别进行有效位置上的均值池化，然后以独立映射将每个模态压缩至 128 维。对样本 i 的模态 m ，定义

$$\boldsymbol{\mu}_i^{(m)} = \frac{\sum_{t=1}^{50} p_{it} \mathbf{x}_{it}^{(m)}}{\sum_{t=1}^{50} p_{it}}, \quad \mathbf{h}_{i,0}^{(m)} = P_m(\boldsymbol{\mu}_i^{(m)}), \quad (11)$$

其中 P_m 依次包含线性映射、层归一化、GELU 和随机失活。原生零向量只要位于有效位置，就按原值参与式 (11)。三个 128 维表示拼接为 384 维，经 128 维融合层后送入三分类分支与单值回归分支。基线模型共有 163460 个参数。

分类采用仅由训练集类别频数确定的平衡加权交叉熵， $w_c = N/(3N_c)$ ；回归采用 SmoothL1 损失。总目标为

$$\mathcal{L} = \mathcal{L}_{\text{WCE}} + \lambda_r \mathcal{L}_{\text{SmoothL1}}, \quad \lambda_r = 1. \quad (12)$$

输入不作默认标准化，也不在训练时加入人工连续缺失。优化采用 AdamW，学习率 10^{-3} 、权重衰减 10^{-4} 、批量大小 128，随机失活率 0.1；最多训练 80 轮，提前停止耐心轮数为 12。这些设定对应实际实验配置，未依据附件 2 测试划分调整。

2.4 轻量时间注意力残差池化模型

均值池化对有效位置赋予相同权重，可能削弱短暂但关键的情绪线索。为补充时间维度信息，本文对每一模态增加一个标量打分器，并在有效位置上归一化：

$$e_{it}^{(m)} = f_m(\mathbf{x}_{it}^{(m)}), \quad \alpha_{it}^{(m)} = \frac{p_{it} \exp(e_{it}^{(m)})}{\sum_{s:p_{is}=1} \exp(e_{is}^{(m)})}, \quad \mathbf{a}_i^{(m)} = \sum_{t=1}^{50} \alpha_{it}^{(m)} \mathbf{x}_{it}^{(m)}. \quad (13)$$

填充位置在归一化前屏蔽，因此其注意力权重为零。时间表示使用与均值路径相同的模态映射，最终表示为

$$\mathbf{h}_i^{(m)} = P_m(\boldsymbol{\mu}_i^{(m)}) + \gamma_m P_m(\mathbf{a}_i^{(m)}). \quad (14)$$

三个残差系数初始为零，使模型初始预测与相应基线完全一致。改进模型保持已确定的模态映射、融合层和预测分支参数不变，仅估计新增的模态打分器及残差系数，使性能变化集中于池化方式。新增可调参数为 883 个，约为基线参数量的 0.54%；总参数量为 164343。该结构不使用跨模态注意力或额外的重建网络。

2.5 缺失场景构造与鲁棒性评价

评估协议由完整输入和 54 个预定的连续缺失场景组成。单模态场景对文本、语音或视觉分别设置 $\rho \in \{0.1, 0.2, 0.3, 0.4, 0.5\}$ ，并在有效前缀的前段、中段和后段放置遮挡，共 45 种。双模态场景取文本与语音、文本与视觉、语音与视觉三种组合，统一使用 $\rho = 0.3$ 及三个位置，共 9 种。若有效长度为 L_i ，遮挡长度为 $\ell_i = \max(1, \text{round}(\rho L_i))$ ；三个起点依次为 0、 $\lfloor (L_i - \ell_i)/2 \rfloor$ 和 $L_i - \ell_i$ 。人工缺失在模型输入中覆盖为精确零向量，填充区间与原生零记录均不因此改写。各模型使用相同的预定场景定义。

完整输入与各缺失条件均报告准确率、宏平均 F1、平均绝对误差 (MAE) 和皮尔逊相关系数。为在开发验证中同时兼顾分类与回归，另定义内部综合分数

$$S = \frac{1}{4} \text{Acc} + \frac{1}{4} \text{MacroF1} + \frac{1}{4} (1 - \text{MAE} / 6) + \frac{1}{8} (\text{Pearson} + 1), \quad R = \frac{1}{2} \left(S_{\text{clean}} + \frac{1}{54} \sum_{j=1}^{54} S_j \right). \quad (15)$$

R 仅为本项目的验证比较指标，不是竞赛官方评分。基线参数按完整输入验证分数确定，改进模型按预定的 R 确定；比较时保留这一选择口径差异。图 11 和图 12 分别用于展示比

例变化与模态/位置组合。




图 11 不同单模态连续缺失比例下的验证集性能。每个比例先对三种模态与前、中、后三种遮挡位置取平均，再绘制三次随机初始化的均值与样本标准差；阴影为样本标准差。蓝线为掩码均值池化基线，红线为时间注意力残差池化模型；MAE 越低越好，其余指标越高越好。

2.6 实验结果与分析

2.6.1 完整输入与平均缺失条件

表 6 给出三次随机初始化的验证集均值及样本标准差。完整输入下，本文模型的宏平均 F1 由 0.6139 增至 0.6241，MAE 由 0.6079 降至 0.6059；平均缺失条件下，宏平均 F1 由 0.6092 增至 0.6163，MAE 由 0.6111 降至 0.6091，相关系数由 0.6359 增至 0.6414。与此同时，平均缺失准确率从 0.6349 略降为 0.6340。这些结果支持小幅平均改进，不支持所有指标均改善的表述。

2.6.2 缺失比例、模态与位置

不同遮挡比例的分组结果如图 11 所示。随着缺失范围扩大，两个模型的内部综合分数整体下降；在比例 0.5 的分组中，本文模型与基线模型的平均综合分数分别为 0.7392 与 0.7372。图 12 进一步显示，收益依赖模态和缺失位置：18 个模态/位置组合中，宏平均 F1 有 17 个均值差为正，相关系数有 18 个为正，MAE 改善有 16 个为正，而准确率仅 6 个为正。该方向计数不表示每次随机初始化或每个样本均受益。文本与语音、文本与视觉同时缺失时，综合收益接近零，说明关键模态同时失去观测后，简单池化残差的补偿能力有限。




图 12 缺失模态及位置对模型间性能差异的影响。宏平均 F1、相关系数和准确率为“本文模型减基线模型”，MAE 为“基线模型减本文模型”，故正值均表示本文模型较优；色块为验证集三次随机初始化均值之差。

表 6 附件 2 验证集上完整输入与 54 种缺失条件的预测结果（三次随机初始化均值 $\pm$ 样本标准差）

模型	条件	准确率 $\uparrow$	宏平均 F1 $\uparrow$	MAE $\downarrow$	相关系数 $\uparrow$
基线模型	完整	0.6401 ± 0.0048	0.6139 ± 0.0091	0.6079 ± 0.0103	0.6409 ± 0.0043
本文模型	完整	0.6419 ± 0.0057	0.6241 ± 0.0026	0.6059 ± 0.0066	0.6472 ± 0.0025
基线模型	平均缺失	0.6349 ± 0.0062	0.6092 ± 0.0075	0.6111 ± 0.0098	0.6359 ± 0.0038
本文模型	平均缺失	0.6340 ± 0.0049	0.6163 ± 0.0012	0.6091 ± 0.0060	0.6414 ± 0.0025

2.6.3 随机初始化稳定性与误差分析

三次对应初始化下，本文模型相对基线模型的综合鲁棒分数差依次为 $+0.005600$ 、 $+0.003791$ 和 -0.000090 ，平均为 $+0.003100 \pm 0.002907$ （样本标准差）。两次获得正向改进，一次基本持平，表明改进具有一定初始化敏感性。图 13(a) 给出相同种子下的配对分数；(b) 展示种子 42 的干净验证集混淆矩阵，便于观察中性类的识别差异；(c) 汇总不同缺失场景的选择分数；(d) 单独呈现视觉整段原生全零子集。基线与本文模型的鲁棒分数均值分别为 0.741677 ± 0.001458 和 0.744777 ± 0.001492 。验证集中有 15 个视觉整段原生全零样本，保留该子集及原标签后观察到部分初始化下本文模型在该子集的分类表现低于基线，因此不能用总体均值掩盖这一局部风险。




图 13 最终模型的稳定性与误差分析。(a) 三个训练种子下与对应基线的配对鲁棒分数；(b) 种子 42 的干净验证集混淆矩阵，行为真实类别、列为预测类别；(c) 按缺失形式汇总的选择分数；(d) 15 条视觉整段原生全零样本的分类准确率与宏平均 F1。误差线表示三次训练种子的样本标准差，不表示置信区间。

2.7 消融分析

表 7 压缩展示主要结构选择。更深的单模态时间编码器与训练阶段连续遮挡增强，在三次初始化的相同验证协议下均未超过基线。均值与最大值残差池化在一次初始化下有正向迹象，但缺少重复验证；低秩模态交互分支在同次初始化下降。跨模态重建的非零混合比例未在三次初始化中给出一致正收益；文本单独标准化下降，增大回归损失权重的收益很小且伴随准确率下降。可靠性加权分支有单次初始化的正向诊断，但没有同样完整的重复证据。因而本文保留参数开销较小、具有三次初始化配对结果的时间注意力残差池化方案。

表 7 主要结构与训练策略的验证集消融摘要。一次初始化结果仅为筛选证据，不与三次初始化均值作统计等同解释

方案	初始化次数	总参数量	综合鲁棒分数
基线模型	3	163460	0.7417 ± 0.0015
单模态时间编码	3	957572	0.7351 ± 0.0020
基线加训练期连续遮挡	3	163460	0.7385 ± 0.0025
均值与最大值残差池化	1	163463	0.7443
轻量时间注意力残差池化	3	164343	0.7448 ± 0.0015

2.8 公开多模态模型对比

表 8 对比 TFN、MulT、MISA 与本文模型在附件 2 完整输入验证集上的三次初始化结果。三种公开模型均针对本题的 aligned-50 预计算特征作架构适配，并非对原论文训练流程的完全复现。公开模型按完整输入验证分数选择 **checkpoint**，本文模型沿用固定缺失场景的综合鲁棒分数选择 **checkpoint**，比较时须保留这一口径差异。

表 8 公开多模态模型在附件 2 完整输入验证集上的对比（三次初始化均值 $\pm$ 样本标准差）

方法	参数量	准确率 $\uparrow$	宏平均 F1 $\uparrow$	MAE $\downarrow$	相关系数 $\uparrow$
TFN	4,840,670	0.6099 ± 0.0076	0.5872 ± 0.0083	0.6336 ± 0.0102	0.6056 ± 0.0098
MulT	624,094	0.6172 ± 0.0148	0.5891 ± 0.0236	0.6221 ± 0.0260	0.6369 ± 0.0115
MISA	1,118,852	0.6131 ± 0.0083	0.6010 ± 0.0060	0.9175 ± 0.1005	0.6269 ± 0.0087
本文模型	164,343	0.6419 ± 0.0057	0.6241 ± 0.0026	0.6059 ± 0.0066	0.6472 ± 0.0025

本文模型在准确率、宏平均 F1 和皮尔逊相关系数上取得更高均值，MAE 均值更低，参数量也较少。MISA 的 MAE 相对较高；已有检查确认其回归标签尺度、回归头输出和评价实现未发现错误，因此表中保留实际结果。

2.9 附件 3 专项测试集最终预测

附件 3 对齐版仅提供 text_bert、audio 与 vision，没有预计算的 text 特征。本文复用已验证的 text_bert $\rightarrow$ bert-base-uncased $\rightarrow$ text[50,768] 接口适配：在 20 条同时具有原始文本特征与标记张量的已知样本上，604/604 个有效行的余弦相似度最大值均位于同索引；特征最大绝对差为 3.0041×10^{-5} ，RMSE 为 8.3977×10^{-7} 。同一锁定模型分别输入原特征与重构特征时，分类 logit 和回归输出的最大绝对差为 2.44×10^{-6} 与 1.12×10^{-6} 。模型参数未修改，也未重新训练。

表 9 列出全部 30 条附件 3 样本的最终预测。分类置信度为预测类别的 softmax 概率；表内不使用真实标签，也不据此调整模型。

表 9 附件 3 全部 30 条无标签样本的最终预测

样本 ID	预测类别	连续情感强度	分类置信度
附件 3_01	消极	-0.405876	0.7460
附件 3_02	中性	-0.144469	0.6501
附件 3_03	中性	-0.128127	0.6101
附件 3_04	积极	+0.514640	0.6097
附件 3_05	消极	-1.642545	0.9405

续下页

续表 9

样本 ID	预测类别	连续情感强度	分类置信度
附件 3_06	积极	+0.765383	0.7435
附件 3_07	中性	+0.249776	0.4401
附件 3_08	消极	-0.337494	0.5324
附件 3_09	积极	+1.076601	0.8747
附件 3_10	中性	-0.178815	0.7725
附件 3_11	中性	+0.010376	0.5348
附件 3_12	积极	+0.922382	0.6466
附件 3_13	积极	+0.237651	0.4991
附件 3_14	消极	-0.550781	0.7443
附件 3_15	积极	+0.684222	0.7227
附件 3_16	积极	+1.539758	0.9228
附件 3_17	消极	-0.589950	0.4977
附件 3_18	积极	+0.246677	0.4397
附件 3_19	消极	-0.320886	0.4778
附件 3_20	中性	-0.246796	0.6422
附件 3_21	积极	+0.667961	0.7211
附件 3_22	中性	+0.186271	0.4059
附件 3_23	中性	+0.138655	0.6286
附件 3_24	消极	-0.458430	0.5284
附件 3_25	中性	+0.048311	0.5231
附件 3_26	积极	+0.574989	0.7292
附件 3_27	积极	+0.567220	0.6708
附件 3_28	积极	+0.397136	0.4846
附件 3_29	中性	+0.071600	0.4322
附件 3_30	中性	-0.202034	0.5667

预测类别中，消极 7 条（23.33%）、中性 11 条（36.67%）、积极 12 条（40.00%）。预测情感强度均值为 0.123114，样本标准差为 0.611792，范围为 $[-1.642545, 1.539758]$ ；平均分类置信度为 0.624599。附件 3 是无标签专项测试集，上述数值仅描述预测分布，不能计算准确率、宏平均 F1、MAE 或皮尔逊相关系数，也不能据此判断预测正确率。

2.10 本问小结

本问直接利用预计算特征，依靠有效位掩码防止填充进入池化，并以固定连续缺失场景检验预测模型。轻量时间注意力残差池化在宏平均 F1、MAE 及相关性上取得小幅平均收益，但准确率、个别双模态缺失条件及原生视觉全零子集仍有限制。下一问据此在同一预测函数上分析模型决策依据，而不把内部归因直接等同于真实媒体的因果解释。

3 问题三：多模态情感预测的层级证据归因

3.1 问题分析与总体框架

情感预测给出类别与强度，却不能直接说明哪种模态、哪一段有效序列以及哪项输入证据影响了输出。为此，在问题二确定的多模态情感预测模型基础上，本文构建层级式多模态证据归因框架（Hierarchical Evidence Attribution Framework, HEAF）。该框架依次计算模态级精确贡献、模态对交互、连续窗口遮挡效应、删除干预一致性，并把关键槽位连接到经核验的特征来源。总体流程见图 14：上部为三模态特征经掩码均值池化与注意力残差池化后的固定预测路径，下部在复用同一预测器的条件下依次分析模态联盟、贡献、交互和关键特征区间；右侧将预测与分层证据组织为解释卡。以下解释的是固定预测函数对输入干预的响应，不直接等同于情绪的现实因果来源。

HEAF 由固定预测器、模态联盟归因、连续窗口定位和证据来源映射四级组成。三种

模态构成八个完整联盟，以同一预测函数计算分类对数优势与回归输出的精确 Shapley 贡献，并进一步分解模态对交互；随后在主导模态的有效序列上滑动连续窗口，记录遮挡前后的输出差异，再将选中位置与等长随机窗口及分段删除结果比较。文本关键槽位连接至 BERT 标记和原文字符跨度，音频与视觉关键槽位连接至对应的未对齐特征行。

该层级安排分别回答“哪些模态参与输出”“哪些局部位置对当前预测敏感”以及“关键区间对应哪些特征来源”三个问题。固定预测器和完整联盟使模态贡献可以逐一计算并检查加和关系；连续窗口保留局部序列结构；来源映射使文本、音频、视觉分别获得与其核验结果相符的证据粒度。




图 14 多模态情感预测与层级证据归因框架。固定预测器给出类别与连续情感强度；HEAF 计算模态贡献与交互，并以连续遮挡定位关键特征区间。文本槽位进一步连接原文字符跨度，音频与视觉槽位连接对应的未对齐特征行。图中视频画面和波形为输入上下文示意。

3.2 模态级精确 Shapley 归因

三种模态的联盟共有 $2^3 = 8$ 个，故可逐一计算所有组合，无需采样近似。令 $\mathcal{M} = \{T, A, V\}$, $S \subseteq \mathcal{M}$ 表示保留的模态集合；未保留模态只在有效位置清零，填充与原生零记录不变。分类解释固定完整输入时预测的类别 c^* ，以该类别相对其余类别的对数优势为联盟目标：

$$v_c(S) = z_{c^*}(S) - \log \sum_{k \neq c^*} \exp z_k(S), \quad v_r(S) = \hat{y}^r(S). \quad (16)$$

空联盟对应所有有效模态均被清零后的模型输出。对分类或回归目标分别计算

$$\phi_m = \sum_{S \subseteq \mathcal{M} \setminus \{m\}} \frac{|S|! (2 - |S|)!}{3!} [v(S \cup \{m\}) - v(S)]. \quad (17)$$

由此有 $\sum_m \phi_m = v(\mathcal{M}) - v(\emptyset)$ ，可用作计算完整性检查。分类贡献的单位是对数优势，回归贡献的单位是连续情感强度，两者不可直接混合排序。分类主导模态取最大正贡献；若三者均不为正，则取绝对贡献最大者并标明其非正性质。回归主导模态取绝对贡献最大者；

并列时按文本、语音、视觉的固定顺序处理。下述时间分析遵循分类主导模态。

3.3 模态间交互分析

单个模态贡献之外，本文对文本–语音、文本–视觉和语音–视觉分别计算二阶交互。对模态 i, j 及剩余模态 k ，令

$$I_{ij} = \frac{1}{2}\{v(\{i, j\}) - v(\{i\}) - v(\{j\}) + v(\emptyset) + v(\mathcal{M}) - v(\{i, k\}) - v(\{j, k\}) + v(\{k\})\}. \quad (18)$$

该量平均了不含和包含第三模态两种背景下的二阶差分。正值表示联合贡献超过相应加性基准；负值表示联合贡献低于该基准，其具体含义还需结合样本与目标函数解释，不能一概称为冗余。分类和回归仍分别计算交互量。

在附件 2 验证集 728 条样本上，两种目标的二阶交互统计见表 10。分类目标中，文本–语音和语音–视觉的平均交互为负，文本–视觉为正；回归目标中，文本–语音为负，其余两对为正。符号仅描述固定模型的联合输入相对可加和组合的预测贡献。附件 4 的样本 16 给出一个较强的个体交互例子，其文本–视觉分类交互为 -0.724 ，与总体平均值的方向不同，体现了逐样本解释的必要性。

表 10 附件 2 验证集分类与回归解释目标的二阶模态交互 ($n = 728$)

解释目标	模态对	平均交互	主要符号比例	主要符号
分类	文本–语音	-0.0706	69.4%	负
	文本–视觉	$+0.0781$	60.3%	正
	语音–视觉	-0.0372	64.4%	负
回归	文本–语音	-0.1592	85.7%	负
	文本–视觉	$+0.0503$	65.4%	正
	语音–视觉	$+0.0592$	84.1%	正

3.4 连续窗口时间遮挡与关键区间定位

模态级归因给出重要模态，却未确定模态序列中的局部位置。对分类主导模态，在有效长度 L_i 内设窗口长度 $w_i = \max(1, \text{round}(0.30L_i))$ ，以步长 1 遍历所有连续窗口。记 $g(\mathbf{x})$ 为式 (16) 的固定类别对数优势，窗口 W 的遮挡效应为

$$D_i(W) = g(\mathbf{x}_i) - g(\mathbf{x}_i^{\setminus W}), \quad (19)$$

其中仅该模态在窗口 W 内的有效特征被清零。若存在正效应，取 $D_i(W)$ 最大的窗口；否则取绝对效应最大的窗口并标注方向。平局选择最早位置。覆盖某位置的窗口效应最大值形成 50 位局部曲线。图中的区间以从零开始的对齐特征槽位表示。对回归报告有符号或绝对输出变化，不预设遮挡使情感强度单向下降。

3.5 解释忠实性的干预一致性检验

问题三复用问题二的固定预测器 (seed 42)，类别与强度的预测接口保持一致。其在附件 2 验证集上的基础性能见表 11。中性类别 F1 为 0.467836、召回率为 0.434783，低于另外两类，是主要分类误差来源之一。以下干预统计衡量解释与模型输出变化的一致性，与该表的预测性能含义不同。

时间窗口比例 0.30 是在附件 2 验证集的设计子集上确定的。按视频标识分组后，设计子集含 332 条片段、113 个视频标识，独立的审计子集含 396 条片段、126 个视频标识，两组视频标识无交集。审计时把所选窗口与 32 次随机抽取的等长窗口比较，并按时间曲线删除 10%、20%、30%、40% 的有效位置；区间估计采用视频分组自助采样。

表 11 Q3 固定预测器在附件 2 验证集上的基础性能 (seed 42, $n = 728$)

Accuracy	Macro-F1	MAE	Pearson
0.648352	0.623435	0.608260	0.646170
消极 F1	中性 F1	积极 F1	中性召回率
0.689655	0.467836	0.712813	0.434783

表 12 显示，审计子集上所选窗口的平均分类对数优势下降为 0.482771，随机窗口为 0.082036，差值 0.400735，对应分组自助采样 95% 区间为 [0.3635, 0.4372]；以每条样本 32 次随机抽样的均值为对照，所选窗口效应更大的审计样本比例为 1.0。置信度下降差为 0.077718，类别 logit 下降差为 0.239688。连续回归输出的有符号差为 -0.018095 且区间跨零，但绝对变化差为 0.103545。图 15 同时展示 728 条验证样本的主导模态分布及审计子集的删除曲线。

表 12 附件 2 验证集审计子集的解释干预一致性结果 (396 条片段；按视频分组的 95% 自助采样区间)

输出量	所选窗口	随机等长窗口	平均差	95% 区间
分类对数优势下降	0.482771	0.082036	0.400735	[0.3635, 0.4372]
分类置信度下降	0.093286	0.015567	0.077718	[0.0712, 0.0843]
分类 logit 下降	0.292982	0.053294	0.239688	[0.2195, 0.2603]
回归有符号变化	0.002082	0.020177	-0.018095	[-0.0526, 0.0141]
回归绝对变化	0.202760	0.099215	0.103545	[0.0883, 0.1203]

删除 10%、20%、30%、40% 有效位置时，所选位置相对随机位置的平均分类边际下降差分别为 0.108296、0.237758、0.418076 和 0.465465。单个关键窗口由候选窗口中的最大影响值确定，故该优势包含选择效应；干预结果表示固定模型的扰动响应一致性，与预测正确率分别解释。固定审计子集上的跨种子解释稳定性见表 13：主导模态与贡献排序整体具有较高一致性，关键区间的位置波动更明显。

表 13 附件 2 审计子集的跨种子解释稳定性 (seed 42 分别与 43、44 比较； $n = 396$)

解释目标	种子对	主导模态一致率	Shapley 排序相关	关键区间 IoU
分类	42/43	0.869	0.818	0.579
	42/44	0.831	0.783	0.527
回归	42/43	0.778	0.745	—
	42/44	0.783	0.760	—

分类排序相关仅统计两种子预测类别一致的样本；区间定位按分类目标定义，回归未单独定义关键区间。

3.6 分层证据来源映射

附件 4 的文本链路连接“对齐特征槽位 → BERT 标记 → 原文字符区间”。20 条样本共 604 个有效文本槽位的同索引余弦最大值均位于对应行，平均同索引余弦为 0.999999994，最大绝对特征差为 3.0041×10^{-5} ，重构均方根误差为 8.3977×10^{-7} 。据此，文本主导案例的关键槽位可呈现其原文片段及字符跨度。

音频与视觉采用“对齐特征槽位 → 未对齐特征行”的证据层级。附件 4 中，564/564 个非零音频对齐行、534/534 个非零视觉对齐行均在对应样本的未对齐特征数组中具有唯




图 15 验证集上的主导模态与删除干预结果。(A) 728 条样本的分类/回归主导模态计数；(B) 审计子集上所选与随机窗口的分类边际下降及视频分组 95% 区间；(C) 两种删除方式的配对差。所选窗口来自同一候选集合的最大影响值，因此相对随机窗口的优势含选择效应。

一旦逐元素相等的行。因而关键区间可进一步给出特征行索引。图 16 中的视频画面标作“视频上下文示意”，用于呈现对应样本的场景背景。

3.7 附件 4 预测解释结果

依据前述方法对附件 4 的 20 条对齐样本生成预测与解释卡。表 14 汇总类别、主导模态和证据层级；表 15 列出全部预测，表 16 列出对应的三模态分类贡献及关键区间。附件 4 为无标签样本，这些表反映预测与解释分布，不作为预测性能评价。

表 14 附件 4 的无标签预测及解释摘要（共 20 条样本）

统计项	类别或状态	数量	比例
预测情感类别	消极	7	35%
	中性	5	25%
	积极	8	40%
分类主导模态	文本	19	95%
	语音	0	0%
	视觉	1	5%
回归主导模态	文本	18	90%
	语音	0	0%
	视觉	2	10%
分类主导证据层级	原文字符级	19	95%
	未对齐特征行级	1	5%

表 15 附件 4 全部 20 条无标签样本的预测结果

样本 ID	预测类别	情感强度	分类置信度
01	中性	+0.177915	0.5359
02	消极	-0.027301	0.3898
03	中性	-0.064430	0.5441
04	消极	-0.398096	0.6741
05	积极	+0.886586	0.7131
06	积极	+0.759221	0.7287
07	积极	+0.799232	0.7699
08	积极	+0.678992	0.7512
09	消极	-1.987819	0.9671
10	消极	-1.556107	0.9453
11	消极	-0.965641	0.8577
12	消极	-0.981858	0.8488
13	中性	+0.173788	0.5675
14	中性	+0.154869	0.5568
15	积极	+1.267568	0.8941
16	消极	-2.030377	0.9670
17	积极	+1.656759	0.9493
18	中性	-0.158624	0.5781
19	积极	+0.276115	0.3840
20	积极	+0.875848	0.8013

表 16 附件 4 全部 20 条样本的分类贡献与证据层级：区间为从零开始的对齐特征槽位 $[a, b)$

ID	ϕ_T	ϕ_A	ϕ_V	主导模态	关键区间	证据层级
01	+0.4448	+0.0283	+0.0097	文本	[17, 24)	原文字符级
02	-0.1971	+0.2277	+0.8294	视觉	[1, 7)	特征行级
03	+0.6919	-0.1267	-0.0492	文本	[0, 10)	原文字符级
04	+1.9249	+0.1198	-0.0096	文本	[20, 28)	原文字符级
05	+1.1092	-0.3336	+0.6619	文本	[0, 5)	原文字符级
06	+2.2790	-0.2529	-0.5109	文本	[14, 25)	原文字符级
07	+1.6925	-0.3365	+0.3790	文本	[13, 28)	原文字符级
08	+2.4908	-0.2620	-0.5967	文本	[8, 12)	原文字符级
09	+4.0872	+0.4352	+0.1656	文本	[2, 8)	原文字符级
10	+3.6626	+0.4324	+0.0621	文本	[21, 31)	原文字符级
11	+2.0970	+0.2465	+0.7610	文本	[1, 6)	原文字符级
12	+2.1874	-0.0032	+0.8495	文本	[31, 44)	原文字符级
13	+0.5928	+0.0180	+0.0000	文本	[0, 10)	原文字符级
14	+1.5361	+0.0546	-1.0233	文本	[1, 12)	原文字符级
15	+2.9847	-0.3149	-0.0090	文本	[14, 21)	原文字符级
16	+3.8314	+0.4557	+0.3986	文本	[8, 12)	原文字符级
17	+3.4202	-0.1421	+0.1781	文本	[9, 17)	原文字符级
18	+0.8431	-0.0933	-0.0955	文本	[6, 21)	原文字符级
19	+0.6310	-0.4071	-0.1692	文本	[29, 41)	原文字符级
20	+2.0873	-0.2851	+0.1195	文本	[0, 14)	原文字符级

分类与回归的主导模态在 17 条样本上相同，占 85%。19 条文本主导样本对应原文字符级证据；一条视觉主导样本对应未对齐特征行级证据。表中的 ϕ 均为分类对数优势目标的 Shapley 贡献。

3.8 典型样本分析与本问小结

图 16 展示两条按既定规则选取的案例。样本 14 为文本主导的原文证据案例：预测类别为中性，连续强度 +0.154869，分类贡献 $\phi_T = +1.536072$ 、 $\phi_A = +0.054570$ 、 $\phi_V = -1.023311$ 。关键特征区间为 [1, 12)，对应原文字符区间 [0, 38)，原文片段为“**He is the co-founder of Rossen and Vet**”。

样本 02 为视觉特征级证据案例：预测类别为消极，连续强度 -0.027301，分类贡献 $\phi_T = -0.197115$ 、 $\phi_A = +0.227718$ 、 $\phi_V = +0.829375$ 。视觉关键区间 [1, 7) 包含从零开始的对齐槽位 1–6，逐行对应未对齐视觉特征行 36–41。图中的视频画面仅作上下文示意。两个案例共同呈现模态贡献、关键槽位和相应的证据来源。

本问形成三层解释：模态层以精确 Shapley 贡献确定文本、语音、视觉的作用及主导模态；区间层以连续遮挡定位对预测敏感的对齐特征区间；证据层将文本区间映射至原文字符片段，将音频与视觉区间映射至未对齐特征行。验证集干预检验支持解释与固定模型输出变化的一致性，附件 4 给出无标签样本的逐条解释。原始音视频时间位置不纳入本文证据粒度。

A 文本主导典型案例（样本14）




视频上下文示意

预测类别 中性 情感强度 +0.155
置信度 0.557 分类主模态 文本

已验证文本证据

"He is the co-founder of Rossen and Vet"



B 视觉特征级证据案例（样本02）



视频上下文示意

预测类别 负面 情感强度 -0.027
置信度 0.390 分类主模态 视觉

视觉证据: 对齐槽位 1-6 → 未对齐特征行 36-41




图 16 附件 4 两条典型样本的层级解释。(A) 样本 14 的文本关键槽位映射至原文字符区间；(B) 样本 02 的视觉关键槽位 1-6 映射至未对齐视觉特征行 36-41。视频画面为“视频上下文示意”。

4 模型评价与进一步讨论

4.1 三个问题的衔接与适用范围

本文按照“可追溯特征构建—缺失场景预测—决策证据解释”组织三项工作。问题一在附件 1 原始媒体上建立统一时间窗和来源链，保证特征位置有明确的媒体时间依据；问题二使用附件 2 已经提供的对齐特征，检验轻量预测模型在有效位置局部连续缺失时的开发验证表现；问题三将确定的预测函数用于附件 4，生成模态贡献、交互、关键特征槽位与可核验文本片段。三项工作共享掩码和时间语义的审慎原则，但不应被误写为附件 1 特征直接输入问题二模型。

4.2 预测收益、复杂度与误差边界

问题二的改进结构仅比基线增加 883 个参数，三次随机初始化的平均综合鲁棒分数增加 0.003100，但其中一次基本持平。平均缺失条件下的宏平均 F1、MAE 及相关系数方向较好，准确率略低；部分双模态缺失组合的改进接近零，原生视觉全零样本也存在不利结果。因此，较小的参数开销和平均分数收益是本方法的主要优势，而非对所有缺失类型的普遍优势。基线按完整输入分数、改进模型按综合分数选取参数的口径差异也限制了二者的严格横向解释。综合分数只是内部验证工具，正式判断仍须同时查看四项原始指标。

问题一的重复分层五折评价用于比较特征构建与对齐方案的信息保持能力。该评价的训练/评价折间存在同一视频标识的片段，因此不能将这些数值解释为独立视频上的泛化性能或统计显著性证据。问题二使用附件 2 预定训练与验证划分，所有模型选择及缺失场景比较限于验证集；附件 2 测试划分与附件 3 不支撑本文所报告的验证结论。

4.3 解释证据的层级边界

问题三的八联盟精确计算保证了模态贡献满足加和关系；连续遮挡和删除曲线提供预测函数内部的干预响应证据。然而关键窗口由最大响应准则选取，故其相对随机窗口的优势包含选择效应。文本特征行到标记、再到原始字符片段的链路在附件 4 得到数值核验，语音与视觉特征槽位仍无可靠的媒体时间映射。模型解释可以定位“哪种模态、哪个特征槽位影响当前输出”，但不能据此直接断言真实情绪因果、精确音频秒数或关键视频帧。附件 4 缺乏标签，也无法评估其预测准确性。

在实际应用中，可将类别与强度预测、模态贡献、局部敏感性及证据核验状态同时输出，使用户区分模型决策依据与原始媒体证据。后续若获取可验证的音视频预处理记录和原始时间映射，才能把当前特征槽位层的解释进一步扩展到音频时间和视频帧。

5 结论

针对复杂场景下多模态情感识别的三个问题，本文形成了由原始媒体特征构建、局部缺失预测到层级证据解释的完整方案。问题一对附件 1 三模态媒体分别构造带时间支持的原生特征，以最大时间重叠映射至 50 个公共时间窗，并保留有效掩码和来源索引，得到可追溯的时序表示。其辅助交叉验证帮助比较构建方案，但不作为独立泛化结论。

问题二直接利用附件 2 预计算对齐特征，建立三分类与连续强度的双任务基线，并用轻量时间注意力残差池化补充均值池化的时间选择能力。在验证集的完整输入和 54 种连续缺失条件下，三次初始化的平均综合鲁棒分数取得小幅改进；宏平均 F1、MAE 与相关系数的平均方向较好，准确率略有下降，而且收益随初始化与缺失场景变化。该结果支持选择低参数开销的模型，同时要求对具体应用场景继续检查误差。

问题三提出层级式多模态证据归因框架，通过八种模态联盟的精确贡献、模态间交互、连续时间遮挡和删除干预，构建由模态到局部区间的解释。附件 4 的 20 条无标签样本均生成预测与解释卡；文本证据可映射到经核验的原始字符片段，语音与视觉目前仅能定位到特征槽位。后续工作应以独立来源的音视频时间映射和有标签外部评价扩展现有证据边界，而不能把无标签预测或模型干预响应当作真实情感的正确性与因果证明。

参考文献

- [1] Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *Proceedings of Machine Learning Research*, pages 28492–28518. PMLR, 2023.
- [2] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa: A robustly optimized BERT pretraining approach. *arXiv preprint arXiv:1907.11692*, 2019.
- [3] Sanyuan Chen, Chengyi Wang, Zhengyang Chen, Yu Wu, Shujie Liu, Zhuo Chen, Jinyu Li, Naoyuki Kanda, Takuya Yoshioka, Xiong Xiao, Jian Wu, Long Zhou, Shuo Ren, Yanmin Qian, Yao Qian, Jian Wu, Michael Zeng, Xiangzhan Yu, and Furu Wei. WavLM: Large-scale self-supervised pre-training for full stack speech processing. *IEEE Journal of Selected Topics in Signal Processing*, 16(6):1505–1518, 2022.
- [4] Michael Tschanen, Alexey Gritsenko, Xiao Wang, Muhammad Ferjad Naeem, Nikhil Alabdulmohsin, Nikhil Parthasarathy, Talfan Evans, Lucas Beyer, Ye Xia, Basil Mustafa, Olivier Hénaff, Jeremiah Harmsen, Andreas Steiner, and Xiaohua Zhai. SigLIP 2: Multilingual vision-language encoders with improved semantic understanding, localization, and dense features. *arXiv preprint arXiv:2502.14786*, 2025.
- [5] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, et al. DINOv3: Self-supervised learning for vision at unprecedented scale. *arXiv preprint arXiv:2508.10104*, 2025.

A Q1 补充模态组合评价

本附录给出不同模态组合的辅助评价结果，与正文表 5 的精确数值相对应。正文图 7 展示的时序对齐比较和图 8 展示的典型样本来源追踪均已移至问题一正文。




图 A1 不同模态组合的辅助评价结果。点表示均值，独立的半透明区间表示均值上下一个样本标准差；圆形、方形和菱形分别表示单模态、双模态和三模态组合。