

三模态原始输入

文本

Best

things

in

life

are

free

音频

视频



Text Encoder

RoBERTa

文本特征及时间区间

Audio Encoder

WavLM

语音特征及时间区间

Visual Encoder

SigLip2

视觉特征及显示时间

最大时间重叠对齐

$$j_{ik}^{(m)} = \arg \max_j |I_{ij}^{(m)} \cap B_{ik}|$$

仅映射具有正时间交叠的特征

可追溯对齐结果

B24 10.63–11.08 s

时间 T (s)

0

5

10

15